

답러닝을 활용한 AI 생성 슷폼 영상 탐지 서비스

설 계 서

2026.04.05

가천대학교 컴퓨터공학과

팀장 ■ 권민재(202337639)
팀원 ■ 김지혁(202337642)
팀원 ■ 백현종(202337648)
팀원 ■ 신채은(202334687)
팀원 ■ 조민수(202136037)

문서 정보

본 문서는 딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스 개발을 위한
요구규격 및 설계서입니다.

버 전	1.0
작성일	2026-04-05
상 태	☐ 완료 ☐ 진행 중 ☒ 초안

버전	변경한 사람	변경한 날짜	버전업 변경(또는 추가)내용
0.1	김지혁	2026-03-30	시나리오 구성도 작성 및 요구기능정의
0.2	김지혁	2026-03-30	서비스 아키텍처와 시퀀스 다이어그램
0.3	권민재	2026-03-30	프로젝트 개요 작성
0.4	신채은	2026-03-31	데이터 분석 및 전처리, 성능 시험 작성
0.5	조민수	2026-04-02	AI학습모델의 설계 및 다이어그램 작성
0.6	김지혁	2026-04-03	API설계, 데이터 설계 및 개발환경구성 작성
0.7	권민재	2026-04-04	UI 설계 작성
0.8	백현종	2026-04-04	AI학습모델(딥페이크)설계 및 다이어그램 작성
0.9	백현종	2026-04-05	요구사항 명세, 유스케이스 모델 및 성능평가지표(XAI) 작성
1.0	권민재	2026-04-05	설계서 초안 작성 완료

목 차

1. 프로젝트 개요	
1.1 개발목표와 범위	5
1.2 개발일정/산출물	6
1.3 개발조직/역할	6
2. 요구사항 정의	
2.1 서비스 구성 및 개요	7
2.2 데이터분석의 요구사항	9
2.3 AI학습서버의 요구사항	10
2.4 AI서비스 유스케이스 모델	12
2.5 요구기능 정의(웹사용자용)	16
3. 데이터 분석 및 전처리	
3.1 데이터 수집출처 및 수집방법	17
3.2 데이터 특징추출 및 특징분포	20
3.3 데이터세트 정의 및 생성	23
4. AI학습모델의 설계	
4.1 모델 파이프라인의 구성	25
4.2 AI학습 알고리즘 선정	29
4.3 AI학습 파라미터 설정	34
4.4 AI학습 모델의 생성	39
5. 화면(UI)설계	
5.1 사용자 메뉴구성	43
5.2 초기화면(로그인 전화면)설계	44
5.3 사용자 화면설계(웹)	45
6. 프로세스(기능) 설계	
6.1 시스템 아키텍처	56
6.2 사용자 기능설계(Sequence Diagram)	58
6.3 AI학습서버 기능설계	61

7. API 설계	
7.1 서버/클라이언트 구조	65
7.2 서비스 REST API 정의	66
7.3 서비스 REST API 설계	67
7.4 AI학습서버 REST API 설계	72
8. 데이터 설계	
8.1 ERD	73
8.2 논리적설계(테이블명세서)	74
8.3 로그파일 설계	76
8.4 오류코드 및 오류파일 설계	77
9. 성능시험지표	
9.1 AI서비스 성능평가지표	79
9.2 AI학습 성능(ROC)	83
9.3 AI학습 성능(ROC) 및 평가지표 분석	84
10. 개발환경구성	
10.1 개발환경	86
10.2 소스디렉터리 구조	87
10.3 명칭표준안(변수, 함수, 파일명 등)	88

1. 프로젝트 개요

1.1. 개발목표와 범위

■ 개발목표

본 설계서는 웹 기반 환경에서 AI 생성 영상(딥페이크 및 Text-to-Video) 탐지 서비스를 개발하기 위한 설계서이다. 주요 사용자는 일반 인터넷 사용자이며, PC 및 모바일 브라우저를 통해 접속하고 편리하게 이용할 수 있도록 고안되는 것을 전제로 한다. AI 생성 영상 탐지 기능을 핵심으로 하며, 비로그인 사용자도 기본 탐지 기능을 이용할 수 있고, 로그인 사용자는 분석 기록 저장 및 조회 등 추가 기능을 사용할 수 있도록 개발한다.

아래 그림1-1은 본 서비스의 전체적인 구성을 나타내며, 비로그인 사용자(Guest)와 로그인 사용자(User) 두 종류의 사용자가 본 서비스를 사용한다.




그림 1.1 서비스 설계 범위

■ 개발필요성

본 서비스는 딥페이크 및 T2V AI 생성 영상의 확산으로 인한 사회적 피해를 방지하고, 사용자가 영상의 진위를 직접 확인할 수 있는 신뢰 가능한 탐지 환경을 제공하기 위해 개발된다.

1.2. 개발일정/산출물

본 설계서는 아래 그림2-1과 같이 개발일정에 따라 진행하며, 각 단계별로 산출물을 개발한다.



그림 1.2 개발일정 및 산출물

1.3. 개발조직/역할

역할	이름	역할(개발기능)
팀장	권민재	비동기 API 서버 구축, Redis + Celery 작업 큐 처리, DB 통계 로직 구현 / 시스템 UX/UI 설계 및 구현, 로그인 분기 처리, 결과 화면 및 대시보드 설계
팀원	김지혁	Docker 환경 구성, nginx 설정, CI/CD 파이프라인 구축, AWS 배포 / 시스템 UX/UI 설계 및 구현, 로그인 분기 처리, 결과 화면 및 대시보드 설계
팀원	백현종	딥페이크 데이터셋 전처리, 노이즈 기반 데이터 증강 적용, CNN + LSTM 기반 딥페이크 탐지 모델 개발 (XceptionNet 기반)
팀원	신채은	T2V 데이터셋 수집(FF++, GenVid 등) / VideoMAE 모델 기반 특징 추출 및 Real·Fake 분류 모델 개발 / XAI 모듈 개발 (Grad-CAM, Attention Map) / 설명 가능 모델 구조 확정 및 파인튜닝
팀원	조민수	T2V 데이터셋 정규화 실험 및 전처리 / VideoMAE 모델 로드 및 테스트 / TimeSformer·ViT 기반 T2V 탐지 모델 연구 및 성능 개선 / Attention Map 등 XAI 시각화 툴 검증 및 적용

2. 요구사항 정의

2.1. 서비스 구성 및 개요




그림 2.1 서비스 시나리오 구성도

1. 서비스 시나리오 구상도 개요

본 시스템은 사용자 요청의 효율적인 처리와 확장성을 고려하여 **API Gateway 기반의 마이크로서비스 지향 구조**로 설계되었습니다. 대용량 미디어 처리 부하를 최소화하기 위해 클라이언트 직업 업로드 방식을 채택하고, 별도의 AI 서버를 두어 연산 집약적인 작업을 분리한 것이 특징입니다.

2. 주요 구성 요소

- **frontend (Client)** : 웹/앱 인터페이스를 통해 사용자 요청을 수신하며 S3 직접 업로드 및 분석 결과 조회를 담당합니다.
- **Nginx (API Gateway)** : 모든 클라이언트 요청의 단일 진입점 역할을 수행하며, 부하 분산 및 백엔드 서비스로의 라우팅을 담당합니다.
- **Backend Services** :
 - **Auth-Service** : 사용자 인증 및 JWT 발급을 관리합니다.
 - **User-Service** : 사용자 프로필 및 계정 정보를 관리합니다.
 - **Feature-Service** : 핵심 비즈니스 로직(AI 분석 요청등) 을 처리합니다.

팀명 : 달팽이 질주	답러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---	---	---

- Data Persistence & Caching :

- MySQL : 사용자 정보 및 AI 분석 결과 등 정형 데이터를 저장합니다.
- Redis : 세션 관리 및 Refresh Token 저장을 통해 인증 성능을 최적화합니다.

- External & Academic Server :

- Amazon S3 : 대용량 영상 파일을 저장하는 객체 스토리지 입니다.
- AI Server (학과서버) : S3로부터 영상을 가져와 딥러닝 분석을 수행하는 특화 서버입니다.

2.2. 데이터분석의 요구사항

본 프로젝트에서는 AI 생성 영상 탐지 모델 학습을 위해 필요한 데이터의 내용과 특성을 정의하고, 모델의 일반화 성능을 확보할 수 있도록 데이터 구성 기준을 설정한다. 데이터는 크게 AI 생성 영상과 실제 영상으로 구분되며, AI 영상은 diffusion 기반 생성 영상, text-to-video 생성 영상, 그리고 deepfake 영상 등 다양한 유형을 포함한다. 실제 영상 데이터는 WebVid, MSR-VTT 등과 같은 일반 촬영 영상으로 구성하며, 인물, 자연, 실내, 실외 등 다양한 환경을 포함하도록 한다.

모델이 특정 환경이나 데이터셋에 과적합되지 않도록 하기 위해 데이터는 충분한 다양성을 가져야 한다. 이를 위해 서로 다른 배경, 객체, 조명 조건, 카메라 움직임은 포함한 영상을 수집하며, 영상 간 시간적 연속성을 유지하여 프레임 간 변화와 움직임 패턴을 학습할 수 있도록 한다. 또한 실제 환경을 반영하기 위해 압축, 노이즈, 해상도 변화 등 다양한 현실적 요소를 포함한 데이터를 활용한다.

데이터 라벨링은 기본적으로 AI 영상과 실제 영상을 구분하기 위한 이진 라벨(0: REAL, 1: AI)을 사용하며, 추가적으로 설명 가능 인공지능(XAI) 분석을 위해 이상 발생 구간과 이상 유형에 대한 라벨을 정의한다. 이상 유형은 Object inconsistency, Texture jitter, Movement anomaly, Lighting anomaly, Space anomaly로 구분하며, 이는 모델이 단순 탐지를 넘어 원인 분석까지 수행할 수 있도록 하기 위함이다.

데이터는 학습과 평가의 객관성을 확보하기 위해 Train과 Test로 분리하며, 특히 서로 다른 출처의 데이터셋을 사용하는 cross-dataset 방식으로 구성한다. 이를 통해 모델이 특정 데이터셋에만 최적화되는 것을 방지하고, 다양한 환경에서도 안정적으로 동작하는지를 검증한다.

모델 입력을 위해 모든 영상은 일정한 형태로 전처리된다. 프레임 수는 일정하게 고정하고, 해상도는 224×224로 정규화하며, 모델 입력에 맞게 정규화(mean, std)를 수행한다. 또한 영상의 대표성을 유지하면서도 학습 효율을 높이기 위해 랜덤 샘플링을 통해 프레임을 선택한다.

2.3. AI학습서버의 요구사항

번호	주요모듈	상세기능	개발 담당
(1)	AI 탐지 모듈	영상 입력 및 전처리 기능	신채은
(2)		VideoMAE 기반 영상 특징 추출 기능	신채은
(3)		AI / REAL 분류 기능	조민수
(4)		모델 추론 결과 확률 출력 기능	조민수
(5)	데이터 처리 모듈	영상 데이터 로딩 및 관리 기능	신채은
(6)		데이터 전처리 및 정규화 기능	조민수
(7)	XAI 모듈	Attention 기반 frame score 생성 기능	신채은
(8)		이상 발생 시간 구간 추출 기능	신채은
(9)		Attention score 기반 이상 프레임 판별 기능	신채은
(10)		중요 영역 heatmap 생성 기능	신채은
(11)		이상 유형 분류 기능	신채은
(12)		자연어 설명 생성 기능	신채은
(13)	평가 모듈	모델 성능 평가 (Accuracy, F1 등) 기능	신채은
(14)		ROC Curve 및 AUC 계산 기능	조민수
(15)	인터페이스 모듈	인터페이스 모듈	신채은
(16)		분석 결과 시각화 기능 (그래프, 히트맵)	신채은
(17)		설명 결과 출력 기능	조민수
(18)	로그 모듈	분석 결과 저장 기능	신채은
(19)		오류 및 처리 로그 기록 기능	조민수

번호	주요모듈	상세기능	개발 담당																																				
(1)	데이터 처리 모듈	대상 영상 로딩 및 일정 간격 프레임 샘플링 기능	백현종																																				
(2)		MTCNN 기반 안면 영역 검출 및 256x256 정규화 기능	백현종																																				
(3)	-	사전학습된 Xception 모델 기반 이미지 특징 추출 기능	백현종																																				
(4)		프레임 단위 Real / Fake 진위 확률 산출 기능	백현종																																				
(5)		프레임 확률 평균 집계(Mean Pooling) 기반 영상 최종 판별 기능	백현종																																				
(6)		Grad-CAM 기반 판단 근거 활성화 맵 (Heatmap) 추출 기능	백현종																																				
(7)	XAI 모듈	팀번호: XX 딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스 version v0.1 컴퓨터공학과 (졸업작품 프로젝트) 10.2. 소스디렉터리 구조 1) Backend (Spring Boot - API Server) <table><tr><td>디렉터리 / 파일명</td><td>역할 및 기능</td><td>주요 메소드(예시)</td></tr><tr><td>controller / VideoController.java</td><td>클라이언트의 요청을 받고 응답을 반환하는 메인 컨트롤러</td><td>uploadVideo(), getAnalysisResult()</td></tr><tr><td>service / AnalysisService.java</td><td>비즈니스 로직 처리 및 Celery 작업 큐에 분석 요청 전달</td><td>requestDeepfakeAnalysis(), saveQuizRecord()</td></tr><tr><td>repository / VideoRepository.java</td><td>Spring Data JPA를 이용한 RDBMS 데이터베이스 객체의 데이터 전송을 위한 객체</td><td>findById(), findById()</td></tr><tr><td>dto / VideoResponseDTO.java</td><td>데이터 전송을 위한 객체 (Data Transfer Object)</td><td></td></tr></table> 2) AI Worker (Python - Celery) <table><tr><td>디렉터리 / 파일명</td><td>역할 및 기능</td><td>주요 메소드(예시)</td></tr><tr><td>tasks / worker.py</td><td>Celery로부터 할당받은 분석 작업을 실행하는 메인 태스크</td><td>detect_fake_task(), extract_frames()</td></tr><tr><td>models / inference.py</td><td>실제 AI 모델(Deepfake/F2V) 로드 및 추론 실행</td><td>predict_score(), get_xai_reason()</td></tr><tr><td>utils / video_processor.py</td><td>비디오 파일 전처리 및 프레임 추출 유틸리티</td><td>resize_video(), save_frames()</td></tr></table> 3) Infrastructure (Docker) <table><tr><td>파일명</td><td>역할 및 기능</td><td>비고</td></tr><tr><td>Dockerfile</td><td>각 서비스(Backend, Worker)를 컨테이너화하기 위한 빌드 파일</td><td>이미지 최적화</td></tr><tr><td>docker-compose.yml</td><td>API, Worker, Redis 컨테이너를 통합 실행 및 네트워크 관리</td><td>개발/운영 환경 구성</td></tr></table> 최종 조작 의심 영역(안면 부위) 시각화 이미지 생성 기능 <td>백현종</td>	디렉터리 / 파일명	역할 및 기능	주요 메소드(예시)	controller / VideoController.java	클라이언트의 요청을 받고 응답을 반환하는 메인 컨트롤러	uploadVideo(), getAnalysisResult()	service / AnalysisService.java	비즈니스 로직 처리 및 Celery 작업 큐에 분석 요청 전달	requestDeepfakeAnalysis(), saveQuizRecord()	repository / VideoRepository.java	Spring Data JPA를 이용한 RDBMS 데이터베이스 객체의 데이터 전송을 위한 객체	findById(), findById()	dto / VideoResponseDTO.java	데이터 전송을 위한 객체 (Data Transfer Object)		디렉터리 / 파일명	역할 및 기능	주요 메소드(예시)	tasks / worker.py	Celery로부터 할당받은 분석 작업을 실행하는 메인 태스크	detect_fake_task(), extract_frames()	models / inference.py	실제 AI 모델(Deepfake/F2V) 로드 및 추론 실행	predict_score(), get_xai_reason()	utils / video_processor.py	비디오 파일 전처리 및 프레임 추출 유틸리티	resize_video(), save_frames()	파일명	역할 및 기능	비고	Dockerfile	각 서비스(Backend, Worker)를 컨테이너화하기 위한 빌드 파일	이미지 최적화	docker-compose.yml	API, Worker, Redis 컨테이너를 통합 실행 및 네트워크 관리	개발/운영 환경 구성	백현종
디렉터리 / 파일명	역할 및 기능	주요 메소드(예시)																																					
controller / VideoController.java	클라이언트의 요청을 받고 응답을 반환하는 메인 컨트롤러	uploadVideo(), getAnalysisResult()																																					
service / AnalysisService.java	비즈니스 로직 처리 및 Celery 작업 큐에 분석 요청 전달	requestDeepfakeAnalysis(), saveQuizRecord()																																					
repository / VideoRepository.java	Spring Data JPA를 이용한 RDBMS 데이터베이스 객체의 데이터 전송을 위한 객체	findById(), findById()																																					
dto / VideoResponseDTO.java	데이터 전송을 위한 객체 (Data Transfer Object)																																						
디렉터리 / 파일명	역할 및 기능	주요 메소드(예시)																																					
tasks / worker.py	Celery로부터 할당받은 분석 작업을 실행하는 메인 태스크	detect_fake_task(), extract_frames()																																					
models / inference.py	실제 AI 모델(Deepfake/F2V) 로드 및 추론 실행	predict_score(), get_xai_reason()																																					
utils / video_processor.py	비디오 파일 전처리 및 프레임 추출 유틸리티	resize_video(), save_frames()																																					
파일명	역할 및 기능	비고																																					
Dockerfile	각 서비스(Backend, Worker)를 컨테이너화하기 위한 빌드 파일	이미지 최적화																																					
docker-compose.yml	API, Worker, Redis 컨테이너를 통합 실행 및 네트워크 관리	개발/운영 환경 구성																																					
(8)	-	테스트 데이터셋 기반 모델 탐지 정확도 (Accuracy), F1-score, Precision, Recall 평가 기능	백현종																																				
(9)		임계값(Threshold) 변화에 따른 ROC Curve 및 AUC 계산 기능	백현종																																				
(10)		딥페이크 분석 결과(진위 여부, 확률, 히트맵 주소) 반환 및 로그 저장 기능	백현종																																				

2.4. AI서비스 유스케이스 모델




그림 2.2 사용자용 유스케이스 다이어그램




그림 2.3 관리자용 유스케이스 다이어그램





그림 2.x ai 서비스 유스케이스 다이어그램

본 시스템의 주요 액터는 사용자, 관리자로 구성된다. 사용자는 AI 생성 영상 탐지 서비스를 이용하는 주체로서, 영상을 업로드하고 진위 판별 결과 및 설명 결과를

제공받는다. 관리자는 데이터 수집, 학습 데이터 관리, 모델 학습, 학습 결과 확인 등 시스템 운영 및 학습 관련 기능을 수행한다.

유스케이스는 크게 데이터수집, AI학습서버, AI서버의 세 영역으로 구분된다. 데이터수집 영역에서는 학습용 영상 데이터의 수집과 저장 및 관리가 이루어진다. AI학습서버 영역에서는 수집된 데이터를 기반으로 전처리, 모델 학습, 모델 저장, 성능 확인이 수행된다. AI서버 영역에서는 학습된 모델을 불러와 사용자가 업로드한 영상에 대해 진위 판별을 수행하고, 최종 결과와 설명 가능 시각화 결과를 제공한다



본 시스템의 주요 액터는 관리자와 사용자로 구성된다. 사용자는 딥페이크 탐지 서비스를 이용하는 주체로서, 판별할 영상을 업로드하고 영상 단위 진위 탐지 결과 및 시각화 히트맵 결과를 제공받는다. 관리자는 시스템 운영 및 모델 개발의 주체로서, 학습 데이터셋 관리, 탐지 모델 학습, 그리고 성능 평가 및 최종 모델 저장을 수행한다. 유스케이스는 크게 'AI 학습 및 데이터 관리 영역'과 'AI 추론 영역'으로 구분된다. AI 학습 및 데이터 관리 영역에서는 얼굴 데이터 전처리, MTCNN/Xception 기반 모델 학습, 탐지 성능 평가 및 모델 저장이 이루어진다. AI 추론 영역에서는 사용자가 업로드한 대상 영상에 대해 실시간 판별 요청을 받아 처리하며, 예측된 진위 탐지 결과와 판단 근거가 되는 Grad-CAM 시각화 결과를 사용자에게 제공한다.


2.5. 요구기능 정의 (웹사용자용)

번호	주요기능명	상세기능명	개발담당
1)	사용자인증	서비스 가입신청	권민재
2)		로그인/로그아웃	권민재
3)		로그아웃	권민재
4)		아이디/비밀번호 찾기	권민재
5)		비밀번호 변경	권민재
6)	영상분석	영상 파일 업로드	권민재
7)		URL 기반 분석 요청	권민재
8)		분석 진행 상태	권민재
9)		분석 결과 조회	권민재
10)	퀴즈	다음 퀴즈 영상	권민재
11)		정답 제출	권민재
12)		내 정답률	권민재
13)	분석 기록	다음 퀴즈 영상	권민재
14)		특정 기록 삭제	권민재
15)		기록 삭제	권민재

3. 데이터 분석 및 전처리

3.1. 데이터 수집출처 및 수집방법

3.1.1. ai 생성 영상 탐지



본 프로젝트에서는 AI 생성 영상 탐지 모델을 학습하고 평가하기 위해 실제 촬영 영상과 AI 생성 영상을 함께 포함하는 영상 데이터셋을 사용한다. AI 생성 영상 탐지 과제는 단순 이미지 분류와 달리 영상의 공간적 특징뿐 아니라 프레임 간 시간적 일관성, 움직임의 자연스러움, 객체 형태의 유지 여부, 질감 변화 등을 함께 고려해야 한다. 따라서 본 프로젝트에서는 다양한 생성 모델과 실제 영상으로 구성된 GenVideo-100K 데이터셋을 기반으로 학습 데이터를 구성하고, 이를 학과서버 환경에서 manifest 기반으로 관리한다.

기존 설계 단계에서는 AI 생성 영상 탐지용 데이터셋을 GenVideo Dataset으로 정의하고, 실제 영상과 AI 생성 영상을 구분하는 이진 라벨 구조를 중심으로 데이터 수집 계획을 수립하였다. 최신 구현 단계에서는 이를 구체화하여, 학과서버에 구축된

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 [졸업작품 프로젝트]
-------------	---------------------------------	-----------------	-----------------------

GenVideo-100K 데이터를 실제 학습 및 평가 데이터로 사용한다. GenVideo-100K는 AI 생성 영상 탐지를 위한 대규모 영상 데이터셋의 일부를 프로젝트 환경에 맞게 구성한 것으로, 실제 영상과 여러 생성 모델 계열의 AI 생성 영상으로 이루어진다. 본 프로젝트에서는 이를 기반으로 real과 AI-generated를 구분하는 이진 분류 모델을 학습한다.

3.1.1.1 데이터 수집 출처

AI 생성 영상 탐지 파트의 주요 데이터 출처는 GenVideo-100K이다. GenVideo Video Generation Detection Dataset(2024) 논문에서 제공하는 데이터 셋이다. GenVideo는 AI 생성 영상 탐지 모델의 일반화 성능과 강건성을 평가하기 위해 구성된 데이터셋으로, 얼굴 중심의 딥페이크 데이터셋과 달리 다양한 장면, 객체, 배경, 움직임을 포함한다. 이러한 특성은 실제 서비스 환경에서 사용자가 업로드할 수 있는 다양한 스포츠 영상의 특성을 반영하는 데 적합하다.

GenVideo 데이터셋은 실제 영상과 AI 생성 영상으로 구성된다. 실제 영상은 일반 촬영 영상에서 수집된 데이터이며, AI 생성 영상은 다양한 text-to-video, image-to-video, diffusion 기반 생성 모델 등을 통해 생성된 영상으로 구성된다. GenVideo 논문에서는 생성 영상이 특정 얼굴 조작에 한정되지 않고 다양한 장면과 motion variation을 포함한다고 설명하며, 이는 본 프로젝트가 다루는 완전 생성 영상 탐지 문제와 잘 부합한다.

(url: <https://modelscope.cn/datasets/cccnju/GenVideo-100K>)

3.1.1.2 데이터 구성

학과서버에 구성된 GenVideo-100K 데이터는 실제 영상 디렉토리와 여러 AI 생성 영상 디렉토리로 구성된다. 실제 영상은 real 계열 디렉토리에 저장되며, AI 생성 영상은 생성 모델 또는 생성 계열별 디렉토리에 저장된다.

각 fake 계열 디렉토리는 대체로 특정 생성 모델 또는 생성 방식에 대응되며, 실제 영상은 real 디렉토리에 저장된다. 이러한 구성은 모델이 특정 생성 모델 하나에만 의존하지 않고, 여러 생성 방식에서 나타나는 공통적인 AI 생성 영상의 특징을 학습한다.

이진 라벨 구조를 사용하는 이유는 프로젝트의 1차 목표가 입력 영상이 실제 영상인지 AI 생성 영상인지 판별하는 것이기 때문이다. 향후 생성 모델 종류별 분류나 T2V/I2V/V2V와 같은 세부 유형 분류로 확장할 수 있으나, 현재 AI 생성 영상 탐지 파트에서는 real과 AI-generated를 구분하는 이진 분류 문제로 정의한다.

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

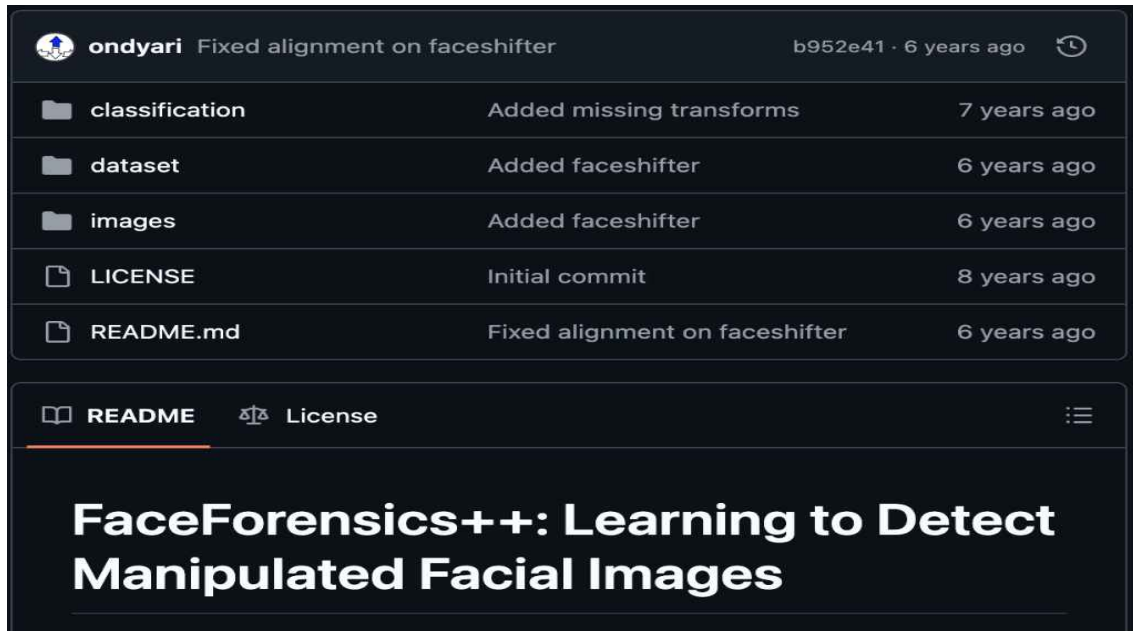
GenVideo-100K 데이터는 20만개의 영상으로 구성되어있으며, Real 10만개, AI-generated 10만개로 구성되어있다. AI-generated 영상은 10개의 영상 제작 ai 모델로 생성한 각각 1만개의 영상으로 구성되어있다.

3.1.1.3 데이터 포맷

학습 데이터셋의 원본 영상 형식은 주로 .mp4와 .gif가 혼합되어 있으며,해상도는 224×224 ~ 1024×576와 같이 다양한 크기로 있다.

Video Source	Type	Task	Time	Resolution	FPS	Length	Training Set	Testing Set	Total Count
Kinetics-400 [Kay et al., 2017b]	Real	-	17.05	224-340	-	5-10s	260,232	-	1,213,511
Youku-mPLUG [Xu et al., 2023b]		-	23.07	-	-	10-120s	953,279	-	
MSR-VTT [Xu et al., 2016b]	Real	-	16.05	-	-	10-30s	-	10,000	10,000
ZeroScope [zer, 2024]	Fake	T2V	23.07	1024×576	8	3s	133,169	-	1,048,575
I2VGen-XL [Wang et al., 2023c]		I2V	23.12	1280×720	8	2s	61,975	-	
SVD [Blattmann et al., 2023b]		I2V	23.12	1024×576	8	4s	149,026	-	
VideoCrafter [Chen et al., 2024]		T2V	24.01	1024×576	8	2s	39,485	-	
Pika [pik, 2022]		T2V&I2V	24.02	1088×640	24	3s	98,377	-	
DynamiCrafter [Xing et al., 2023]		I2V	24.03	1024×576	8	3s	46,205	-	
SD [Zhang et al., 2023b]		T2V&I2V	23-24	512-1024	8	2-6s	200,720	-	
SEINE [Chen et al., 2023c]		I2V	24.04	1024×576	8	2-4s	24,737	-	
Latte [Ma et al., 2024b]		T2V	24.03	512×512	8	2s	149,979	-	
OpenSora [Ope, 2024]		T2V	24.03	512×512	8	2s	177,410	-	
ModelScope [Wang et al., 2023d]	Fake	T2V	23.03	256×256	8	4s	-	700	8,588
MorphStudio [Mor, 2023]		T2V	23.08	1280×720	8	2s	-	700	
MoonValley [moonvalley.ai, 2022]		T2V	24.01	1024×576	16	3s	-	626	
HotShot [Hot, 2023]		T2V	23.10	672×384	8	1s	-	700	
Show_1 [Zhang et al., 2023c]		T2V	23.10	576×320	8	4s	-	700	
Gen2 [Esser et al., 2023]		I2V&T2V	23.09	896×512	24	4s	-	1,380	
Crafter [Chen et al., 2023b]		T2V	23.04	256×256	8	4s	-	1,400	
Lavie [Wang et al., 2023a]		T2V	23.09	1280×2048	8	2s	-	1,400	
Sora [Brooks et al., 2024]		T2V	24.02	-	-	-60s	-	56	
WildScape		T2V&I2V	24	512-1024	8-16	2-6s	-	926	
Total Count	-	-	-	-	-	-	2,294,594	19,588	2,314,182

3.1.2. 딥페이크 탐지



FaceForensics++ (Extended) Dataset

- 출처 링크: <https://github.com/ondyari/FaceForensics>
- 출처 논문: FaceForensics++: Learning to Detect Manipulated Facial Images
- 제공 형태: 파이썬 스크립트를 통한 데이터 다운로드 (MP4)

데이터 구성

- 총 약 10,000여 개 영상
- 실제 데이터: 유튜브 등에서 수집된 실제 인터뷰 영상 및 액터 촬영 원본 영상 등 (Original Sequences)
- 생성 데이터: 기존 4가지 얼굴 조작 기법(Deepfakes, Face2Face, FaceSwap, NeuralTextures)에 확장 조작 기법(DeepFakeDetection 등)이 추가 적용된 영상 (Manipulated Sequences)

데이터 포맷 (수집 원본 기준)

- 형식: MP4 영상 (H.264 코덱 기반)
- 해상도: 원본 영상별 상이 (주로 720p, 1080p 등의 HD/FHD 해상도)
- 길이: 영상별 상이 (수 초 ~ 수십 초 내외의 클립 형태)
- 압축 품질: Raw(무손실), c23(고화질 압축), c40(저화질 압축) 형태로 제공되며, 본 프로젝트에서는 현실적인 화질 저하 환경을 고려하여 c23 버전을 주로 활용함.

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

데이터 필드 구조

필드명	설명
video_path	영상 파일 경로
label	0: Real (Original), 1: Fake (Manipulated)
manipulation_type	Deepfakes / Face2Face / FaceSwap / NeuralTextures / DeepFakeDetection 등
compression	c23 (고화질 압축) / c40 (저화질 압축)
frame_id	영상에서 추출된 프레임 번호

3.2. 데이터 특징추출 및 특징분포

3.2.1 ai 생성 영상 탐지

AI 생성 영상은 개별 프레임만 보았을 때 실제 영상과 유사하게 보일 수 있으나, 영상 전체를 관찰하면 객체 형태, 질감, 조명, 배경 구조, 프레임 간 움직임 등에서 부자연스러운 특징이 나타날 수 있다. 따라서 본 프로젝트에서는 AI 생성 영상 탐지를 위한 데이터 특징을 크게 공간적 특징과 시간적 특징으로 구분하여 정리한다. 또한 데이터셋이 특정 클래스, 특정 생성 모델, 특정 파일 형식에 편향되지 않았는지를 확인하기 위해 주요 특징분포를 함께 분석한다.

3.2.1.1 공간적 특징

공간적 특징은 영상의 각 프레임 내부에서 관찰되는 시각적 특성을 말한다. 실제 촬영 영상은 카메라로 촬영된 장면이므로 객체의 형태, 배경 구조, 조명, 질감 등이 물리적 환경과 비교적 일관된 관계를 가진다. 반면 AI 생성 영상은 생성 모델의 특성에 따라 프레임 내부의 특정 영역에서 형태 왜곡, 질감 불안정, 조명 부자연스러움 등이 나타날 수 있다.

공간적 특징	설명
객체 형태	사람, 동물, 사물 등의 형태가 실제 구조와 다르게 생성되는 현상
객체 경계	전경과 배경의 경계가 흐릿하거나 비정상적으로 연결되는 현상
세부 구조	손가락, 얼굴, 눈, 입, 동물의 다리 등 세부 영역이 왜곡되는 현상
질감 패턴	피부, 머리카락, 옷, 배경 질감이 과도하게 매끄럽거나 반복되는 현상
조명 및 그림자	광원 방향, 그림자 위치, 밝기 변화가 장면 구조와 맞지 않는 현상
배경 구조	배경의 원근감, 물체 배치, 공간 구조가 부자연스럽게 표현되는 현상

이러한 공간적 특징은 AI 생성 영상에서 나타날 수 있는 대표적인 시각적 단서이다. 다만 본 프로젝트에서는 이러한 특징을 사람이 직접 규칙으로 판정하는 방식으로 사용하지 않는다. 공간적 특징은 데이터 분석과 결과 해석을 위한 기준이며, 실제 탐지 모델은 학습 데이터를 통해 이러한 차이를 통계적으로 학습하도록 설계한다.

3.2.1.2 시간적 특징

시간적 특징은 연속된 프레임 사이에서 나타나는 변화와 일관성을 의미한다. AI 생성 영상 탐지에서 시간적 특징은 매우 중요하다. 최근 생성 모델은 단일 프레임의 시각

적 품질을 높게 생성할 수 있으므로, 한 장의 프레임만으로는 실제 영상과 AI 생성 영상을 구분하기 어려운 경우가 많다. 그러나 여러 프레임을 연속적으로 관찰하면 객체의 형태가 유지되지 않거나, 질감이 흔들리거나, 움직임이 부자연스럽게 이어지는 문제가 나타날 수 있다.

본 프로젝트에서 고려하는 주요 시간적 특징은 다음과 같다.

시간적 특징	설명
움직임 연속성	객체나 카메라의 움직임이 프레임 간 자연스럽게 이어지는지 여부
객체 일관성	동일 객체의 형태, 크기, 위치가 시간에 따라 안정적으로 유지되는지 여부
질감 지속성	피부, 옷, 배경 등의 질감이 프레임마다 흔들리지 않고 유지되는지 여부
장면 안정성	배경 구조와 공간 관계가 연속 프레임에서 일관되게 유지되는지 여부
조명 변화	시간 흐름에 따른 조명과 그림자의 변화가 자연스러운지 여부
비정상적 움직임	프레임 간 움직임이 갑자기 튀거나 물리적으로 부자연스럽게 이어지는 현상

시간적 특징은 단일 이미지 기반 분석으로는 확인하기 어렵다. 따라서 AI 생성 영상 탐지 데이터는 단일 프레임이 아니라 영상 단위로 다루어야 하며, 모델 학습에서도 프레임 간 변화가 반영될 수 있도록 구성해야 한다. 이 내용은 이후 4장 AI학습모델의 설계에서 VideoMAE 기반 모델 구조와 연결된다.

3.2.1.3 실제 영상과 AI 생성 영상의 특징 차이

실제 영상과 AI 생성 영상은 다음과 같은 특징 차이를 보일 수 있다. 다만 이러한 차이는 모든 샘플에서 항상 동일하게 나타나는 것은 아니며, 생성 모델의 종류, 영상 길이, 해상도, 압축 상태, 장면 복잡도에 따라 달라질 수 있다. 따라서 아래 항목은 절대적인 판정 규칙이 아니라, 데이터 분석과 모델 해석을 위한 기준으로 사용한다.

구분	실제 영상	
객체 형태	시간에 따라 비교적 안정적으로 유지됨	일부 프레임에서 형태가 변형될 수 있음
세부 구조	손, 얼굴, 사물 경계 등이 실제 구조와 일치함	세부 구조가 비정상적으로 생성될 수 있음

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

질감	물체와 배경 질감이 비교적 일관됨	질감이 과도하게 매끄럽거나 프레임마다 흔들릴 수 있음
움직임	물리적 연속성과 관성이 반영됨	움직임이 갑자기 튀거나 부자연스럽게 이어질 수 있음
조명	광원과 그림자 변화가 장면 구조와 일치함	조명 변화나 그림자 방향이 불안정할 수 있음
배경	공간 구조와 원근감이 비교적 안정적임	배경 구조가 프레임마다 변형되거나 왜곡될 수 있음
프레임 간 일관성	객체와 장면의 시간적 연결성이 유지됨	특정 구간에서 temporal inconsistency가 나타날 수 있음

이러한 특징 차이는 AI 생성 영상 탐지 모델이 학습해야 할 주요 단서가 된다. 본 프로젝트에서는 이를 사람이 직접 판정하는 규칙으로 사용하지 않고, 데이터셋 구성과 모델 성능 해석을 위한 기준으로 활용한다.

3.2.1.4 특징분포 분석 기준

Video Source	Type	Task	Time	Resolution	FPS	Length	Training Set	Testing Set	Total Count
Kinetics-400 [Kay et al., 2017b]	Real	-	17.05	224-340	-	5-10s	260,232	-	1,213,511
Youku-mPLUG [Xu et al., 2023b]		-	23.07	-	-	10-120s	953,279	-	
MSR-VTT [Xu et al., 2016b]	Real	-	16.05	-	-	10-30s	-	10,000	10,000
ZeroScope [zer, 2024]	Fake	T2V	23.07	1024×576	8	3s	133,169	-	1,048,575
I2VGen-XL [Wang et al., 2023c]		I2V	23.12	1280×720	8	2s	61,975	-	
SVD [Blattmann et al., 2023b]		I2V	23.12	1024×576	8	4s	149,026	-	
VideoCrafter [Chen et al., 2024]		T2V	24.01	1024×576	8	2s	39,485	-	
Pika [pik, 2022]		T2V&I2V	24.02	1088×640	24	3s	98,377	-	
DynamiCrafter [Xing et al., 2023]		I2V	24.03	1024×576	8	3s	46,205	-	
SD [Zhang et al., 2023b]		T2V&I2V	23-24	512-1024	8	2-6s	200,720	-	
SEINE [Chen et al., 2023c]		I2V	24.04	1024×576	8	2-4s	24,737	-	
Latte [Ma et al., 2024b]		T2V	24.03	512×512	8	2s	149,979	-	
OpenSora [Ope, 2024]		T2V	24.03	512×512	8	2s	177,410	-	
ModelScope [Wang et al., 2023d]	Fake	T2V	23.03	256×256	8	4s	-	700	8,588
MorphStudio [Mor, 2023]		T2V	23.08	1280×720	8	2s	-	700	
MoonValley [moonvalley.ai, 2022]		T2V	24.01	1024×576	16	3s	-	626	
HotShot [Hot, 2023]		T2V	23.10	672×384	8	1s	-	700	
Show_1 [Zhang et al., 2023c]		T2V	23.10	576×320	8	4s	-	700	
Gen2 [Esser et al., 2023]		I2V&T2V	23.09	896×512	24	4s	-	1,380	
Crafter [Chen et al., 2023b]		T2V	23.04	256×256	8	4s	-	1,400	
Lavie [Wang et al., 2023a]		T2V	23.09	1280×2048	8	2s	-	1,400	
Sora [Brooks et al., 2024]		T2V	24.02	-	-	-60s	-	56	
WildScape		T2V&I2V	24	512-1024	8-16	2-6s	-	926	
Total Count	-	-	-	-	-	-	2,294,594	19,588	2,314,182

특징분포 분석은 수집된 데이터셋이 AI 생성 영상 탐지 모델 학습에 적합하게 구성되어 있는지 확인하기 위한 과정이다. 데이터셋이 특정 클래스, 특정 생성 모델, 특정 파일 형식에 치우쳐 있을 경우, 모델은 실제 AI 생성 영상의 일반적 특징이 아니라 데이터셋의 편향된 특성을 학습할 수 있다. 따라서 본 프로젝트에서는 학습 전에 데

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

이더 분포를 확인하고, 학습 후에는 모델의 예측 결과 분포를 함께 분석한다.

라벨 분포는 가장 기본적인 확인 항목이다. Real과 AI-generated 샘플 수가 크게 불균형하면 모델이 다수 클래스에 치우쳐 학습될 수 있다. 따라서 학습 데이터와 평가 데이터에서 두 클래스가 적절한 비율을 유지하는지 확인해야 한다. 사용한 데이터셋에서는 Real과 AI-generated의 샘플 수는 1:1로 동일하게 설정되었다.


데이터 분할 분포는 train, validation, test set이 적절하게 구성되었는지 확인하기 위한 항목이다. 특정 split에 특정 클래스나 특정 생성 모델이 과도하게 몰리면 모델 성능 평가가 왜곡될 수 있다. 특히 test set은 최종 성능 평가에 사용되므로, 학습 데이터와 중복되거나 지나치게 유사한 샘플이 포함되지 않도록 관리해야 한다. 때문에, 본프로젝트에서는 모델의 준수한 성능을 위해 데이터의 분포를 각각 8:1:1로 설정하고 사용하였다.

생성 모델 분포도 중요하다. AI 생성 영상이 특정 생성 모델의 결과물에만 집중되어 있으면, 모델이 AI 생성 영상의 일반적인 특징이 아니라 특정 generator의 고유한 흔적만 학습할 수 있다. 따라서 가능하면 여러 생성 모델의 영상이 학습 및 평가 데이터에 고르게 포함되는지 확인해야 한다. 해당 부분은, Genvideo, GenVidBench 논문에서도 cross-generator의 이름으로 확인할 수 있다. 생성 모델의 다양성은 탐지 모델 성능에 직접적인 영향을 미친다. 때문에, 본 프로젝트에서는 10개의 생성 모델로 구성된 FAKE 데이터로 구성되어있으며 1개의 테스트 용 생성 모델 데이터셋을 사용하였다.

파일 형식과 파일 상태 분포이다. 본 프로젝트에서 사용하는 데이터에는 MP4와 GIF가 혼합되어 있다. 때문에, 모델은 두 개 파일 형식에 대응가능하게 제작되었다.

영상 길이와 해상도 분포는 전처리 및 학습 안정성과 관련된다. 영상 길이가 지나치게 짧거나 긴 샘플이 많으면 프레임 샘플링 방식에 영향을 줄 수 있으며, 해상도 차이가 크면 리사이징 과정에서 정보 손실이 발생할 수 있다. 따라서 원본 영상의 길이와 해상도 분포를 확인하고, 필요한 경우 전처리 단계에서 이를 보정한다.

3.2.1.5 데이터 특징 및 분포




본 프로젝트에서는 AI 생성 영상 탐지를 위해 수집한 영상 데이터를 기반으로 학습에 필요한 특징을 추출하였다. 영상 데이터는 프레임 단위로 분해하여 처리하였으며, 각 프레임에서 공간적 특징과 시간적 특징을 함께 고려하였다. 먼저, 공간적 특징은 Vision Transformer 기반 모델 VideoMAE를 활용하여 추출하였으며, 이는 프레임 내 객체의 형태, 질감, 색상, 구조 등의 정보를 반영한다. 이러한 특징을 통해 AI 생성 영상에서 나타나는 비정상적인 텍스처나 시각적 패턴을 효과적으로 탐지할 수 있다.

또한, 시간적 특징은 연속된 프레임 간의 변화를 분석하여 추출하였다. 실제 영상의 경우 시간 흐름에 따라 자연스러운 움직임을 보이지만, AI 생성 영상에서는 프레임 간 불연속성이나 비정상적인 motion 패턴이 나타나는 경우가 많다. 따라서 프레임 간 차이 및 변화량을 분석하여 이러한 temporal inconsistency를 탐지하도록 설계하였다. 추출된 특징 데이터는 (Frame × Channel × Height × Width) 형태의 텐서로 구성되며, 각 영상에는 Real(0) 또는 AI Generated(1)의 라벨이 부여된다.

분석 결과, 실제 영상은 특징 값이 비교적 안정적이고 일정한 분포를 보이는 반면, AI 생성 영상은 분산이 크고 불규칙한 분포를 가지며 특정 구간에서 이상값이 나타나는 경향이 확인되었다.

3.2.2. 딥페이크 탐지



본 프로젝트에서는 딥페이크 조작 영상 탐지를 위해 영상 전체를 분석하는 대신, 위조가 주로 발생하는 핵심 영역인 '얼굴(Face)' 객체를 중심으로 국소적(Local) 특징을 추출한다. 영상 데이터는 프레임 단위로 분해되며, 다음과 같은 다단계 전처리 파이프라인을 거쳐 정제된다.

- **공간적 특징 추출 (MTCNN):** 프레임 내 안면 객체를 정확히 검출하기 위해 MTCNN 알고리즘을 활용한다. 딥페이크 위조 흔적은 주로 얼굴과 배경의 경계 (Blending Boundary)에 집중되므로, 검출된 Bounding Box를 1.3배(Crop Scale=1.3) 확장 및 크롭하여 미세한 조작 흔적과 비정상적인 시각 패턴을 보존한다.
- **대상 얼굴 일관성 유지 (IOU Tracking):** 인접 프레임 간의 IOU(Intersection over Union) 스코어를 계산(Threshold=0.2)하여, 프레임이 전환되더라도 다른 객체(배경의 작은 얼굴 등)로 타겟이 튜는 것을 방지하고 동일 인물의 얼굴만 연속적으로 추적한다.
- **노이즈 필터링 (Laplacian Variance):** 슛폼 영상 특성상 동적 움직임으로 인해 심하게 흔들린(Blurry) 프레임은 모델 학습의 노이즈로 작용한다. 이를 방지하기 위해 Laplacian Variance 알고리즘으로 블러 스코어를 산출하고, 기준치 미만의 프레임은 선제적으로 배제한다.
- **데이터 텐서화 및 라벨링:** 정제된 얼굴 이미지는 256×256 해상도로 정규화되며, 최종적으로 모델 입력에 맞춰 3×256×256 형태의 RGB 이미지 텐서로 구성된다. 각 텐서에는 진위 여부에 따라 Real(0) 또는 Fake(1)의 라벨이 부여된다.

기존 연구 및 관련 분석에 따르면, 실제 영상과 딥페이크 조작 영상은 얼굴 윤곽선 주변의 픽셀 분포, 경계부의 자연스러움, 노이즈 패턴, 프레임 간 일관성 측면에서 차이를 보일 수 있다. 본 프로젝트에서는 이러한 차이를 딥페이크 탐지를

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

위한 주요 단서로 활용한다.

구분 (Feature)	실제 영상 (Real)	딥페이크 조작 영상 (AI Generated)
얼굴-배경 경계선	픽셀 연결이 자연스럽게 부드러움	블렌딩(Blending) 오류로 인한 픽셀 부조화 발생
주파수 및 노이즈	프레임 전체에 일관된 노이즈 분포	합성 부위 주변의 불규칙한 고주파 노이즈(Jittering) 발생 가능
시간적 연속성	프레임 간 움직임 및 피부 톤 일관성 유지	프레임 전환 시 미세한 떨림(Temporal Inconsistency) 발생 가능

3.3. 데이터셋 정의 및 생성

3.3.1 ai 생성 영상 탐지

본 절에서는 AI 생성 영상 탐지 모델의 학습과 평가에 사용되는 데이터셋의 정의 방식과 생성 절차를 설명한다. 본 프로젝트에서 사용하는 원본 데이터는 실제 영상과 AI 생성 영상으로 구성되어 있으나, 원본 파일을 그대로 학습에 사용하는 것은 적절하지 않다. 영상 파일은 경로, 라벨, 데이터 분할 정보, 파일 상태 등이 함께 관리되어야 하며, 일부 손상 파일이나 0바이트 파일은 학습 대상에서 제외해야 한다. 따라서 본 프로젝트에서는 원본 영상 파일을 manifest 기반으로 정리하고, 학습 가능한 샘플만 선별하여 데이터셋을 생성한다.

본 프로젝트의 AI 생성 영상 탐지 데이터셋은 입력 영상이 실제 영상인지 AI 생성 영상인지를 판별하는 이진 분류 문제로 정의한다. 이에 따라 각 샘플은 영상 파일 경로와 정답 라벨을 가진다.

3.3.1.1 원본 데이터와 학습 데이터셋의 구분

본 프로젝트에서는 원본 데이터와 학습 데이터셋을 구분한다. 원본 데이터는 학과 서버에 저장된 GenVideo-100K 영상 파일 전체를 의미한다. 이 원본 데이터에는 실제 영상과 AI 생성 영상이 함께 포함되어 있으며, MP4와 GIF 형식이 혼합되어 있다. 또한 대용량 데이터셋 특성상 압축 해제나 다운로드 과정에서 일부 파일이 손상되었거나, 0바이트 파일이 포함될 수 있다.

반면 학습 데이터셋은 원본 데이터 중에서 실제 학습과 평가에 사용할 수 있도록 정리된 샘플 집합을 의미한다. 즉, 단순히 원본 폴더에 존재하는 모든 파일을 사용하는 것이 아니라, 라벨이 명확하고, 파일이 존재하며, 손상되지 않았고, 학습·검증·평가 split이 정의된 샘플만 학습 데이터셋에 포함한다. 이와 같이 원본 데이터와 학습 데이터셋을 구분함으로써, 데이터 오류가 학습 과정에 직접 영향을 주는 것을 줄이고, 실험에 사용된 샘플 구성을 재현 가능하게 관리할 수 있다.

3.3.1.2 Manifest 기반 데이터셋 정의

본 프로젝트에서는 데이터셋을 manifest 기반으로 정의한다. Manifest는 각 영상 샘플의 경로, 라벨, 데이터 분할 정보, 파일 상태 정보를 저장한 파일이다. 이를 통해 학습 코드는 원본 폴더 구조를 직접 탐색하는 방식이 아니라, manifest에 정의된 샘플 목록을 기준으로 데이터를 불러온다.

Manifest 기반 방식은 대용량 영상 데이터셋 관리에 적합하다. 원본 영상 파일의 수가 많고 디렉토리 구조가 복잡한 경우, 학습 시마다 폴더를 직접 탐색하면 데이터 구성이 변경되었을 때 실험 재현성이 떨어질 수 있다. 반면 manifest를 사용하면 특정 실험에서 어떤 샘플을 사용했는지 명확히 기록할 수 있고, train, validation, test 분할도 동일한 기준으로 유지할 수 있다.

필드명	설명
relative_path	데이터 루트 기준 영상 파일의 상대 경로
label	0: Real, 1: AI-generated
split	train, validation, test 구분
status	파일 상태 정보
is_zero_byte	0바이트 파일 여부

이러한 구조를 사용하면 원본 데이터 파일을 직접 이동하거나 복사하지 않고도, manifest 수정만으로 학습 샘플 구성과 데이터 분할을 관리할 수 있다.

3.3.1.3 Train / Validation / Test 데이터셋 구성

AI 생성 영상 탐지 모델을 학습하고 평가하기 위해 데이터셋은 train, validation, test로 분할한다.

Train set은 모델이 실제로 학습하는 데이터이다. Validation set은 학습 과정에서 모델이 과적합되고 있는지 확인하고, 서로 다른 실험 설정을 비교하는 데 사용한다. Test set은 최종 성능 평가에 사용되며, 모델 학습이나 파라미터 조정에는 사용하지 않는다.

데이터 분할 시에는 라벨 분포와 생성 모델 분포가 지나치게 치우치지 않도록 관리해야 한다. 예를 들어 train set에는 AI 생성 영상이 충분히 포함되어 있지만 test set에는 특정 생성 모델의 영상만 포함되어 있다면, 평가 결과가 실제 일반화 성능을 충분히 반영하지 못할 수 있다. 따라서 split 구성 시에는 라벨 균형, split별 샘플 수, 데이터 누수 여부 등을 확인한다.

3.3.1.4 모델 입력 데이터 생성

Manifest를 통해 선별된 각 샘플은 학습 과정에서 모델 입력 형태로 변환된다. 원본 영상은 길이, 해상도, 파일 형식이 서로 다르기 때문에 그대로 모델에 입력할 수 없다. 따라서 영상 파일에서 일정 개수의 프레임을 추출하고, 동일한 크기와 형식으로 변환하여 학습 입력을 생성한다.

본 프로젝트에서는 기본적으로 하나의 영상 clip을 16개의 RGB 프레임으로 구성한다. 각 프레임은 모델 입력 조건에 맞추어 224×224 크기로 변환된다. 최종적으로 하나의 샘플은 다음과 같은 형태의 입력 데이터와 라벨로 구성된다.

- input: 16-frame RGB clip
- label: 0 또는 1

이를 tensor 형태로 표현하면 다음과 같다.

- input_tensor: [16, 3, 224, 224]
- label: [1]

여러 샘플을 batch 단위로 묶으면 다음과 같은 형태가 된다.

- batch_input: [B, 16, 3, 224, 224]
- batch_label: [B]

3.3.1.5 캐시 데이터셋 생성

영상 파일은 학습 과정에서 반복적으로 로딩되고 디코딩된다. 특히 MP4나 GIF 파일을 매 epoch마다 직접 읽으면 CPU 병목이 발생할 수 있으며, 대용량 데이터셋에서는 학습 속도가 크게 저하될 수 있다. 이를 줄이기 위해 본 프로젝트에서는 필요 시 캐시 데이터셋을 생성하여 사용한다.

캐시 데이터셋은 원본 영상에서 미리 일정 개수의 프레임을 추출하고, 입력 크기에 맞게 변환한 결과를 별도의 파일로 저장한 것이다. 본 프로젝트에서는 기본적으로 16 프레임, 224×224 크기의 전처리 결과를 .pt 형식으로 저장하는 방식을 사용할 수 있다. 이후 학습 시에는 원본 영상 파일을 매번 디코딩하지 않고, 캐시된 tensor 파일을 불러와 학습에 사용하였다.

3.3.2. 딥페이크 탐지

본 프로젝트에서는 딥페이크 조작 영상 탐지를 위한 학습 데이터를 정의하고, 대용량 이미지 처리의 효율성과 학습의 안정성을 고려하여 다음과 같이 데이터셋을 구성하였다.

- **데이터 스토리지 최적화 (.tar Archiving):** 수십만 장의 안면 프레임 이미지를 개별 파일로 관리할 경우 발생할 수 있는 I/O 비효율을 줄이기 위해, 전처리된 이미지 시퀀스를 비디오 단위의 아카이브(.tar) 파일로 저장한다. 이를 통해 데이터 로딩 속도를 높이고 학습 효율을 개선한다.
- **데이터 누수(Data Leakage) 차단:** 동일 비디오에서 추출된 프레임이 학습 세트와 검증 세트에 동시에 포함되어 데이터 누수가 발생하는 것을 방지하기 위해, 프레임 단위가 아닌 비디오(.tar) 단위로 Train/Validation 세트를 8:2 비율로 분리 (Disjoint Split)하여 데이터셋을 정의한다.
- **데이터셋 반환 형태 (Dataset Definition):** 최종 데이터셋은 (image_tensor, label) 형태로 정의된다. image_tensor는 256x256 해상도의 3채널 RGB 텐서로 구성되며, label은 Real(0) 또는 Fake(1)의 이진 값을 가진다.
- **온라인 데이터 증강 (Augmentation):** 모델의 일반화 성능을 높이기 위해 학습 시점에 Random Horizontal Flip, 제한적인 Color Jitter 등의 증강 기법을 적용한다. 다만 딥페이크 탐지는 미세한 조작 흔적을 학습해야 하므로, 입력 특성을 과도하게 훼손하지 않는 범위에서 보수적으로 적용한다.

4. 학습모델의 설계

4.1. 모델 파이프라인의 구성

4.1.1. AI 생성 영상 탐지

본 프로젝트에서 설계하는 AI 생성 영상 탐지 모델은 입력 영상으로부터 시공간적 특징을 추출하고, 이를 기반으로 해당 영상이 실제 촬영된 영상인지, 혹은 인공지능에 의해 생성된 영상인지를 판별하는 구조로 구성된다. 본 연구의 최종 목적은 단순히 높은 분류 성능을 확보하는 데 그치지 않고, 모델이 어떤 시간 구간과 시각적 단서를 근거로 판단하였는지를 함께 제시하는 탐지 프레임워크를 구축하는 데 있다. 따라서 전체 파이프라인은 크게 영상 입력 및 데이터 로딩 단계, 전처리 및 프레임 샘플링 단계, 비디오 인코더 기반 특징 추출 단계, 이진 분류 단계, 설명 가능성 분석 단계, 추론 결과 출력 및 서비스 연동 단계로 구성된다.

본 프로젝트의 AI 생성 영상 탐지 파이프라인은 다음과 같은 흐름으로 정의된다.




그림 4.1 AI 생성 영상 탐지 모델의 전체 파이프라인

그림 4.1은 본 프로젝트에서 사용하는 AI 생성 영상 탐지 모델의 전체 파이프라인을 나타낸다. 사용자가 입력한 영상은 먼저 모델이 처리할 수 있는 고정 길이의 프레임 시퀀스로 변환되며, 이후 비디오 인코더를 통해 시공간 특징으로 표현된다. 추출된 특징은 분류 헤드로 전달되어 실제 영상과 AI 생성 영상 중 하나로 판별되며, 필요한 경우 attention 기반 XAI 모듈을 통해 의심 프레임, 의심 구간, 시각화 결과가 함께 생성된다.

4.1.1.1 영상 입력 및 데이터 로딩 단계

입력 단계에서는 분석 대상이 되는 원본 영상을 모델이 처리할 수 있는 형태로 불러온다. 영상 데이터는 이미지와 달리 시간축 정보를 포함하고 있으므로, 단일 프레임만으로는 충분한 판단이 어려운 경우가 많다. 특히 AI 생성 영상 탐지에서는 프레임 단위의 시각적 부자연스러움뿐 아니라, 프레임 간 움직임의 불연속성, 질감의 변화, 객체 형태의 비일관성, 조명 변화의 부자연스러움, 공간 구조의 불안정성 등이 중요한 단서로 작용할 수 있다. 따라서 본 프로젝트에서는 입력 영상을 일정 길이의 프레임 시퀀스로 변환하여 모델에 제공하는 방식을 채택한다.

현재 구현된 데이터 로딩 모듈은 일반적인 영상 파일뿐 아니라 실험 및 캐시 처리를 위한 텐서 파일도 처리할 수 있도록 설계되어 있다. 지원되는 입력 형식은 .mp4, .avi, .mov, .mkv, .gif, .npy, .pt이다. 이는 GenVideo-100K 데이터셋에 포함된 영상 파일 형식이 단일하지 않고, 일부 GIF와 MP4가 혼합되어 있는 상황을 고려한 것이다. 또한 학습 및 평가 데이터는 단순히 폴더 구조만으로 관리하는 것이 아니라, manifest 파일을 기준으로 관리된다. manifest에는 각 샘플의 경로, 라벨, 데이터 분할 정보, 파일 상태 정보가 포함되며, 손상 파일이나 0바이트 파일은 학습 대상에서 제외된다.

이러한 manifest 기반 데이터 관리는 대규모 영상 데이터셋을 안정적으로 사용하기 위해 필요하다. AI 생성 영상 데이터셋은 용량이 크고, 다운로드 또는 압축 해제 과정에서 일부 파일이 손상되거나 누락될 가능성이 있다. 따라서 모델 학습 단계에서 모든 파일을 무조건 사용하는 방식은 적절하지 않다. 본 프로젝트에서는 status, is_zero_byte와 같은 필드를 이용하여 사용 가능한 샘플만 선별하고, 누락되거나 손상된 샘플은 경고 로그를 남긴 뒤 제외하도록 구성하였다. 이를 통해 학습 중 데이터 로딩 오류로 전체 실험이 중단되는 문제를 줄이고, 재현 가능한 실험 환경을 확보할 수 있다.

4.1.1.2 전처리 및 프레임 샘플링 단계

전처리 단계에서는 입력 영상의 길이, 해상도, 프레임 수, 픽셀 분포를 모델 입력 조건에 맞추는 작업을 수행한다. 영상은 원본마다 길이와 FPS, 해상도가 다르기 때문에, 이를 그대로 모델에 입력하면 학습과 추론 과정에서 입력 차원이 불일치하게 된다. 따라서 본 프로젝트에서는 각 영상에서 일정 개수의 프레임을 샘플링하여 고정 길이의 클립으로 변환한다.

현재 기본 입력 프레임 수는 16프레임으로 설정하였다. 프레임 수를 16으로 고정하면 연산량을 일정 수준으로 제한하면서도 영상의 시간적 흐름을 일부 반영할 수 있다. 프레임 수가 많을수록 더 긴 시간 정보를 반영할 수 있지만, 비디오 모델의 특성상 GPU 메모리 사용량이 크게 증가한다. 따라서 본 프로젝트에서는 학과서버의 GPU 자원과 실험 효율성을 고려하여 16프레임 기반의 입력 구성을 우선 사용하였다.

프레임 샘플링은 영상 전체 구간에서 균등하게 인덱스를 선택하는 방식으로 수행된다. 영상 길이가 16프레임보다 긴 경우에는 전체 구간을 기준으로 일정 간격의 프레임 선택을 하고, 영상 길이가 짧은 경우에는 보간된 인덱스를 사용하여 고정된 개수의 프레임을 구성한다. 이러한 방식은 영상 길이가 서로 달라도 동일한 형태의 입력 텐서를 생성할 수 있게 한다.

또한 긴 영상에 대해서는 하나의 영상 전체를 하나의 클립으로만 처리하지 않고, 여러 구간으로 나누어 추론(이하 multi-clip inference)을 수행할 수 있도록 설계하였다. 예를 들어 영상 길이가 짧은 경우에는 1개의 대표 클립을 사용하고, 길이가 길어질수록 3개, 5개 또는 그 이상의 클립을 추출하여 각 클립별 예측 결과를 계산한다. 최종 영상 단위 판단에서는 각 클립의 예측 확률 중 가장 높은 confidence를 가진 클립을 대표 클립으로 선택한다. 이는 AI 생성 영상의 이상 징후가 영상 전체에 균일하게 나타나지 않고 특정 구간에 집중될 수 있다는 점을 고려한 설계이다.

샘플링된 프레임은 모델 입력 해상도에 맞추어 224×224 크기로 리사이징된다. 이후 각 프레임은 RGB 채널 기준으로 정규화되며, ImageNet-style normalization을 적용한다. 즉, 픽셀 값을 0~1 범위로 변환한 뒤 평균과 표준편차를 이용하여 정규화한다. 이러한 전처리는 사전학습된 비디오 인코더의 입력 분포와 맞추기 위해 필요하다.

전처리 단계의 핵심 목적은 모든 입력 영상을 동일한 텐서 형태로 변환하는 것이다. 최종적으로 하나의 영상 클립은 [T, C, H, W] 형태의 프레임 시퀀스로 변환되며, 배치 처리 시에는 [B, T, C, H, W] 형태로 모델에 입력된다. 여기서 B는 batch size, T는 샘플링된 프레임 수, C는 RGB 채널 수, H와 W는 입력 해상도를 의미한다.

4.1.1.3 VideoMAE-compatible encoder 기반 특징 추출 단계

전처리된 프레임 시퀀스는 비디오 인코더로 입력된다. 본 프로젝트에서는 VideoMAE-compatible encoder를 핵심 특징 추출기로 사용한다. VideoMAE는 Masked Autoencoder 구조를 비디오 영역에 확장한 모델로, 입력 비디오의 일부 패치를 마스킹한 뒤 복원하는 자기지도학습 방식을 통해 시공간 표현을 학습한다. 이러한 구조는 단일 이미지 모델과 달리 프레임 내 공간 정보와 프레임 간 시간 정보를 함께 처리할 수 있다는 장점이 있다.

AI 생성 영상 탐지 문제에서 중요한 것은 단순한 객체 인식이 아니라, 실제 영상과 생성 영상 사이에 존재하는 미세한 분포 차이와 시공간적 부자연스러움을 포착하는 것이다. AI 생성 영상은 개별 프레임만 보면 자연스러워 보일 수 있으나, 연속된 프레임에서 객체의 형태가 조금씩 변형되거나, 질감이 깜빡이거나, 움직임의 방향과 속도가 불안정하거나, 조명과 그림자의 변화가 실제 물리 환경과 맞지 않는 경우가 있다. 따라서 본 프로젝트에서는 정적 이미지 기반 모델보다는 시공간 정보를 통합적으로 처리할 수 있는 비디오 기반 인코더를 사용한다.

현재 구현된 모델은 HuggingFace VideoMAEModel을 사용할 수 있도록 구성되어 있으며, 사전학습된 VideoMAE 가중치가 정상적으로 제공되는 경우 이를 로드하여 encoder로 사용한다. 사전학습 모델을 사용하는 이유는 제한된 프로젝트 기간과 연산 자원 내에서 안정적인 표현 학습 능력을 확보하기 위해서이다. 처음부터 대규모 비디오 데이터를 이용해 인코더 전체를 학습하는 것은 데이터와 GPU 자원 측면에서 부담이 크다. 반면 사전학습된 비디오 인코더를 활용하면 일반적인 영상 패턴에 대한 표현을 이미 학습한 상태에서 AI 생성 영상 탐지 태스크에 맞게 파인튜닝할 수 있다. 컴퓨터 비전 분야에서는 사전학습된 모델이 좋은 성능을 보이는 것도 소소한 이유이다.

본 프로젝트에서는 다양한 모델의 성능 검증을 위해 사용한 레거시 모델을 fallback encoder로 함께 제공한다. fallback encoder는 VideoMAE를 대체하기 위한 경량 인코더로, 주로 CPU 환경에서의 스모크 테스트, 파이프라인 동작 검증, 외부 가중치 다운로드가 어려운 상황에서 사용된다. 단, 최종 성능 평가와 실제 탐지 모델은 VideoMAE-compatible encoder를 기준으로 한다.

encoder는 입력된 프레임 시퀀스를 고차원 feature representation으로 변환한다. VideoMAE 계열 인코더에서 모델은 각 비디오 패치 또는 토큰에 대한 sequence feature를 생성하며, 이 sequence feature는 이후 분류 헤드에서 사용된다. MLP head를 사용할 경우에는 sequence feature를 평균 풀링하여 하나의 feature vector로 요약하고, Transformer head를 사용할 경우에는 sequence feature를 유지한 채 추가적인 self-attention 기반 분류 과정을 수행한다.

4.1.1.4 이진 분류 단계

인코더를 통해 추출된 특징은 분류 헤드로 전달된다. 분류 헤드는 입력 영상이 실제 영상인지 AI 생성 영상인지에 대한 logit 값을 출력한다. 본 프로젝트는 AI 생성 영상 탐지 문제를 우선 이진 분류 문제로 정의한다. 즉, 각 입력 영상 또는 클립은 real 또는 ai_generated 중 하나의 클래스로 분류된다. 라벨은 0을 실제 영상, 1을 AI 생성 영상으로 정의한다.

현재 모델은 두 가지 분류 헤드를 선택할 수 있도록 구현되어 있다. 첫 번째는 MLP classifier head이다. MLP head는 인코더가 생성한 pooled feature vector를 입력으로 받아 선형층, 활성화 함수, dropout, 최종 출력층을 거쳐 하나의 logit을 산출한다. 이 구조는 비교적 단순하고 안정적이며, 인코더 자체의 표현력이 탐지 성능에 얼마나 기여하는지 확인하기에 적합하다.

두 번째는 Transformer classifier head이다. Transformer head는 인코더의 sequence feature를 그대로 활용하여 추가적인 self-attention 연산을 수행한다. 이때 학습 가능한 CLS token을 sequence 앞에 추가하고, positional encoding을 더

한 뒤 Transformer encoder layer를 통과시킨다. 최종적으로 CLS token에 해당하는 출력 feature를 사용하여 real 또는 AI-generated 여부를 예측한다. 이 방식은 단순히 전체 feature를 평균내는 것보다 토큰 간 관계를 한 번 더 학습할 수 있으며, 시간적·공간적 단서가 특정 token이나 구간에 집중되는 영상 탐지 문제에 적합할 수 있다.

분류 헤드의 출력은 하나의 binary logit이며, 추론 시에는 sigmoid 함수를 적용하여 0과 1 사이의 확률값으로 변환한다. 이 확률값은 AI 생성 영상일 가능성을 의미한다. 기본 threshold는 0.5로 설정되며, 확률값이 0.5 이상이면 ai_generated, 0.5 미만이면 real로 판정한다. 서비스 API 응답에서는 이를 FAKE 또는 REAL 형태로 변환하여 사용자에게 제공할 수 있다.

4.1.1.5 학습 파이프라인

학습 단계에서는 manifest를 통해 train split과 validation split을 구성하고, 각 샘플을 데이터 로더를 통해 미니배치 단위로 모델에 전달한다. 모델은 입력 클립에 대해 logit을 출력하고, 정답 라벨과의 차이를 기반으로 손실을 계산한다. 본 프로젝트에서는 이진 분류 문제에 적합한 BCEWithLogitsLoss를 사용한다. 이 손실 함수는 sigmoid 연산과 binary cross entropy를 함께 처리하므로, 수치적으로 안정적인 학습이 가능하다.

최적화 알고리즘으로는 AdamW를 사용한다. AdamW는 Transformer 계열 모델 학습에서 널리 사용되는 optimizer이며, weight decay를 분리하여 적용함으로써 일반화 성능을 안정적으로 확보할 수 있다. 학습은 epoch 단위로 수행되며, 각 epoch가 끝날 때 validation set에 대한 성능을 계산한다. 평가 지표로는 accuracy, F1-score, ROC-AUC를 사용한다.

학습 결과는 train_metrics.json 파일로 저장되며, 각 epoch별로 train loss, validation loss, accuracy, F1-score, ROC-AUC가 기록된다. 또한 학습된 모델 가중치는 checkpoint 파일로 저장되어 이후 단일 영상 추론, manifest 기반 대량 추론, API 서버 추론에서 재사용된다. 이러한 저장 구조는 실험 결과를 비교하고, 최종 모델을 선택하며, 이후 설계서와 발표 자료에서 정량적 근거를 제시하는 데 활용하였다.

본 프로젝트에서는 학습 전략으로 크게 head-only 학습, full fine-tuning, transformer head 학습을 비교할 수 있도록 구성하였다. head-only 학습은 사전 학습된 encoder를 고정하고 분류 헤드만 학습하는 방식이며, 상대적으로 학습이 안정적이고 GPU 자원 부담이 적다. full fine-tuning은 encoder와 classifier head를 함께 학습하는 방식으로, 데이터셋에 더 강하게 적응할 수 있으나 과적합 가능성과 연산 비용이 증가한다. Transformer head 학습은 기존 MLP head보다 sequence

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 [졸업작품 프로젝트]
-------------	---------------------------------	-----------------	-----------------------

feature를 더 적극적으로 활용하기 위한 확장 방식이다. 이러한 비교를 통해 본 프로젝트에 적합한 모델 구조와 학습 방식을 선택한다.

4.1.1.6 단일 영상 추론 및 multi-clip inference 단계

추론 단계에서는 학습된 checkpoint를 불러온 뒤, 새로운 입력 영상에 대해 AI 생성 여부를 판단한다. 입력 영상은 학습 단계와 동일하게 프레임 샘플링, resize, normalization 과정을 거쳐 모델 입력 텐서로 변환된다. 이후 모델은 각 클립에 대한 AI 생성 확률을 출력한다.

영상 길이가 짧은 경우에는 하나의 클립만 사용하여 예측을 수행하지만, 영상 길이가 긴 경우에는 여러 개의 클립을 추출하여 각각 예측을 수행한다. 이때 각 clip prediction은 개별 score와 함께 저장되며, 최종 영상 단위 판단에서는 가장 높은 score를 가진 clip을 representative clip으로 선택한다. 이는 AI 생성 영상의 이상 징후가 영상 전체에 고르게 분포하지 않고 특정 장면이나 시간 구간에 집중될 수 있다는 점을 고려한 방식이다.

예를 들어 20초 길이의 영상은 여러 구간으로 나뉘어 분석될 수 있으며, 각 구간에서 모델이 산출한 AI 생성 확률 중 가장 높은 값을 최종 score로 사용할 수 있다. 이 방식은 단일 샘플링으로 인해 중요한 이상 구간을 놓치는 문제를 줄이고, 서비스 환경에서 다양한 길이의 스포츠 영상을 처리하는 데 유리하다.

추론 결과는 prediction, confidence(score), inference metadata, clip_predictions를 포함한다. prediction은 real 또는 ai_generated로 표현되며, confidence는 대표 클립의 sigmoid score이다. inference metadata에는 영상 길이, FPS, 전체 프레임 수, clip 수, clip당 프레임 수, 대표 clip index 등이 포함된다. 이를 통해 단순히 최종 판정만 제공하는 것이 아니라, 어떤 방식으로 영상이 분석되었는지를 함께 기록할 수 있다.

4.1.1.7 설명 가능성 분석 단계 (xai)

본 프로젝트의 또 다른 핵심 구성 요소는 설명 가능성 분석 모듈이다. AI 생성 영상 탐지 모델은 결과값만 제시하는 경우 사용자에게 충분한 신뢰를 주기 어렵다. 특히 실제 서비스로 확장할 경우, &왜 이 영상이 AI 생성 영상으로 판단되었는가&에 대한 근거 제시는 매우 중요하다. 이를 위해 본 프로젝트에서는 VideoMAE-compatible encoder의 attention 정보를 활용하여 frame importance를 계산하고, 모델이 상대적으로 중요하게 본 프레임과 시간 구간을 추출한다.

현재 AI 생성 영상 탐지 파트에서 사용하는 XAI 방식은 attention 기반 분석이다. VideoMAE encoder에서 attention 정보를 가져올 수 있는 경우, attention rollout 방식을 이용하여 각 프레임 또는 temporal token의 중요도를 계산한다. 이 값은 0과

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

1 사이로 정규화되며, threshold 이상인 프레임들은 의심 구간으로 묶인다. 예를 들어 연속된 몇 개의 sampled frame에서 frame importance가 높게 나타나면, 해당 구간을 하나의 anomaly segment로 정의한다.

추출된 segment에 대해서는 간단한 통계적 휴리스틱을 적용하여 이상 유형을 분류한다. 현재 사용되는 이상 유형은 motion anomaly, texture anomaly, object inconsistency, lighting anomaly, spatial inconsistency 등이다. 이는 DAVID-X와 같은 defect-level annotation을 직접 학습한 결과라기보다는, attention map과 frame importance의 분포를 기반으로 의심 구간의 성격을 추정하는 방식이다. 따라서 해당 이상 유형은 모델 판단을 설명하기 위한 보조 정보로 사용되어야 하며, 정답 라벨과 같은 절대적 근거로 해석해서는 안 된다.

XAI 모듈은 frame importance뿐만 아니라 sampled frame metadata도 함께 제공한다. 즉, 모델 입력으로 사용된 sampled frame이 원본 영상의 몇 번째 프레임에 해당하는지, 해당 프레임의 timestamp가 몇 초인지 기록한다. 이를 통해 사용자나 개발자는 모델이 주목한 sampled frame이 실제 영상의 어느 시간 구간에 해당하는지 확인할 수 있다.

또한 attention map이 공간 정보를 포함하는 경우, 해당 map을 입력 프레임 크기로 upsampling하여 heatmap과 overlay 이미지를 생성한다. heatmap은 모델이 상대적으로 중요하게 본 영역을 시각적으로 표현하며, overlay는 원본 프레임 위에 heatmap을 겹쳐 표시한 이미지이다. 이러한 시각화 결과는 사용자가 모델의 판단 근거를 직관적으로 이해하는 데 도움을 줄 수 있다.

다만 attention 기반 XAI는 모델 내부의 주의 흐름을 시각화한 보조 자료일 뿐, 최종 분류 결과의 완전한 인과적 설명으로 단정할 수 없다. 즉, heatmap이 특정 영역을 강조한다고 해서 해당 영역 하나만으로 모델이 판단했다고 해석해서는 안 된다. 따라서 본 프로젝트에서는 XAI 결과를 &모델이 중요하게 본 후보 근거&로 제시하고, 모델 신뢰도와 XAI 신뢰도를 구분하여 다루는 방향으로 설계한다. 특히 attention map이 균일하거나 공간적 집중도가 낮은 경우에는 localized heatmap을 무리하게 생성하지 않고, heatmap reliability가 낮음을 명시한다.

(4.1.1.8 API 및 서비스 연동 단계)

학습과 추론 파이프라인은 최종적으로 AI 분석 API와 연결된다. 현재 AI 생성 영상 탐지 서버는 FastAPI 기반으로 구성되어 있으며, /t2v/analyze endpoint를 통해 외부 서비스와 연동될 수 있다. 먼저, 백엔드 서버 또는 클라이언트는 분석 대상 영상을 S3에 저장한다. 그다음 저장된 영상의 S3 URL을 AI 서버에 전달하면 AI 서버는 해당 영상을 임시 파일로 다운로드한 뒤 모델 추론을 수행한다.

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

분석 요청에는 s3_url 또는 video_url이 포함될 수 있으며, 선택적으로 return_xai, request_id가 전달될 수 있다. AI 서버는 입력 영상을 분석한 뒤 decision, t2v_prob, model_used, evidence, xai_visualization, forensic_report와 같은 정보를 반환한다. 여기서 decision은 사용자에게 제공되는 최종 판정이며, t2v_prob는 AI 생성 영상일 확률을 의미한다. evidence에는 frame importance, sampled frame 정보, 의심 구간, 설명 문장, clip별 예측 결과가 포함된다. xai_visualization에는 heatmap 및 overlay 경로와 시각화 품질 정보가 포함된다.

이러한 API 구조는 웹 서비스와 AI 서버를 분리하는 데 유리하다. 웹 서비스는 사용자 인증, 영상 업로드, 분석 기록 저장, 결과 화면 제공을 담당하고, AI 서버는 GPU 기반 영상 분석과 모델 추론을 담당한다. 이와 같이 역할을 분리하면 AI 모델의 연산 부하가 일반 백엔드 기능에 영향을 주는 것을 줄일 수 있으며, 향후 AI 모델이 교체되더라도 API 응답 구조를 유지함으로써 서비스 전체 구조를 안정적으로 관리할 수 있다.

4.1.1.9 모델 파이프라인의 설계 의의


본 프로젝트의 AI 생성 영상 탐지 파이프라인은 단순한 이미지 분류 구조가 아니라, 영상 데이터의 시간적 특성과 생성 영상의 시공간적 불안정성을 함께 고려하는 구조이다. 입력 영상은 고정 길이 프레임 시퀀스로 변환되고, VideoMAE-compatible encoder는 프레임 내부의 공간 정보와 프레임 간 시간 정보를 함께 반영한 feature를 생성한다. 이후 MLP 또는 Transformer classifier head를 통해 이진 분류를 수행하고, attention 기반 XAI 모듈을 통해 모델 판단의 보조 근거를 생성한다.

이 구조의 장점은 다음과 같다. 첫째, 영상 전체를 단일 이미지처럼 처리하지 않고 temporal sampling을 적용하기 때문에 움직임과 시간적 일관성을 일부 반영할 수 있다. 둘째, 사전학습된 VideoMAE encoder를 활용함으로써 제한된 프로젝트 자원 안에서도 비디오 표현 학습의 이점을 활용할 수 있다. 셋째, 단일 영상뿐 아니라 manifest 기반 대량 추론을 지원하므로 실험 평가와 서비스 추론에 모두 활용할 수 있다. 넷째, attention 기반 frame importance와 heatmap/overlay를 생성함으로써 탐지 결과의 설명 가능성을 보완할 수 있다.

따라서 본 프로젝트의 모델 파이프라인은 영상 입력 > 전처리 > 시공간 특징 추출 > 이진 분류 > 설명 가능 결과 생성 > API 응답으로 이어지는 end-to-end 구조로 설계된다. 이는 AI 생성 영상 탐지 모델을 단순 실험 코드로만 사용하는 것이 아니라, 실제 웹 기반 탐지 서비스와 연결 가능한 형태로 확장하기 위한 기반 구조라고 할 수 있다.

4.1.2. 딥페이크 탐지

딥페이크 탐지 모델 파이프라인 구조도 (Deepfake Detection Model Pipeline Architecture)



본 프로젝트에서 설계하는 AI 학습 모델은 입력 영상으로부터 얼굴 영역을 정밀하게 추출하고, 이를 기반으로 해당 영상의 위조 여부를 판별하는 구조로 구성된다. 본 연구의 목적은 압축이 적용된 실제 영상 환경에서도 비교적 안정적으로 동작할 수 있는 딥페이크 탐지 모델을 설계하는 데 있으며, 이를 위해 전체 파이프라인은 크게 영상 입력 및 전처리 단계, 얼굴 특징 추출 단계, 분류 단계, 설명 가능성(XAI) 분석 단계로 구성된다.

- **영상 입력 및 샘플링:** FaceForensics++ 데이터셋을 기반으로 실영상과 조작 영상을 수집하여 학습에 적합한 형태로 변환한다. 영상 데이터는 프레임 단위의 이미지 집합이므로, 연산 효율성을 높이기 위해 각 영상으로부터 일정 간격으로 프레임을 샘플링한다. 이는 영상 전체를 사용하는 방식보다 연산량을 줄일 수 있을 뿐 아니라, 조작 흔적이 집중된 얼굴 중심의 데이터를 효과적으로 확보할 수 있게 한다.
- **정밀 전처리 단계:** MTCNN을 활용하여 안면 객체를 검출하며, 조작 경계면의 아티팩트를 보존하기 위해 Bounding Box를 1.3배 확장 크롭한다. 이후 인접 프레임 간 IOU 기반 추적과 Laplacian Variance 기반 블러 필터링을 적용하여 품질이 낮은 프레임을 제거한 뒤, 256×256 해상도로 정규화한다. 이러한 공정은 모델이 배경 노이즈를 배제하고 위조 흔적 자체에 집중하도록 돕는다.
- **얼굴 특징 추출 단계:** 딥페이크 탐지의 대표적인 베이스라인 모델인 Xception 구조를 사용한다. Xception은 깊이별 분리 합성곱(Depthwise Separable

Convolution)을 통해 이미지 내의 미세한 질감 차이와 비정상적인 패턴을 효과적으로 인코딩한다. 이는 학부 수준의 프로젝트 범위 내에서 구현 가능성과 실험 효율성을 동시에 확보할 수 있는 현실적인 설계라고 할 수 있다.

- **분류 및 설명 가능성 분석:** 추출된 고차원 특징 벡터를 바탕으로 최종 분류기는 Real(0) 또는 Fake(1)에 대한 확률값을 출력한다. 아울러 모델의 신뢰성을 높이기 위해 **Grad-CAM** 기법을 도입한다. 이는 모델이 얼굴의 어느 부위를 근거로 조작 여부를 판단했는지 히트맵 형태로 시각화함으로써, “왜 조작으로 판단했는가”에 대한 객관적인 근거를 제시하고 탐지 프레임워크의 완성도를 제고한다.

4.2. AI학습알고리즘의 선정

4.2.1 ai 생성 영상 탐지

본 프로젝트의 AI 학습 알고리즘은 AI 생성 영상 탐지라는 과제의 특성을 반영하여 선정하였다. 일반적인 이미지 분류 문제에서는 단일 프레임 수준의 CNN 또는 ViT 기반 모델만으로도 일정 수준의 성능을 확보할 수 있으나, 영상 탐지 문제에서는 공간 정보뿐 아니라 시간 정보까지 함께 고려해야 한다. 특히 완전 생성 영상의 경우, 개별 프레임만 보면 실제 영상과 구분하기 어려울 정도로 자연스럽게 보일 수 있으나, 연속된 프레임 사이에서 객체의 형태가 미세하게 변하거나, 질감이 흔들리거나, 움직임이 물리적으로 부자연스럽게 이어지는 현상이 나타날 수 있다. 따라서 본 프로젝트에서는 단일 이미지 기반 접근보다 시공간 특성을 동시에 학습할 수 있는 비디오 기반 모델을 우선적으로 채택하였다.

AI 생성 영상 탐지 문제는 기본적으로 입력 영상이 실제 촬영 영상인지, 인공지능 생성 모델에 의해 만들어진 영상인지를 구분하는 이진 분류 문제로 정의한다. 본 프로젝트에서는 라벨 0을 실제 영상, 라벨 1을 AI 생성 영상으로 정의하며, 모델은 입력 영상에 대해 AI 생성 영상일 확률을 출력한다. 이와 같은 이진 분류 방식은 문제 정의가 명확하고, 초기 모델 학습 및 평가를 안정적으로 수행할 수 있다는 장점이 있다. 현재 AI 생성 영상 탐지 파트에서는 우선 real과 AI-generated를 구분하는 binary classification을 기본 태스크로 설정한다.

AI 생성 영상 탐지를 위한 알고리즘 후보는 크게 네 가지 방향으로 검토할 수 있다. 첫 번째는 CNN 또는 ViT 기반의 프레임 단위 분류 방식이다. 이 방식은 각 프레임을 이미지처럼 처리한 뒤 프레임별 예측 결과를 평균하거나 투표하여 영상 단위 결과를 산출한다. 구현이 단순하고 학습 속도가 빠르다는 장점이 있으나, 프레임 간 시간적 일관성이나 움직임의 부자연스러움을 직접적으로 학습하기 어렵다는 한계가 있다. AI 생성 영상에서는 객체가 한 프레임에서는 자연스럽게 보이더라도 다음 프레임에서 형태나 질감이 불안정하게 변화하는 경우가 많기 때문에, 단일 프레임 기반 모델만으로는 탐지 근거가 부족할 수 있다.

두 번째는 TimeSformer, VideoSwin, VideoMAE와 같은 video transformer 기반 모델이다. 이 계열 모델은 프레임 내 공간적 특징과 프레임 간 시간적 특징을 함께 처리할 수 있으며, 영상 전체의 시공간 패턴을 하나의 표현으로 통합할 수 있다. AI 생성 영상 탐지에서는 프레임 단위의 시각적 흔적뿐 아니라 움직임, 장면 전환, 질감 지속성, 객체 일관성 등 시간축 정보를 함께 고려해야 하므로, video transformer 계열 모델은 본 프로젝트의 목적에 적합하다.

세 번째는 diffusion reconstruction error 또는 생성 모델의 재구성 특성을 활용하는 방식이다. 일부 연구에서는 실제 영상과 AI 생성 영상이 diffusion model에 의해 재구성 될 때 서로 다른 오차 패턴을 보인다는 점을 이용하여 탐지를 수행한다. 이러한 접근은 생성 영상의 흔적을 직접적으로 분석할 수 있다는 장점이 있으나, 별도의 diffusion model 추론이 필요하고, 영상 단위로 적용할 경우 연산량이 크며, 학부 프로젝트 수준에서 안정적으로 서비스 파이프라인에 통합하기에는 부담이 있다. 따라서 본 프로젝트에서는 diffusion 기반 탐지를 핵심 알고리즘으로 채택하기보다는, 관련 연구로 참고하고 향후 확장 가능성이 있는 후보로 남긴다.

네 번째는 vision-language multimodal model을 활용하여 영상의 결함을 자연어로 설명하는 방식이다. 최근 연구에서는 단순히 real/fake를 분류하는 것을 넘어, AI 생성 영상에서 발생하는 object inconsistency, texture jitter, movement anomaly, lighting anomaly와 같은 결함을 시간·공간적으로 설명하려는 시도가 이루어지고 있다. 이러한 방식은 설명 가능성 측면에서 장점이 크지만, 결함 단위의 annotation이 포함된 별도 데이터셋과 대규모 multimodal model 학습 자원이 필요하다. 현재 프로젝트의 범위와 학과서버 자원을 고려하면, 이 방식을 직접 구현하는 것은 부담이 크다. 따라서 본 프로젝트에서는 vision-language model 방식은 향후 발전 방향으로 두고, 현재는 VideoMAE 기반 이진 분류 모델과 attention 기반 XAI를 결합하는 현실적인 구조를 채택한다.

이러한 후보 검토를 바탕으로 본 프로젝트에서는 VideoMAE-compatible encoder 기반 이진 분류 모델을 핵심 알고리즘으로 선정하였다. VideoMAE는 Masked Autoencoder 구조를 비디오 영역에 확장한 모델로, 입력 영상의 일부 시공간 패치를 마스킹한 뒤 이를 복원하는 자기지도학습 방식으로 사전학습된다. 이 방식은 대규모 비디오 데이터에서 라벨 없이도 의미 있는 시공간 표현을 학습할 수 있게 하며, 이후 다운스트림 태스크에서 높은 전이 성능을 기대할 수 있다. 본 프로젝트에서는 이러한 VideoMAE의 사전학습 표현을 활용하여 AI 생성 영상 탐지에 필요한 특징을 추출하고, 그 위에 이진 분류 헤드를 결합하는 방식으로 모델을 구성한다.




그림 4.2 VideoMAE 구조

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

VideoMAE를 주요 인코더로 선택한 이유는 다음과 같다.

첫째, VideoMAE는 영상의 공간적 정보와 시간적 정보를 동시에 반영할 수 있다. AI 생성 영상 탐지에서 중요한 단서는 단일 프레임의 객체 분류 결과가 아니라, 실제 영상과 생성 영상 사이에 존재하는 미세한 시공간적 차이이다. 예를 들어 AI 생성 영상에서는 손, 얼굴, 동물의 다리, 물체 경계와 같은 세부 영역에서 형태가 일관되지 않거나, 질감이 프레임마다 흔들리거나, 움직임이 실제 물리 법칙과 맞지 않게 이어질 수 있다. VideoMAE는 프레임 시퀀스를 입력으로 사용하므로 이러한 시간축상의 변화를 모델 표현에 반영할 수 있다.

둘째, VideoMAE는 사전학습 기반 모델이기 때문에 제한된 프로젝트 자원 내에서도 현실적인 성능 확보가 가능하다. 대규모 비디오 모델을 처음부터 학습하려면 방대한 데이터와 긴 학습 시간이 필요하지만, 본 프로젝트는 졸업 프로젝트 범위 내에서 학과서버 GPU 자원을 활용하여 실험을 수행해야 한다. 따라서 이미 일반적인 비디오 표현을 학습한 사전학습 모델을 불러온 뒤, AI 생성 영상 탐지 데이터셋에 맞게 분류 헤드 또는 일부 encoder를 파인튜닝하는 방식이 적절하다.

셋째, VideoMAE는 Transformer 계열 구조를 기반으로 하므로 attention 기반 해석 방법과 결합하기 용이하다. 본 프로젝트는 최종 판정 결과뿐 아니라 사용자가 납득할 수 있는 보조 근거를 제공하는 것을 목표로 한다. Transformer 기반 모델에서는 attention map 또는 attention rollout을 통해 모델이 상대적으로 중요하게 본 프레임과 영역을 추정할 수 있다. 물론 attention이 곧 최종 판단의 완전한 인과적 설명이라고 볼 수는 없지만, frame importance와 heatmap을 생성하여 모델 판단의 보조 근거를 제시하는데 활용할 수 있다.

넷째, VideoMAE-compatible 구조는 실험 확장성이 높다. 현재 구현에서는 HuggingFace VideoMAEModel을 불러와 사용할 수 있고, 사전학습 가중치를 사용할 수 없는 경우에는 경량 fallback encoder를 사용하여 파이프라인 동작을 검증할 수 있다. 또한 분류 헤드를 MLP 또는 Transformer head로 선택할 수 있어, 단순한 baseline 구조와 시간축 token 관계를 추가로 학습하는 구조를 비교할 수 있다. 이와 같은 설계는 모델 실험을 단계적으로 확장하는 데 적합하다.

본 프로젝트의 실제 모델 구조는 크게 encoder와 classifier head로 나뉜다. Encoder는 입력된 프레임 시퀀스를 시공간 feature로 변환하는 역할을 수행한다. 입력 영상은 전처리 과정을 통해 16개의 샘플링된 프레임으로 변환되며, 각 프레임은 224×224 해상

도로 정규화된다. 이렇게 구성된 입력 텐서는 VideoMAE-compatible encoder를 통과하면서 sequence feature 또는 pooled feature로 변환된다. 이후 classifier head는 encoder가 생성한 feature를 입력받아 real 또는 AI-generated 여부를 예측한다.

분류 헤드로는 MLP classifier head와 Transformer classifier head를 모두 사용할 수 있도록 설계하였다. MLP head는 인코더가 생성한 pooled feature vector를 입력받아 선형층, 활성화 함수, dropout, 최종 출력층을 거쳐 하나의 binary logit을 산출한다. 이 방식은 구조가 단순하고 학습 안정성이 높으며, encoder의 표현력이 실제 탐지 성능에 어느 정도 기여하는지 확인하기에 적합하다. 초기 baseline을 구성하거나 head-only 실험을 수행할 때 유용하다.

Transformer classifier head는 encoder의 sequence feature를 유지한 채 추가적인 self-attention 기반 분류를 수행하는 구조이다. 이 방식에서는 학습 가능한 CLS token을 sequence 앞에 추가하고, positional encoding을 더한 뒤 Transformer encoder layer를 통과시킨다. 이후 CLS token에 해당하는 출력 feature를 사용하여 최종 binary logit을 계산한다. Transformer head는 단순히 전체 token을 평균내는 방식보다 token 간 관계를 한 번 더 학습할 수 있으므로, 특정 프레임이나 특정 시공간 token에 나타나는 AI 생성 흔적을 더 정교하게 반영할 가능성이 있다.

본 프로젝트에서는 모델 학습 전략도 여러 단계로 나누어 검토하였다. 첫 번째 전략은 head-only 학습이다. 이는 사전학습된 VideoMAE encoder를 고정하고, 새로 추가한 classifier head만 학습하는 방식이다. 이 방식은 사전학습된 표현을 크게 훼손하지 않고, 적은 GPU 자원으로 빠르게 baseline 성능을 확인할 수 있다는 장점이 있다. 또한 데이터셋 규모가 제한적이거나 과적합이 우려되는 경우 비교적 안정적인 결과를 기대할 수 있다.

두 번째 전략은 full fine-tuning이다. 이는 VideoMAE encoder와 classifier head를 함께 학습하는 방식이다. Full fine-tuning은 AI 생성 영상 탐지 데이터셋에 모델 전체를 더 강하게 적응시킬 수 있다는 장점이 있지만, 학습 자원이 더 많이 필요하고 과적합 가능성도 증가한다. 특히 GenVideo-100K와 같은 특정 데이터셋에서 높은 성능을 얻더라도, 그 성능이 다른 생성 모델이나 외부 영상으로 일반화되는지는 별도로 검증해야 한다. 따라서 full fine-tuning은 head-only 실험과 비교하여 성능 향상 여부와 일반화 가능성을 함께 판단해야 한다.

세 번째 전략은 Transformer head 기반 학습이다. 이는 encoder가 생성한 sequence feature를 더 적극적으로 활용하기 위한 방식이다. 단순 MLP head는 pooled feature를

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 [졸업작품 프로젝트]
-------------	---------------------------------	-----------------	-----------------------

기반으로 빠르게 분류할 수 있으나, 프레임 간 관계나 token 간 상호작용을 추가로 학습하는 데는 한계가 있다. Transformer head는 이러한 한계를 보완하기 위해 classifier 단계에서도 self-attention을 적용한다. 본 프로젝트에서는 MLP head와 Transformer head를 비교하여, 시간축 정보를 분류 단계에서 더 활용하는 것이 실제 성능 향상으로 이어지는지 확인할 수 있도록 설계하였다.

학습 알고리즘의 최적화 과정에서는 이진 분류 문제에 적합한 손실 함수를 사용한다. 모델의 최종 출력은 하나의 logit이며, 학습 시에는 BCEWithLogitsLoss를 사용하여 정답 라벨과 예측 logit 사이의 차이를 최소화한다. BCEWithLogitsLoss는 sigmoid 연산과 binary cross entropy를 내부적으로 함께 처리하므로, 수치적으로 안정적인 학습이 가능하다. Optimizer로는 AdamW를 사용한다. AdamW는 Transformer 계열 모델에서 널리 사용되는 최적화 알고리즘으로, weight decay를 분리하여 적용함으로써 일반화 성능 확보에 유리하다.

성능 평가는 Accuracy, F1-score, ROC-AUC를 중심으로 수행한다. Accuracy는 전체 영상 중 올바르게 분류한 비율을 나타내며, F1-score는 precision과 recall의 균형을 반영한다. ROC-AUC는 threshold 변화에 따른 전반적인 분리 성능을 확인할 수 있는 지표이다. AI 생성 영상 탐지에서는 단순 accuracy만으로는 충분하지 않다. 예를 들어 데이터 분포가 불균형한 경우 accuracy가 높더라도 실제 AI 생성 영상을 놓치거나 실제 영상을 AI 생성 영상으로 오답하는 문제가 발생할 수 있다. 따라서 본 프로젝트에서는 F1-score와 ROC-AUC를 함께 사용하여 모델의 탐지 성능을 종합적으로 평가한다.

설명 가능성 측면에서는 attention 기반 XAI 방식을 채택하였다. 본 프로젝트는 단순히 “AI 생성 영상이다” 또는 “실제 영상이다”라는 결과만 제공하는 것을 목표로 하지 않는다. 실제 서비스 환경에서는 사용자가 모델의 판단을 신뢰할 수 있도록, 어떤 프레임과 어떤 영역이 판단에 영향을 주었는지에 대한 보조 근거를 제공해야 한다. 이를 위해 VideoMAE-compatible encoder에서 attention 정보를 추출할 수 있는 경우, attention rollout을 통해 frame importance를 계산한다.

Frame importance는 모델이 입력 clip 내에서 상대적으로 중요하게 본 프레임의 점수이다. 이 점수는 0과 1 사이로 정규화되며, threshold 이상인 프레임들은 의심 구간으로 묶인다. 이후 의심 구간에 대해 motion anomaly, texture anomaly, object inconsistency, lighting anomaly, spatial inconsistency와 같은 이상 유형을 휴리스틱하게 부여한다. 이러한 이상 유형은 사람이 직접 주석을 단 defect-level label을 학습한 결과가 아니라, attention map과 frame importance의 분포를 바탕으로 추정한 보조 설명이다. 따라서 설계상 XAI 결과는 모델 판단을 보조하는 해석 자료로 사용하며,

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

최종 판단의 절대적 원인으로 단정하지 않는다.

공간적 attention map이 제공되는 경우에는 이를 원본 프레임 크기로 upsampling하여 heatmap과 overlay 이미지를 생성한다. Heatmap은 모델이 상대적으로 중요하게 본 영역을 색상으로 표현한 이미지이며, overlay는 원본 프레임 위에 heatmap을 겹쳐 표시한 결과이다. 이러한 시각화 결과는 사용자가 모델이 어떤 구간과 영역을 근거로 AI 생성 가능성을 판단했는지 직관적으로 이해하는 데 도움을 준다. 다만 heatmap이 균일하거나 attention map의 공간적 신뢰도가 낮은 경우에는 localized evidence로 과도하게 해석하지 않도록 heatmap reliability와 warning 정보를 함께 제공한다.

보조적으로 검토 가능한 알고리즘으로는 SigLIP과 같은 이미지 기반 foundation model, diffusion reconstruction 기반 탐지 방식, vision-language model 기반 설명형 탐지 방식이 있다. SigLIP은 강력한 이미지 표현을 제공할 수 있지만 기본적으로 비디오 모델이 아니므로, 프레임 단위 특징을 추출한 뒤 별도의 temporal aggregation 구조를 설계해야 한다. Diffusion reconstruction 기반 탐지는 생성 영상의 재구성 오차를 직접 활용할 수 있다는 장점이 있으나, 영상 단위 처리 비용이 크고 현재 서비스형 파이프라인에 바로 통합하기에는 부담이 있다. Vision-language model 기반 방식은 자연어 설명과 결합 근거 제시에 강점이 있으나, 대규모 멀티모달 모델과 세밀한 결합 주석 데이터가 필요하다. 따라서 본 프로젝트의 현재 범위에서는 이들 방식을 핵심 알고리즘으로 채택하지 않고, 향후 성능 개선과 설명 가능성 고도화를 위한 확장 후보로 둔다.

결과적으로 본 프로젝트의 AI 생성 영상 탐지 알고리즘은 VideoMAE-compatible encoder + 선택형 classifier head + attention 기반 XAI 모듈을 중심으로 구성된다. 입력 영상은 일정 개수의 프레임으로 샘플링되고, VideoMAE-compatible encoder를 통해 시공간 feature로 변환된다. 이후 MLP 또는 Transformer classifier head가 binary logit을 산출하며, sigmoid 확률값을 기준으로 real 또는 AI-generated 여부를 판단한다. 필요 시 attention rollout 기반 frame importance, 의심 구간, heatmap/overlay, 자연어 설명을 함께 생성하여 탐지 결과의 해석 가능성을 보완한다.

이러한 알고리즘 선정은 구현 가능성, 성능 확보 가능성, 설명 가능성 확보라는 세 가지 기준을 동시에 고려한 결과이다. VideoMAE는 비디오 데이터의 시공간 특징을 학습하는데 적합하고, 사전학습 가중치를 활용할 수 있어 제한된 자원에서도 효율적인 실험이 가능하다. MLP와 Transformer head를 모두 지원하는 구조는 baseline과 확장 모델을 비교할 수 있게 하며, attention 기반 XAI는 서비스 사용자에게 판단 근거를 제공하는 데 활용될 수 있다. 따라서 본 프로젝트에서는 VideoMAE 기반 이진 분류 모델을 AI 생성 영상 탐지의 핵심 알고리즘으로 선정한다.

4.2.2 AI 학습 알고리즘의 선정(딥페이크 탐지)

4.2.2.1. 모델 선정을 위한 후보군 비교 및 분석

본 연구의 목적에 적합한 백본 네트워크(Backbone Network)를 선정하기 위해, 현재 딥페이크 탐지 분야에서 널리 활용되는 주요 CNN 아키텍처들을 비교 검토하였다.

주요 CNN 기반 알고리즘의 기술적 특성 비교

모델명 (Model)	주요 메커니즘	특징 및 장점	딥페이크 탐지 적합성
ResNet-50	Residual Connection	깊은 망 학습에 유리	범용성이 높으나 미세 질감 추출력 보통
EfficientNet-B0	Compound Scaling	파라미터 효율성 우수	연산은 빠르나 압축 노이즈에 다소 취약
Xception	Depthwise Separable Conv.	공간/채널 상관관계 분리	압축 환경(FF++)에서 우수한 강건성

비교 결과, **Xception**은 특징 표현력이 우수할 뿐만 아니라, 특히 FaceForensics++와 같이 영상 압축이 적용된 환경에서 타 모델 대비 우수한 강건성을 보이는 것으로 알려져 있다. 이는 화질 저하가 빈번한 실제 영상 환경에서도 본 탐지 프레임워크가 안정적인 성능을 유지하는 데 중요한 근거가 된다.

4.2.2.2. 핵심 알고리즘: Xception (Extreme Inception)

Xception은 표준 합성곱 대신 ****깊이별 분리 합성곱(Depthwise Separable Convolution)****을 채택하여 연산 효율성과 특징 추출 성능을 동시에 확보한 구조를 가진다.

구조적 특징: 공간적 상관관계와 채널 간 상관관계를 분리하여 학습하는 방식은 합성 모델이 얼굴을 생성할 때 남기는 미세한 질감 왜곡이나 색상 채널 간의 불일치를 포착하는 데 **효과적인 구조로 볼 수 있다.**

단계적 특징 추출: 초기 계층(Entry Flow)에서 기본적인 시각 특징을 학습하고, 중간 계층(Middle Flow)에서 안면 내부의 세부 질감 이상을 인코딩하며, 마지막 계층(Exit Flow)에서 이를 고차원 벡터로 요약한다. 이러한 단계적 메커니즘은 실제 얼굴과 조작 얼굴 사이의 미세한 차이를 구분하는 데 도움을 준다.

4.2.2.3. 이진 분류(Binary Classification) 및 판단 체계 설계

본 프로젝트는 입력된 안면 데이터를 실제(Real, 0)와 조작(Fake, 1)으로 구분하는 이진 분류 문제로 정의하여 수행한다.

분류 및 손실 함수: Xception 백본에서 추출된 특징 벡터는 최종 분류 헤드를 거쳐 확률값으로 변환된다. 이 과정에서 Sigmoid 함수를 적용하여 0과 1 사이의 확률값을 도출하며, 이진 분류 문제에 적합한 Binary Cross Entropy(BCE) 손실 함수를 사용하여 모델을 학습시킨다.

영상 단위 집계 전략: 단일 프레임 분석의 한계를 보완하기 위해, 한 영상에서 샘플링된 프레임들의 판별 확률을 평균하여 최종 진위 여부를 판별한다. 이러한 방식은 정 프레임의 일시적 오판 가능성을 줄이고 영상 전체에 대한 안정적인 탐지 결과를 얻는데 도움이 된다.

4.2.2.4. Grad-CAM 기반 설명 가능성(XAI) 분석

단순한 결과 제시에 그치지 않고 모델의 판단 근거를 시각화하기 위해 Grad-CAM 기법을 도입한다.

시각적 근거 제시: 모델이 얼굴의 어느 부위(안면 윤곽, 눈가, 입가 등)를 중점적으로 분석하여 조작으로 판단했는지 히트맵(Heatmap) 형태로 확인한다.

기대 효과: 이러한 설명 가능성 분석은 탐지 결과에 대한 객관적 근거를 제시함으로써, 탐지 프레임워크 전반의 신뢰성을 보완하는 데 중요한 역할을 할 수 있다.

4.3. AI학습 파라미터 설정

4.3.1 AI 생성 영상 탐지

본 프로젝트에서는 사전학습된 VideoMAE-compatible encoder를 기반으로 AI 생성 영상 탐지 모델을 구성하며, 이에 맞는 입력 설정, 모델 설정, 학습 설정, 추론 설정, XAI 설정을 구분하여 관리한다.

본 프로젝트의 AI 생성 영상 탐지 모델은 실제 영상과 AI 생성 영상을 구분하는 이진 분류 문제로 정의된다. 모델은 입력 영상 또는 클립에 대해 하나의 logit 값을 출력하고, 추론 단계에서는 sigmoid 함수를 적용하여 AI 생성 영상일 확률을 계산한다. 확률값이 기준 임계값 이상이면 ai_generated, 미만이면 real로 판정한다. 학습 단계에서는 이진 분류 문제에 적합한 BCEWithLogitsLoss를 사용하며, 최적화 알고리즘으로는 Transformer 계열 모델 학습에 적합한 AdamW를 사용한다.

파라미터	내용
입력 프레임 수	16
입력 해상도	224×224
옵티마이저	AdamW
초기 학습률	1e-4
가중치 감쇠	1e-2
배치 크기	smoke test: 2, 4, 8, 실제 학습: 8
손실 함수	BCEWithLogitsLoss
학습 epoch 수	smoke test: 3, 실제 학습: 10

표4.3 대표 파라미터

4.3.1.1 입력 데이터 파라미터

입력 데이터 파라미터는 원본 영상을 모델이 처리할 수 있는 고정된 형태의 텐서로 변환하기 위한 설정이다. 영상 데이터는 원본마다 길이, FPS, 해상도, 파일 형식이 다르기 때문에, 학습과 추론 과정에서 동일한 입력 구조를 유지하기 위해 프레임 수와 입력 해상도를 고정한다.

본 프로젝트의 기본 입력 프레임 수는 16프레임이다. 즉, 하나의 영상 또는 클립에서 16개의 프레임을 샘플링하여 모델에 입력한다. 프레임 수를 늘리면 더 긴 시간 정보를 반영할 수 있으나, 비디오 모델의 특성상 GPU 메모리 사용량과 연산량이 크게 증가한다. 따라서 현재 구현에서는 16프레임을 기본값으로 사용하고, 이후 자원 여건에 따라 32프레임 또는 더 긴 클립 입력을 실험 후보로 둘 수 있다.

프레임 샘플링 방식은 전체 영상 구간에서 균등하게 인덱스를 선택하는 temporal sampling 방식을 사용한다. 원본 영상의 프레임 수가 모델 입력 프레임 수보다 많으

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

면 전체 구간에서 일정 간격으로 프레임을 선택하고, 원본 영상의 프레임 수가 부족한 경우에는 보간된 인덱스를 사용하여 고정된 개수의 프레임을 구성한다. 이를 통해 길이가 서로 다른 영상도 동일한 입력 크기로 변환할 수 있다.

입력 해상도는 224×224로 설정한다. 이는 VideoMAE 및 여러 ViT 계열 모델에서 널리 사용되는 표준 입력 크기이며, 학습 속도와 표현력 사이의 균형을 고려한 값이다. 더 높은 해상도를 사용할 경우 미세한 질감 차이를 더 잘 보존할 수 있으나, 연산량과 메모리 사용량이 증가한다. 따라서 현재 단계에서는 224×224를 기본 입력 해상도로 사용하고, 고해상도 입력은 향후 성능 개선 실험의 후보로 둔다.

입력 정규화는 ImageNet-style normalization을 사용한다. 각 프레임의 픽셀 값을 0~1 범위로 변환한 뒤, RGB 채널별 평균과 표준편차를 적용하여 정규화한다. 이는 사전학습된 비전 모델이 기대하는 입력 분포와 맞추기 위한 설정이다.

현재 구현 범위에서는 과도한 데이터 증강보다 입력 데이터의 일관성과 재현성을 우선한다. AI 생성 영상 탐지는 일반 객체 인식 문제와 달리 미세한 시각적 흔적과 시간적 불일치를 탐지해야 하므로, 강한 색상 변형, 블러, 압축 왜곡, 과도한 crop과 같은 증강은 탐지 단서를 훼손할 수 있다. 따라서 학습 초기에는 고정된 리사이징과 정규화를 중심으로 전처리를 수행하고, 향후 일반화 성능 보강이 필요할 경우 제한적인 augmentation을 검토한다.

4.3.1.2 데이터셋 및 manifest 파라미터

본 프로젝트에서는 학습 데이터와 평가 데이터를 manifest 기반으로 관리한다. manifest는 각 샘플의 파일 경로, 라벨, split, 파일 상태 정보를 포함하며, 이를 통해 train, validation, test 데이터를 명확하게 분리한다. 라벨은 0: real, 1: AI-generated로 정의된다.

데이터셋 구성에서 중요한 파라미터는 split, status, is_zero_byte이다. split은 해당 샘플이 train, validation, test 중 어느 용도로 사용되는지를 나타낸다. status는 파일의 사용 가능 여부를 나타내며, 정상 샘플만 학습과 평가에 포함한다. is_zero_byte는 파일 크기가 0바이트인지 여부를 나타내며, 0바이트 파일은 학습 대상에서 제외한다.

이러한 manifest 필터링은 대용량 영상 데이터셋에서 매우 중요하다. GenVideo-100K와 같은 대규모 영상 데이터셋은 다운로드, 압축 해제, 변환 과정에서 일부 파일이 손상되거나 누락될 수 있다. 따라서 학습 시 모든 파일을 무조건 사용하는 것이 아니라, 정상적으로 로딩 가능한 샘플만 사용해야 한다. 본 프로젝트에서는 누락된 파일이나 손상된 샘플을 발견하면 경고 로그를 남기고 해당 샘플을 건너뛰도록 구성하여, 일부 파일 오류가 전체 학습을 중단시키지 않도록 설계하였다.

4.3.1.3 모델 호출 CLI 파라미터

모델 구조 파라미터는 VideoMAE-compatible encoder와 classifier head의 동작 방식을 결정한다. 본 프로젝트의 핵심 모델은 사전학습된 VideoMAE encoder를 기반으로 하며, 그 위에 이진 분류용 classifier head를 결합한다.

Encoder 설정에서 가장 중요한 파라미터는 `encoder_name`, `use_pretrained`, `freeze_encoder`이다. `encoder_name`은 사용할 VideoMAE 모델의 이름 또는 로컬 경로를 의미한다. 학과서버에서는 사전학습된 VideoMAE 가중치를 로컬 경로에 저장하고, CLI 실행 시 해당 경로를 인자로 전달하는 방식으로 사용한다. 현재 기본 encoder 경로는 서버 환경을 기준으로 `/home/t26106/ai-detection/project-g/models/videomae-base`로 설정되어 있다.

`use_pretrained`는 사전학습된 VideoMAE encoder를 사용할지 여부를 결정한다. `use_pretrained=True`인 경우 지정된 `encoder_name`에서 VideoMAE 모델을 로드한다. 이때 모델 로딩에 실패하면 fallback으로 조용히 넘어가지 않고 오류를 발생시킨다. 이는 실험자가 의도하지 않은 상태에서 경량 fallback encoder로 학습되는 문제를 방지하기 위한 설계이다. 반대로 `--no-pretrained` 옵션을 사용하는 경우에는 fallback encoder를 사용한다. 이 설정은 주로 CPU-only 환경에서의 스모크 테스트나 외부 모델 가중치를 사용할 수 없는 상황에서 파이프라인 동작 여부를 확인하기 위해 사용한다.

`freeze_encoder`는 encoder의 파라미터를 고정할지 여부를 결정한다. Encoder를 고정하면 사전학습된 표현을 유지한 상태에서 classifier head만 학습할 수 있다. 이는 head-only 학습 전략에 해당하며, GPU 자원 사용량을 줄이고 과적합 가능성을 낮출 수 있다. 반대로 encoder를 고정하지 않으면 VideoMAE encoder와 classifier head를 함께 학습하는 full fine-tuning이 가능하다. Full fine-tuning은 데이터셋에 더 강하게 적응할 수 있으나, 더 많은 연산 자원과 신중한 학습률 설정이 필요하다.

Classifier head 설정에서는 `head_type`이 핵심 파라미터이다. 현재 모델은 mlp와 transformer 두 가지 head를 지원한다. mlp head는 encoder의 pooled feature를 입력받아 선형층과 활성화 함수, dropout을 거쳐 최종 logit을 출력한다. 구조가 단순하고 빠르며, baseline 실험에 적합하다. transformer head는 encoder의 sequence feature를 입력받아 추가적인 self-attention 연산을 수행한 뒤 최종 logit을 출력한다. 이는 시공간 token 간 관계를 분류 단계에서 한 번 더 반영할 수 있다는 장점이 있다. 기본적으로는 transformer head를 사용한다.

Transformer head를 사용할 경우에는 `transformer_head_layers`, `transformer_head_heads`, `transformer_head_ff_dim`이 추가로 사용된다. 현재 기본값은 layer 수 2, attention head 수 8, feed-forward hidden dimension 2048

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

이다. 이 값들은 Transformer head의 표현력과 연산량을 결정한다. layer 수와 head 수가 증가하면 더 복잡한 token 관계를 학습할 수 있으나, 학습 속도와 메모리 사용량이 증가한다. 따라서 현재 프로젝트에서는 비교적 가벼운 2-layer Transformer head를 기본 구조로 사용한다.

4.3.1.4 학습 파라미터

학습 파라미터는 모델이 데이터셋에 적응하는 방식을 결정한다. 본 프로젝트에서는 학습 안정성과 실험 재현성을 고려하여 seed, batch size, epoch, optimizer, learning rate, weight decay, loss function을 명시적으로 관리한다.

Seed는 기본적으로 42를 사용한다. Seed를 고정하면 데이터 셔플링, 초기화, 일부 연산의 무작위성을 일정하게 유지할 수 있어 실험 결과를 비교하기 쉽다. 비디오 모델 학습은 데이터 샘플링과 GPU 연산에 따라 결과가 달라질 수 있으므로, 가능한 범위 내에서 seed를 고정하여 재현성을 확보한다.

Batch size는 GPU 메모리 상황에 따라 조정된다. 비디오 데이터는 이미지보다 입력 크기가 크기 때문에 일반 이미지 분류 모델보다 작은 batch size를 사용할 수밖에 없다. 코드 기본값은 2로 설정되어 있으며, 이는 로컬 또는 제한된 환경에서 스모크 테스트를 안정적으로 수행하기 위한 값이다. 학과서버에서 실제 학습을 수행할 때는 GPU 메모리 상황에 따라 batch size를 조정할 수 있다. 가장 최근의 학습에서는 데이터셋의 양과 처리시간을 고려하여 batch size 8로 수행하였다.

Epoch 수는 실험 목적에 따라 달라진다. 스모크 테스트에서는 1 epoch만으로 파이프라인 동작 여부를 확인할 수 있다. 실제 서버 실험에서는 30k subset 기준 3 epoch 학습, full transformer head 실험 기준 10 epoch 학습과 같이 실험 조건에 따라 epoch 수를 다르게 설정하였다.

Optimizer는 AdamW를 사용한다. AdamW는 Adam의 adaptive learning rate 특성과 decoupled weight decay를 결합한 방식으로, Transformer 계열 모델 학습에서 널리 사용된다. 현재 구현의 기본 learning rate는 $1e-4$, weight decay는 $1e-2$ 이다.

손실 함수는 BCEWithLogitsLoss를 사용한다. 이 손실 함수는 binary classification에 적합하며, 모델의 raw logit을 입력으로 받아 sigmoid와 binary cross entropy를 내부적으로 안정적으로 처리한다. 따라서 모델 마지막 층에서 sigmoid를 직접 적용하지 않고 logit을 출력하도록 구성한 뒤, 학습 시 BCEWithLogitsLoss를 적용한다. 추론 시에만 sigmoid를 적용하여 AI 생성 영상일 확률을 계산한다.

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

정규화 및 과적합 방지 파라미터로는 dropout과 weight decay가 사용된다. Classifier head에는 dropout이 적용되며, 기본 dropout 값은 0.1이다. Weight decay는 optimizer 단계에서 적용된다. 또한 학습 과정에서는 validation 성능을 epoch별로 기록하고, accuracy, F1-score, ROC-AUC를 함께 확인하여 과적합 여부를 판단한다. 향후 학습 자동화가 강화될 경우 validation metric 기준 best checkpoint 저장이나 early stopping을 추가로 적용할 수 있다.

4.3.1.5 평가 파라미터

평가 파라미터는 모델의 성능을 어떤 기준으로 판단할지 결정한다. 본 프로젝트에서는 accuracy, F1-score, ROC-AUC를 주요 평가 지표로 사용한다. Accuracy는 전체 평가 샘플 중 모델이 올바르게 분류한 비율을 나타내며, F1-score는 precision과 recall의 균형을 반영한다. ROC-AUC는 threshold 변화에 따른 전체적인 분류 능력을 나타낸다.

AI 생성 영상 탐지에서는 단순 accuracy만으로 모델 성능을 판단하기 어렵다. 예를 들어 특정 클래스가 더 많이 포함된 데이터셋에서는 한쪽 클래스로 치우친 예측만으로도 높은 accuracy가 나올 수 있다. 또한 실제 서비스에서는 AI 생성 영상을 놓치는 경우와 실제 영상을 AI 생성 영상으로 오탐하는 경우가 모두 문제가 될 수 있다. 따라서 본 프로젝트에서는 accuracy와 함께 F1-score를 사용하여 클래스 간 균형을 확인하고, ROC-AUC를 통해 threshold 하나에 종속되지 않는 분리 성능을 함께 평가한다.

학습 결과는 train_metrics.json 파일에 저장된다. 해당 파일은 epoch별 metric summary를 JSON 배열 형태로 기록하며, 각 항목에는 epoch, train_loss, val_loss, accuracy, f1_score, roc_auc가 포함된다. 이러한 출력 구조는 실험 결과를 비교하고, 발표 자료나 설계서에 성능 근거를 제시하는 데 활용된다.

4.3.1.6 추론 파라미터

추론 단계에서는 학습된 checkpoint를 불러와 새로운 영상에 대해 real 또는 AI-generated 여부를 판정한다. 추론 파라미터는 학습 파라미터와 일부 공유되며, 추가적으로 multi-clip inference와 threshold 설정이 포함된다.

기본 추론 입력 프레임 수는 학습과 동일하게 16프레임이다. 입력 해상도 역시 224×224를 사용한다. 이는 학습 시 모델이 본 입력 분포와 추론 시 입력 분포를 일치시키기 위한 설정이다. 만약 추론 시 다른 프레임 수나 해상도를 사용하면 모델의 예측 안정성이 떨어질 수 있으므로, 학습과 추론의 입력 설정은 기본적으로 동일하게 유지한다.

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

긴 영상에 대해서는 multi-clip inference를 적용한다. 현재 추론 파이프라인은 영상 길이에 따라 여러 개의 clip을 추출할 수 있으며, 기본 최대 clip 수는 8이다. 짧은 영상은 1개 clip으로 분석하고, 길이가 길어질수록 3개, 5개 또는 최대 8개 clip으로 나누어 분석한다. 각 clip에 대해 AI 생성 확률을 계산한 뒤, 가장 높은 confidence를 가진 clip을 representative clip으로 선택한다.

최종 영상 단위 판정은 representative clip의 confidence를 기준으로 수행한다. 현재 기본 threshold는 0.5이다. 즉, sigmoid 확률값이 0.5 이상이면 ai_generated, 0.5 미만이면 real로 판단한다. 이 방식은 AI 생성 흔적이 특정 구간에 집중되어 있는 경우를 고려한 것이다. 평균값을 사용할 경우 특정 의심 구간의 강한 신호가 전체 평균에 의해 희석될 수 있으므로, 본 프로젝트에서는 기본적으로 max clip confidence 전략을 사용한다.

추론 결과는 단일 영상 추론과 manifest 기반 대량 추론으로 나뉜다. 단일 영상 추론에서는 prediction, confidence, inference, clip_predictions가 출력된다. Manifest 기반 추론에서는 전체 샘플에 대한 prediction 배열과 failure 배열, 그리고 전체 metric summary가 함께 저장된다. 이러한 구조는 서비스 단일 요청과 실험용 대량 평가를 모두 지원하기 위한 설계이다.

4.3.1.7 XAI 파라미터

XAI 파라미터는 모델 판단의 보조 근거를 생성하기 위한 설정이다. 본 프로젝트에서는 attention 기반 frame importance와 heatmap/overlay를 생성하여 사용자가 모델의 판단 근거를 확인할 수 있도록 한다.

XAI 사용 여부는 with_xai 또는 return_xai 옵션으로 제어한다. XAI를 사용하지 않는 경우 모델은 prediction과 confidence만 출력한다. XAI를 사용하는 경우에는 대표 clip에 대해 frame importance, sampled frame metadata, anomaly segment, explanation, heatmap/overlay 정보를 추가로 생성한다.

기본 XAI threshold는 0.6이다. Frame importance 값이 이 threshold 이상인 sampled frame은 의심 프레임으로 간주되며, 연속된 의심 프레임은 하나의 segment로 묶인다. 이 segment는 영상 내에서 모델이 상대적으로 중요하게 본 시간 구간을 의미한다. Threshold가 너무 낮으면 많은 프레임이 의심 구간으로 선택되어 설명이 흐려질 수 있고, 너무 높으면 실제 중요한 구간을 놓칠 수 있다. 따라서 기본 값 0.6을 사용하되, 향후 validation set을 기준으로 조정할 수 있다.

XAI method는 encoder에 따라 달라진다. VideoMAE attention을 사용할 수 있는 경우에는 attention_rollup 방식으로 frame importance를 계산한다. Fallback encoder를 사용하는 경우에는 activation energy 기반 frame importance를 사용

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

할 수 있다. 만약 attention이 정상적으로 반환되지 않는 경우에는 XAI method를 unavailable로 표시한다. 이와 같이 XAI method를 명시하는 이유는 사용자가 어떤 방식으로 설명 결과가 생성되었는지 구분할 수 있도록 하기 위함이다.

4.3.1.8 최종 파라미터 설정 방향

최종적으로 본 프로젝트의 AI 생성 영상 탐지 모델은 16프레임 입력, 224×224 해상도, VideoMAE-compatible encoder, Transformer classifier head, BCEWithLogitsLoss, AdamW optimizer를 기본 설정으로 사용한다. 단, 모델 비교와 실험 재현성을 위해 MLP head, head-only 학습, full fine-tuning, fallback encoder 실험도 함께 유지한다.

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

4.3.2 AI 학습 파라미터 설정(딥페이크 탐지)

4.3.2.1. 입력 데이터 및 증강 설정

본 모델의 입력 데이터는 전처리 단계를 통해 추출된 256×256 해상도의 안면 이미지 프레임이다. 학습 과정에서 모델의 일반화 성능을 높이기 위해 위조 흔적을 훼손하지 않는 범위 내에서 제한적인 증강 전략을 수행한다.

입력 규격: 얼굴 내부의 미세한 질감 차이를 보존하면서도 연산 효율성을 확보할 수 있는 256×256 (RGB) 크기를 채택한다.

증강 기법: 딥페이크 탐지는 픽셀 단위의 미세한 신호가 중요하므로, 원본 이미지를 과도하게 변형하지 않는 기법 위주로 적용한다. 좌우 반전 불변성을 위한 **Random Horizontal Flip**과 조명 변화 대응을 위한 **Color Jitter**를 주로 활용하며, 조작 흔적 자체를 지울 수 있는 강한 블러(Blur) 처리는 배제하여 학습 데이터의 신뢰성을 유지한다.

4.3.2.2. 학습 최적화 및 파라미터 설계

사전학습된 Xception 모델의 특징을 크게 훼손하지 않으면서 딥페이크 탐지 태스크에 점진적으로 적응시키기 위해 다음과 같이 하이퍼파라미터를 설계한다.

Adam 옵티마이저 (Optimizer): 초기 학습의 안정성과 튜닝의 용이성이 뛰어나며, 다양한 환경에서도 보다 안정적으로 수렴하도록 돕는 특성이 있어 딥러닝 모델 학습에 널리 활용된다. 본 프로젝트에서는 Xception 모델의 효율적인 가중치 업데이트를 위해 Adam을 최적화 알고리즘으로 채택하였다.

학습률 (Learning Rate): 초기 학습률은 1e-4(0.0001) 수준으로 설정한다. 이는 기존 가중치의 급격한 변동을 방지하기 위함이며, 학습 진행 중 오차가 정체될 경우 학습률을 단계적으로 낮추는 방식을 적용하여 보다 안정적인 성능을 확보할 수 있도록 조정한다.

배치 크기 및 에폭 (Batch Size & Epoch): 하드웨어의 GPU 메모리 자원을 고려하여 배치 크기는 8 또는 16으로 설정한다. 총 학습 에폭은 30 내외로 하되, 검증 성능이 일정 기간 개선되지 않을 경우 학습을 조기 종료하여 불필요한 연산을 방지하고 과적합을 예방한다.

4.3.2.3. 손실 함수 및 성능 평가 지표

본 문제는 실제(Real)와 조작(Fake)을 구분하는 이진 분류 체계이므로, 확률 기반의 오차 측정을 위해 다음과 같은 기준을 적용한다.

손실 함수 (Loss Function): 실제 라벨과 모델의 예측 확률 사이의 차이를 계산하는 Binary Cross Entropy(BCE)를 사용한다. 이는 이진 분류 태스크에서 가장 표준적으로 활용되는 방식으로, 확률 분포의 오차를 최소화하는 데 효과적이다.

성능 평가 지표: 모델의 탐지 성능의 균형을 확인하기 위해 정확도(Accuracy) 외에도 정밀도(Precision), 재현율(Recall), F1-Score를 종합적으로 평가한다. 특히 실제 영상을 조작으로 오판하거나 조작 영상을 놓치는 사례를 균형 있게 분석함으로써 실제 탐지 환경에서의 안정성을 검증한다.

딥페이크 탐지 모델 학습 파라미터 요약

항목	설정 값	비고
입력 해상도	256 × 256 (RGB)	안면 영역 중심 데이터
백본 모델	Xception	사전학습 가중치 활용
옵티마이저	Adam	초기 학습 안정성 확보
초기 학습률	1e-4	학습 진행에 따른 조정 가능
배치 크기	8 또는 16	하드웨어 자원 최적화
손실 함수	Binary Cross Entropy	이진 분류 최적화
정규화 기법	드롭아웃(Dropout), 조기 종료	과적합 방지 및 일반화
최종 판별	프레임 확률값 평균 집계	영상 단위 최종 판별

4.4. AI학습 모델의 생성

4.4.1. ai 생성 영상 탐지

AI 학습 모델의 생성은 사전학습된 비디오 인코더를 기반으로 전체 탐지 모델을 구성한 뒤, AI 생성 영상 탐지 데이터셋에 맞추어 학습 및 검증을 수행하고, 최종적으로 서비스 추론에 사용할 수 있는 checkpoint를 저장하는 과정으로 이루어진다. 본 프로젝트에서는 처음부터 비디오 인코더 전체를 독자적으로 학습하는 방식보다는, 대규모 비디오 데이터에서 일반적인 시공간 표현을 학습한 VideoMAE-compatible encoder를 활용하여 효율적으로 탐지 모델을 구축하는 전략을 채택한다.

본 프로젝트의 모델 생성 과정은 단순히 네트워크 구조를 정의하는 것에 그치지 않는다. 데이터셋 manifest를 기준으로 학습 데이터를 로딩하고, 영상 전처리를 수행하며, VideoMAE-compatible encoder와 classifier head를 결합한 모델을 학습하고, 검증 성능을 기록한 뒤, 학습된 가중치를 checkpoint로 저장하는 전체 과정을 포함한다. 또한 생성된 모델은 단일 영상 추론, manifest 기반 대량 추론, FastAPI 기반 서비스 추론, XAI 결과 생성에 모두 활용될 수 있게끔 하였다.

본 프로젝트에서 AI 생성 영상 탐지 모델 생성 과정은 다음과 같은 단계로 구성된다.




그림 4.4.1 AI 생성 영상 탐지 모델 생성 과정

4.4.1.1 모델 설정 정의

첫 번째 단계는 모델 생성에 필요한 설정값을 정의하는 것이다. 본 프로젝트에서는 모델 구조와 학습 옵션을 명확하게 관리하기 위해 VideoClassifierConfig와 같은 설

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 [졸업작품 프로젝트]
-------------	---------------------------------	-----------------	-----------------------

정 구조를 사용한다. 이 설정에는 encoder 이름, hidden dimension, dropout, pretrained 사용 여부, encoder freeze 여부, classifier head 종류, Transformer head의 layer 수, attention head 수, feed-forward dimension 등이 포함된다.

모델 설정에서 가장 중요한 항목은 encoder_name, use_pretrained, freeze_encoder, head_type이다. encoder_name은 사용할 VideoMAE 모델의 이름 또는 로컬 경로를 의미한다. 학과서버 환경에서는 사전학습된 VideoMAE 가중치를 로컬 경로에 저장하고, CLI 인자 또는 환경변수를 통해 해당 경로를 전달한다. use_pretrained는 사전학습된 VideoMAE encoder를 사용할지 여부를 결정하며, freeze_encoder는 encoder를 고정하고 classifier head만 학습할지 여부를 결정한다. head_type은 mlp 또는 transformer 중 하나를 선택하여 최종 분류 구조를 결정한다.

이와 같이 설정값을 명확히 분리하는 이유는 실험 조건을 재현 가능하게 만들기 위해서이다. AI 생성 영상 탐지 모델은 head-only 학습, full fine-tuning, MLP head 실험, Transformer head 실험 등 여러 조건으로 비교될 수 있다. 따라서 각 실험에서 어떤 encoder, 어떤 head, 어떤 학습 범위를 사용했는지를 설정값으로 명확히 기록해야 한다.

최종 서비스에는 불필요한 요소이나, 향후 모델의 변경에 민감하게 대응 할 수 있도록 CLI 호출기반의 유연한 모델 설정 정의 시스템을 구축하였다.

4.4.1.2 VideoMAE-compatible encoder 초기화

두 번째 단계는 기반 encoder를 초기화하는 것이다. 본 프로젝트의 기본 encoder는 VideoMAE-compatible encoder이다. VideoMAE는 비디오 데이터를 입력으로 받아 프레임 내부의 공간적 특징과 프레임 간 시간적 특징을 함께 표현할 수 있는 구조를 가진다. 이는 AI 생성 영상 탐지에서 중요한 시공간적 부자연스러움을 포착하기 위한 핵심 구성 요소이다.

use_pretrained=True인 경우, 모델은 지정된 encoder_name을 기준으로 HuggingFace VideoMAEModel 또는 로컬에 저장된 VideoMAE 가중치를 로드한다. 이때 사전학습 모델 로딩에 실패하면 자동으로 fallback encoder를 사용하는 것이 아니라 오류를 발생시킨다. 이는 실험자가 의도하지 않은 상태에서 다른 encoder로 학습되는 문제를 방지하기 위한 설계이다. 즉, pretrained encoder를 사용하도록 지정했는데 실제로는 fallback encoder로 학습된다면, 실험 결과를 잘못 해석할 위험이 있으므로 명시적으로 오류를 발생시키는 방식이 더 안전하다.

반대로 --no-pretrained 옵션을 사용하거나 use_pretrained=False로 설정한 경우에는 경량 fallback encoder를 사용한다. Fallback encoder는 최종 성능 확보를 위

한 핵심 모델이라기보다는, CPU-only 환경이나 모델 가중치 다운로드가 어려운 환경에서 전체 파이프라인이 정상적으로 동작하는지 확인하기 위한 용도이다. 이를 통해 데이터 로딩, 전처리, 학습 루프, checkpoint 저장, 추론 출력 형식 등을 빠르게 검증할 수 있다.

Encoder가 초기화되면 입력 영상 클립은 고차원 feature representation으로 변환된다. VideoMAE encoder를 사용하는 경우, 모델은 sequence feature를 생성하며, 이 feature는 이후 classifier head에서 사용된다. MLP head를 사용할 경우에는 sequence feature를 평균 풀링하여 하나의 feature vector로 요약하고, Transformer head를 사용할 경우에는 sequence feature를 유지한 상태에서 추가적인 self-attention 기반 분류를 수행한다.

4.4.1.3 탐지용 classifier head 구성

세 번째 단계는 탐지용 classifier head를 구성하는 것이다. 사전학습된 VideoMAE encoder는 일반적인 비디오 표현을 학습한 모델이므로, AI 생성 영상 탐지라는 이진 분류 문제에 맞는 새로운 출력층이 필요하다. 본 프로젝트에서는 classifier head를 mlp와 transformer 두 가지 방식으로 선택할 수 있도록 설계하였다.

MLP classifier head는 encoder의 pooled feature를 입력받아 이진 분류 logit을 출력하는 구조이다. 이 구조는 선형층, GELU 활성화 함수, dropout, 최종 출력층으로 구성된다. MLP head는 구조가 단순하고 학습 속도가 빠르며, encoder의 표현력이 탐지 성능에 어느 정도 기여하는지 확인하는 baseline으로 적합하다. 또한 encoder를 freeze한 head-only 학습과 결합하면 적은 연산 자원으로 빠르게 성능을 확인할 수 있다.

Transformer classifier head는 encoder가 출력한 sequence feature를 유지한 채 추가적인 Transformer encoder layer를 적용하는 구조이다. 이 방식에서는 학습 가능한 CLS token을 sequence 앞에 추가하고, sinusoidal positional encoding을 더한 뒤 self-attention 기반 encoder layer를 통과시킨다. 이후 CLS token의 최종 feature를 이용하여 binary logit을 출력한다. Transformer head는 token 간 관계를 분류 단계에서 한 번 더 학습할 수 있기 때문에, AI 생성 영상의 흔적이 특정 프레임이나 특정 시공간 token에 집중되는 경우 더 유리할 수 있다.

현재는 Transformer head를 기본값으로 사용하도록 구성되어 있다.

4.4.1.4 학습 데이터셋 구성 및 DataLoader 생성

네 번째 단계는 학습 데이터셋과 DataLoader를 생성하는 것이다. 본 프로젝트에서는 영상 데이터를 manifest 기반으로 관리한다. Manifest에는 각 영상의 상대 경로, 라벨, split, 파일 상태, 0바이트 여부 등의 정보가 포함된다. 학습 시에는 train

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

manifest와 validation manifest를 각각 불러오거나, 하나의 shared manifest에서 split 값을 기준으로 train과 validation 샘플을 분리한다.

각 manifest row는 하나의 영상 샘플에 대응된다. 데이터 로딩 모듈은 각 샘플의 경로를 확인한 뒤, 실제 파일이 존재하고 정상 상태인지 검사한다. status가 비정상이거나 is_zero_byte가 1인 경우 해당 샘플은 학습에서 제외된다. 또한 경로가 존재하지 않는 경우에는 경고 로그를 출력하고 해당 샘플을 건너뛰다. 이를 통해 일부 손상 파일이나 누락 파일이 전체 학습을 중단시키지 않도록 한다.

DataLoader는 샘플을 미니배치 단위로 묶어 모델 학습에 전달한다. 각 샘플은 로딩 시점에 영상 파일에서 프레임을 읽고, 16프레임 temporal sampling을 수행하며, 224×224 resize와 normalization을 거쳐 모델 입력 텐서로 변환된다. 최종적으로 모델에는 [B, T, C, H, W] 형태의 tensor와 label tensor가 전달된다.

이러한 구조는 원본 영상을 그대로 학습하는 것이 아니라, 매 샘플마다 모델 입력에 적합한 고정 길이 클립을 생성하는 방식이다. 따라서 원본 영상의 길이와 해상도가 서로 달라도 동일한 모델 구조로 학습할 수 있다. 또한 manifest 기반으로 데이터셋을 관리하므로, 특정 split이나 특정 generator에 대한 실험을 구성하기 쉽고, 추후 새로운 데이터셋을 추가할 때도 manifest만 확장하면 동일한 학습 파이프라인을 사용할 수 있다.

4.4.1.5 모델 학습 과정

다섯 번째 단계는 모델 학습이다. 생성된 VideoMAE-compatible encoder와 classifier head는 학습 데이터에 대해 반복적으로 forward, loss 계산, backward, optimizer step을 수행한다. 본 프로젝트에서는 이진 분류 문제에 적합한 BCEWithLogitsLoss를 사용한다. 모델은 하나의 binary logit을 출력하고, 손실 함수는 이 logit과 정답 label 사이의 차이를 계산한다.

Optimizer로는 AdamW를 사용한다. AdamW는 Transformer 기반 모델 학습에서 널리 사용되는 최적화 알고리즘이며, weight decay를 분리하여 적용함으로써 일반화 성능 확보에 유리하다. 현재 기본 학습률은 $1e-4$ 이다.

학습 루프에서는 각 batch에 대해 다음 순서로 학습을 수행한다.

1. 입력 tensor와 label을 device로 이동
2. optimizer gradient 초기화
3. 모델 forward 수행
4. BCEWithLogitsLoss 계산
5. NaN loss 여부 확인

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

6. backward 수행
7. optimizer step 수행
8. running loss 기록

학습 중 일정 step마다 running loss를 출력하여 학습이 정상적으로 진행되는지 확인할 수 있다. 만약 loss가 NaN으로 계산되면 학습을 중단하고 오류를 발생시킨다. 이는 데이터 이상, 학습률 문제, 모델 출력 폭주 등을 조기에 발견하기 위한 안정성 장치이다.

본 프로젝트의 학습 방식은 실험 목적에 따라 head-only 학습과 full fine-tuning으로 나눌 수 있다. Head-only 학습에서는 encoder를 freeze하고 classifier head만 학습한다. 이 방식은 빠르고 안정적이며, 사전학습된 VideoMAE 표현이 AI 생성 영상 탐지에 얼마나 유용한지 확인하는 데 적합하다. Full fine-tuning에서는 encoder와 classifier head를 모두 학습한다. 이 방식은 데이터셋에 더 강하게 적응할 수 있지만, 연산 비용이 크고 과적합 가능성이 있으므로 validation 성능을 함께 확인해야 한다.

4.4.1.6 검증 및 성능 지표 계산

여섯 번째 단계는 validation set에 대한 평가이다. 각 epoch가 끝나면 모델을 evaluation mode로 전환하고, validation dataloader에 대해 예측을 수행한다. 이때 gradient 계산은 사용하지 않으며, 모든 validation sample의 logit과 label을 수집한 뒤 성능 지표를 계산한다.

본 프로젝트에서 사용하는 주요 성능 지표는 accuracy, F1-score, ROC-AUC이다. Accuracy는 전체 샘플 중 올바르게 분류한 비율을 의미하고, F1-score는 precision과 recall의 균형을 반영한다. ROC-AUC는 threshold 변화에 따른 전체적인 분리 성능을 나타낸다. AI 생성 영상 탐지에서는 단순 accuracy만으로 모델의 성능을 판단하기 어렵기 때문에, F1-score와 ROC-AUC를 함께 사용하여 모델의 균형성과 분리 능력을 평가한다.

검증 결과는 epoch별 summary로 구성된다. 각 summary에는 epoch 번호, train loss, validation loss, accuracy, F1-score, ROC-AUC가 포함된다. 이 정보는 학습 진행 상황을 확인하고, 여러 실험 조건을 비교하며, 최종 모델을 선택하는 근거로 사용된다.

4.4.1.7 모델 checkpoint 및 학습 결과 저장

일곱 번째 단계는 학습된 모델과 성능 결과를 저장하는 것이다. 학습이 완료되면 모델의 state dict를 model.pt 형식의 checkpoint 파일로 저장한다. 이 checkpoint는 이후 단일 영상 추론, manifest 기반 추론, API 서버 추론에서 로드되어 사용된다.

학습 성능 결과는 train_metrics.json 파일로 저장된다. 이 파일은 JSON 배열 형태이며, 각 epoch별 성능 summary를 포함한다. 예를 들어 다음과 같은 구조를 가진다.

```
[
  {
    "epoch": 1,
    "train_loss": 0.0,
    "val_loss": 0.0,
    "accuracy": 0.0,
    "f1_score": 0.0,
    "roc_auc": 0.0
  }
]
```

이러한 저장 방식은 모델 생성 결과를 재현하고 비교하는 데 중요하다. 단순히 최종 checkpoint만 저장하면 학습 과정에서 성능이 어떻게 변화했는지 확인하기 어렵다. 반면 epoch별 metrics를 함께 저장하면 head-only, full fine-tuning, MLP head, Transformer head 등 서로 다른 실험 조건을 비교할 수 있다. 또한 최종 epoch 모델이 항상 최선의 모델은 아닐 수 있으므로, validation 성능을 기준으로 best epoch를 판단하는 데에도 활용할 수 있다.

현재 프로젝트에서는 여러 실험 결과가 runs와 outputs 디렉토리에 저장된다. 학습 결과는 주로 runs 아래에 저장되고, 추론 결과는 outputs 아래에 저장된다. 이러한 디렉토리 구분은 학습 산출물과 추론 산출물을 명확히 분리하여 관리하기 위한 것이다.

4.4.1.8 단일 영상 추론 모델 생성

여덟 번째 단계는 저장된 checkpoint를 이용하여 단일 영상 추론 모델을 구성하는 것이다. 추론 단계에서는 학습 때와 동일한 모델 설정을 사용하여 VideoClassifier를 생성하고, 저장된 model.pt의 state dict를 로드한다. 이때 학습 당시 사용한 head type, encoder 경로, pretrained 여부, Transformer head 설정이 추론 시에도 동일해야 한다. 만약 학습 시 Transformer head를 사용했는데 추론 시 MLP head로 모델을 생성하면 checkpoint 구조가 맞지 않아 로딩 오류가 발생할 수 있다.

단일 영상 추론에서는 입력 영상 경로를 받아 영상을 로딩하고, 학습 단계와 동일하게 16프레임 샘플링, 224×224 resize, normalization을 수행한다. 이후 모델은 각 clip에 대해 AI 생성 확률을 계산한다. 영상 길이가 짧으면 하나의 clip만 사용하지만, 긴 영상의 경우 multi-clip inference를 적용하여 여러 구간을 분석한다.

각 clip의 예측 결과는 clip_predictions에 저장된다. 여기에는 clip index, confidence, prediction, 시작 프레임, 종료 프레임, 시작 timestamp, 종료 timestamp, sampled frame 목록이 포함된다. 최종 prediction은 가장 높은 confidence를 가진 representative clip을 기준으로 결정된다. 이 방식은 AI 생성 영상의 이상 징후가 특정 구간에만 강하게 나타나는 경우를 고려한 설계이다.

단일 영상 추론 결과는 다음 정보를 포함한다.

- prediction: real 또는 ai_generated
- confidence: 대표 clip의 AI 생성 확률
- inference: 영상 길이, FPS, 전체 프레임 수, clip 수, 대표 clip index
- clip_predictions: 각 clip별 예측 결과와 sampled frame 정보

이 출력 구조는 서비스 화면에서 최종 판정, 확신도, 의심 구간, 분석 메타데이터를 표시하는 데 활용될 수 있다.

4.4.1.9 Manifest 기반 대량 추론 모델 생성

아홉 번째 단계는 manifest 기반 대량 추론이다. 단일 영상 추론이 서비스 요청 단위의 분석을 위한 것이라면, manifest 기반 추론은 테스트 데이터셋 전체에 대해 모델 성능을 평가하기 위한 과정이다. 저장된 checkpoint를 로드한 뒤, test manifest에 포함된 모든 샘플에 대해 순차적으로 추론을 수행한다.

각 샘플에 대해 단일 영상 추론과 동일한 절차가 적용된다. 정상적으로 예측이 완료된 샘플은 predictions 배열에 저장되고, 로딩 실패나 추론 오류가 발생한 샘플은 failures 배열에 저장된다. 이 방식은 대규모 데이터셋 평가에서 일부 파일 오류와 모델 성능 평가를 분리하는 데 유리하다.

Manifest 기반 추론 결과는 다음 정보를 포함한다.

manifest 경로
split 정보
checkpoint 경로
전체 sample 수
정상 prediction 수
failure 수
accuracy, F1-score, ROC-AUC
개별 prediction 목록
failure 목록

표4.4.1 Manifest 결과

이 결과는 설계서의 성능시험지표와 직접 연결된다. 예를 들어 GenVideo test split

에 대해 manifest inference를 수행하면, 전체 테스트 샘플 수와 정상 처리 수, 실패 수, accuracy, F1-score, ROC-AUC를 함께 확인할 수 있다. 따라서 manifest inference는 최종 모델의 정량 평가를 위한 핵심 절차이다.

4.4.1.10 XAI 결과 생성

열 번째 단계는 설명 가능성 결과 생성이다. 본 프로젝트의 모델 생성 과정은 단순한 이진 분류 모델 생성에서 끝나지 않고, 모델이 어떤 프레임과 영역을 중요하게 보았는지에 대한 보조 근거를 함께 생성할 수 있도록 설계된다. 이를 위해 추론 시 with_xai 옵션을 활성화하면, 모델은 prediction과 confidence뿐 아니라 XAI payload를 함께 출력한다.

XAI 결과 생성은 representative clip을 기준으로 수행된다. 먼저 VideoMAE encoder에서 attention 정보를 사용할 수 있는 경우, attention rollout 방식으로 frame importance를 계산한다. Frame importance는 clip 내 sampled frame 각각에 대한 중요도 점수이며, 0과 1 사이의 값으로 정규화된다. 이후 설정된 threshold 이상인 프레임들을 의심 프레임으로 간주하고, 연속된 의심 프레임을 하나의 segment로 묶는다.

각 segment에 대해서는 attention map과 frame importance의 분포를 기반으로 이상 유형을 추정한다. 현재 사용되는 이상 유형은 motion anomaly, texture anomaly, object inconsistency, lighting anomaly, spatial inconsistency 등이다. 이는 사람이 직접 주석을 단 defect-level label을 학습한 결과가 아니라, 모델의 attention 기반 출력을 해석하기 위한 휴리스틱 결과이다. 따라서 해당 이상 유형은 최종 판단의 절대적 원인이라기보다는 모델이 주목한 의심 구간의 성격을 설명하기 위한 보조 정보로 사용된다.

XAI 결과에는 sampled frame metadata도 포함된다. 즉, 각 sampled frame이 원본 영상의 몇 번째 프레임인지, 해당 timestamp가 몇 초인지 함께 기록된다. 이를 통해 사용자는 모델이 주목한 sampled frame이 실제 영상의 어느 시간 구간에 해당하는지 확인할 수 있다.

공간적 attention map이 제공되는 경우에는 heatmap과 overlay 이미지도 생성된다. Heatmap은 모델이 상대적으로 중요하게 본 영역을 시각적으로 표현한 이미지이고, overlay는 원본 프레임 위에 heatmap을 겹쳐 표시한 이미지이다. 생성된 시각화 파일은 output directory 아래에 저장되며, API 서버에서는 /xai 경로를 통해 정적 파일로 제공할 수 있다.

XAI payload는 다음 정보를 포함한다.

method (attention_rollup)
threshold
clip_index
frame_importance
sampled_frames
segments
explanations
visualizations
attention_map_available
attention_map_shape
summary

표4.4.2 XAI payload

다만 XAI 결과는 모델 판단의 보조 근거로 해석해야 한다. Attention map은 모델 내부의 주의 흐름을 시각화한 것이며, 최종 분류 결과의 완전한 인과적 설명은 아니다. 따라서 본 프로젝트에서는 heatmap reliability, uniform heatmap warning, localized heatmap availability와 같은 정보를 함께 제공하여, XAI 결과의 신뢰도를 구분할 수 있도록 한다.

4.4.1.11 API 서비스 연동 모델 생성

열한 번째 단계는 학습된 모델을 API 서버에서 사용할 수 있도록 구성하는 것이다. 현재 AI 생성 영상 탐지 모델은 FastAPI 기반 서버와 연동될 수 있다. API 서버는 환경변수에서 checkpoint 경로와 encoder 설정을 읽고, 최초 요청 시 모델을 lazy loading 방식으로 초기화한다.

API 서버에서 중요한 설정은 T2V_CHECKPOINT_PATH이다. 이는 서비스 추론에 사용할 모델 checkpoint 경로를 의미한다. 추가적으로 T2V_ENCODER_NAME, T2V_USE_PRETRAINED, T2V_FREEZE_ENCODER, T2V_HEAD_TYPE, T2V_NUM_FRAMES, T2V_IMAGE_SIZE, T2V_MAX_CLIPS, T2V_WITH_XAI, T2V_XAI_THRESHOLD 등을 환경변수로 설정할 수 있다. 이러한 구조는 서버 실행 환경에 따라 모델 경로와 추론 파라미터를 유연하게 변경할 수 있도록 한다.

API 서버는 /t2v/analyze endpoint를 통해 분석 요청을 받는다. 요청에는 s3_url 또는 video_url이 포함되며, 서버는 해당 URL에서 영상을 임시 파일로 다운로드한 뒤 모델 추론을 수행한다. 분석이 완료되면 임시 파일은 삭제되고, 결과는 JSON 형태로 반환된다. 반환 결과에는 최종 판정, AI 생성 확률, 모델 이름, evidence, XAI visualization, forensic report가 포함될 수 있다.

API 응답에서 decision은 FAKE 또는 REAL로 제공된다. 내부 추론 결과의 ai_generated는 서비스 응답에서 FAKE로 대응되고, real은 REAL로 대응된다. t2v_prob는 AI 생성 영상일 확률 점수를 의미하며, 기본 threshold 0.5 이상이면

FAKE, 미만이면 REAL로 판단한다. 이 응답 구조는 웹 서비스에서 사용자에게 최종 분석 결과와 설명 가능 근거를 표시하는 데 사용된다.

4.4.1.12 전체 모델 생성 절차 요약

결과적으로 본 프로젝트의 AI 생성 영상 탐지 모델 생성 과정은 다음과 같이 나타낼 수 있다.




그림4.4.2 전체 모델 생성 절차 요약

이러한 절차는 AI 생성 영상 탐지 모델을 실험 단계에서 끝내지 않고, 실제 서비스와 연결 가능한 형태의 산출물로 생성하기 위한 과정이다. 본 프로젝트의 최종 모델은 단순히 AI 생성 여부만 출력하는 분류기가 아니라, 입력 영상에 대한 판정 결과, confidence, clip별 분석 결과, frame importance, 의심 구간, heatmap/overlay, 설명 문장을 함께 제공할 수 있는 분석 모델로 생성된다.

따라서 본 프로젝트의 AI 학습 모델 생성은 &사전학습 VideoMAE 기반 모델 구성 > AI 생성 영상 데이터셋 기반 학습 > checkpoint 저장 > manifest 평가 > XAI 결과 생성 > FastAPI 서비스 연동&의 순서로 수행된다. 이는 제한된 학과서버 자원 내에서 구현 가능성과 성능 확보 가능성, 설명 가능성, 서비스 연동 가능성을 함께 고려한 모델 생성 방식이라고 할 수 있다.

4.4.2. AI 학습 모델의 생성(딥페이크 탐지)

AI 학습 모델의 생성은 전처리 단계를 통해 확보한 안면 이미지 데이터를 기반으로, Xception 백본과 이진 분류 헤드를 결합한 딥페이크 탐지 모델을 구성하고 이를 학습 데이터에 맞추어 최적화하는 과정으로 이루어진다. 본 프로젝트에서는 이미지 분류 분야에서 성능이 검증된 사전학습 모델을 활용하여 효율적으로 탐지 시스템을 구축하는 전략을 채택한다.

1단계: 기반 모델의 선정 및 초기화

본 연구에서는 딥페이크 탐지에 적합한 백본 네트워크로 Xception을 사용하며, 초기 가중치는 ImageNet 기반의 사전학습 파라미터를 활용한다. 이는 제한된 학습 자원과 프로젝트 기간 내에서 보다 안정적으로 학습을 시작하기 위한 방법이다. 사전학습된 모델이 가진 특징 추출 능력을 얼굴 기반 조작 탐지 과제에 맞게 미세 조정(Fine-tuning)하는 방식으로 적용한다.

2단계: 탐지용 분류 헤드 구성

Xception 백본을 통해 추출된 고차원 특징 벡터는 Global Average Pooling 계층을 거쳐 최종 분류 헤드로 전달된다. 이후 완전연결층(Fully Connected Layer)을 통해 입력 이미지가 실제(Real) 또는 조작(Fake)에 해당할 확률값을 출력하도록 구성한다. 초기 단계에서는 Xception 자체의 특징 추출 성능을 명확히 확인할 수 있도록 직관적인 이진 분류 구조를 채택한다.

3단계: 학습 데이터셋 구성 및 로더 설계

본 프로젝트의 입력 데이터는 영상으로부터 일정 간격으로 샘플링한 프레임에서 안면 영역만을 정밀하게 추출한 이미지이다. FaceForensics++ 데이터셋을 기반으로 MTCNN 얼굴 검출, Bounding Box 확장 크롭, IOU 추적, 블러 필터링, 256×256 해상도 정규화 과정을 거쳐 학습용 데이터를 생성한다. 이후 데이터 로더를 통해 이를 미니배치 단위로 모델 학습에 전달하도록 설계한다.

4단계: 모델 학습 및 검증 과정

생성된 모델은 Binary Cross Entropy 손실 함수와 Adam 옵티마이저를 통해 학습된다. 매 에폭(Epoch)마다 학습 데이터와 검증 데이터를 분리하여 성능을 확인하며, 모델이 훈련 데이터에만 과도하게 적응하지 않도록 관리한다. 정확도뿐만 아니라 정밀도, 재현율, F1-score 등의 지표를 함께 관찰하여 탐지 성능의 균형을 평가한다.

5단계: 영상 단위 판별 결과 생성

프레임 단위의 예측 확률값을 산출한 후, 하나의 영상에서 샘플링된 여러 프레임의 결과

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 [졸업작품 프로젝트]
-------------	---------------------------------	-----------------	-----------------------

를 평균하여 영상 단위의 최종 진위 여부를 판별한다. 이러한 집계 방식은 특정 프레임에서 발생할 수 있는 일시적 오판 가능성을 줄이고, 영상 전체에 대한 안정적인 탐지 결과를 도출하는 데 도움을 준다.

6단계: 최적 모델 선택 및 저장

학습 과정 중 검증 성능이 가장 우수한 시점의 파라미터를 최종 모델로 선택한다. 이는 마지막 에폭의 모델이 항상 최적의 결과를 보장하는 것은 아니기 때문이며, 체크포인트 저장 방식을 통해 과적합을 방지하고 가장 안정적인 성능을 보이는 모델을 최종 산출물로 채택한다.

7단계: 설명 가능성 결과의 생성

최종 분류 결과와 함께 Grad-CAM 기반 시각화를 적용한다. 이를 통해 모델이 얼굴의 어느 부위(안면 윤곽, 눈가, 입가 등)를 근거로 조작 여부를 판단했는지 히트맵 형태로 제시한다. 이러한 분석은 탐지 결과에 대한 신뢰성을 높일 뿐만 아니라, 모델이 실제 위조 흔적에 적절히 반응하는지 확인하는 근거로 활용된다.

결과적으로 본 프로젝트의 모델 생성 과정은 백본 초기화 → 분류 헤드 구성 → 데이터셋 생성 → 학습 및 검증 → 영상 단위 판별 → 모델 저장 → Grad-CAM 분석의 순서로 진행된다. 이는 딥페이크 탐지 과제의 특성을 고려한 현실적인 설계이며, 제한된 자원 환경에서도 구현 가능성과 분석 가능성을 함께 확보할 수 있는 방법이라고 할 수 있다.

5. 화면(UI) 설계

5.1. 사용자 메뉴구성

■ 사용자





그림 5.1 사용자용 메뉴구조도

핵심 사용자 메뉴 구성은 영상 탐지, 탐지 결과, 탐지 기록이며 그에 따른 사용자용 메뉴구조도를 설계했다.


5.2. 초기화면 설계



- 웹을 시작하면 최초로 나타나는 화면이다.
- Solomon AI의 메인 화면이다.
- 비로그인 유저와 로그인 유저의 초기화면은 동일하다.
- 사용자는 영상 파일 업로드 또는 URL 입력 후 **SCAN NOW** 버튼을 눌러 서비스를 이용할 수 있다.
- Home 버튼을 누르면 서비스의 메인 화면으로 이동한다.
- Login 버튼을 누르면 로그인 화면으로 이동한다.


5.3. 사용자 화면설계(웹, 모바일)

■ 홈 화면 (서비스 소개 랜딩) - 화면번호 H01




- Solomon AI의 홈 화면이다.
- 사용자는 **지금 바로 분석하기** 버튼을 눌러 서비스 이용 페이지로 이동할 수 있다.
- 사용자는 **서비스 소개 보기** 버튼을 눌러 Solomon AI의 서비스 소개 페이지로 이동할 수 있다.

■ About 화면 (기술 및 팀 소개) - 화면번호 H02



- Solomon AI의 About 화면이다.
- 사용자는 Solomon AI가 활용하는 기술을 확인할 수 있다.
- 사용자는 Solomon AI의 팀원 정보를 확인할 수 있다.
- 사용자는 [무료로 영상 분석하기](#) 버튼을 눌러 서비스 이용 페이지로 이동할 수 있다.

■ Scan 화면 (메인) - 화면번호 S01



- 웹을 시작하면 최초로 나타나는 화면이다.
- Solomon AI의 메인 화면이다.
- 비로그인 유저와 로그인 유저의 초기화면은 동일하다.
- 사용자는 영상 파일 업로드 또는 URL 입력 후 **SCAN NOW** 버튼을 눌러 서비스를 이용할 수 있다.
- Home 버튼을 누르면 서비스의 메인 화면으로 이동한다.
- Login 버튼을 누르면 로그인 화면으로 이동한다.

■ Scan 대기 화면 (영상 분석 중) - 화면번호 S02


Solomon AI

TARGET: video_evidence_73A.mp4 SYSTEM: ONLINE




- 사용자가 영상 분석을 요청하면 나오는 대기 화면이다.
- 시스템이 영상 분석을 진행 중이라는 부분을 사용자가 직관적으로 알 수 있게 제작했다.
- 오른쪽 상단의 **PROG 41%** 부분이 100%가 되면 영상 분석 완료 페이지로 넘어가게 된다.

■ Scan 완료 화면 (영상 분석) - 화면번호 S03



- 사용자가 영상 분석을 요청을 시스템이 완료 했을 때 나오는 화면이다.
- 사용자가 분석 요청을 한 영상이 AI인지 아닌지 직관적으로 알 수 있도록 화면 설계를 했다.
- 위 페이지에 들어갈 핵심 요소는 다음과 같다.
 1. 최종 판정 결과
 - └ REAL / FAKE 크게 표시
 - 판정 확신도 (%) 함께 표시
 - 색상으로 구분 (FAKE=빨강, REAL=초록)
 2. 분석 점수
 - └ 딥페이크 확률 (%)
 - T2V 확률 (%), 프로그레스 바로 시각화
 3. XAI 설명
 - └ "왜 가짜인지" 텍스트 근거
 - Grad-CAM 히트맵 이미지
 - 의심 프레임 번호 목록
 4. 분석 영상 정보
 - └ 파일명 또는 URL 분석 요청
 - 시간 분석
 - 완료 시간

■ 로그인 화면 - 화면번호 A01



- 사용자 로그인 화면이다.
- 사용자는 **Sign up for free** 버튼을 눌러 회원가입 페이지로 이동할 수 있다.
- 사용자는 **아이디 찾기** 버튼을 눌러 아이디 찾기 페이지로 이동할 수 있다.
- 사용자는 **Forgot your password?** 버튼을 눌러 비밀번호 찾기 페이지로 이동할 수 있다.
- 사용자는 자신의 알맞은 아이디와 비밀번호를 입력 후 **Log In** 버튼을 눌러 로그인을 할 수 있다.

■ 사용자 계정 생성 화면 - 화면번호 A02

- 사용자 계정 생성 화면이다.
- 사용자는 자신의 이름, 이메일 주소, 비밀번호를 입력한 후 **Sign Up** 버튼을 눌러 회원가입을 할 수 있다.

■ 사용자 계정 생성 완료 화면 - 화면번호 A03



- 사용자가 자신의 적절한 정보를 입력 후 시스템에 계정 생성을 요청하면 나오는 화면이다.

■ 아이디 찾기 화면 - 화면번호 A04

- 사용자가 자신의 아이디를 찾을 수 있는 화면이다.
- 사용자가 회원가입 때 입력했던 자신의 이메일 주소로 받은 인증번호를 입력한 뒤 **아이디 찾기** 버튼을 눌러 아이디를 찾을 수 있다.

■ 비밀번호 찾기 화면 - 화면번호 A05

Solomon AI

비밀번호 찾기

가장 시속적인 아이디와 비밀번호를 검색해주어요.

아이디

이메일 주소

연락처

새 비밀번호


새 비밀번호 확인

비밀번호 재설정

가장 시속적인 아이디와 비밀번호를 검색해주어요.

- 사용자가 자신의 비밀번호를 찾을 수 있는 화면이다.
- 사용자가 회원가입 때 입력했던 자신의 정보를 입력하고 인증번호 절차를 마친 뒤, **비밀번호 재설정** 버튼을 눌러 비밀번호를 재설정 할 수 있다.

■ 기록 정보 화면 - 화면번호 H01



- 사용자가 자신이 요청했던 영상 분석 기록을 한 눈에 볼 수 있는 화면이다.
- 화면 상단에는 사용자가 요청했던 영상 분석 수, 그 중에서 AI 생성 영상의 수와 그에 따른 평균 값 통계가 나온다.
- 화면 중앙 부분에는 사용자가 요청했던 영상의 정보가 나온다.
- 사용자는 **All** **FAKE** **REAL** 버튼으로 자신이 요청했던 영상의 전체 보기, Fake 영상만 보기, Real 영상만 볼 수 있다.
- 사용자는 **Search filename or date...** 을 통해 자신이 요청했던 영상을 빠르게 검색할 수 있다.
- 사용자는 **Newest First** **Oldest First** **Highest Probability** **Lowest Probability** 버튼으로 필터를 통해 최신순, 오래된 순으로 영상을 검색할 수 있다.
- 사용자는 버튼으로 자신이 요청했던 영상 분석 기록을 삭제할 수 있다.

6. 프로세스(기능) 설계

6.1. 시스템 아키텍처




그림 2.1 시스템 아키텍처

그림 2.1을 면보 사용자 요청의 효율적인 처리와 확장성을 고려하여 **API Gateway 기반의 마이크로서비스 지향 구조**로 설계되었습니다. 대용량 미디어 처리 부하를 최소화하기 위해 클라이언트 직업 업로드 방식을 채택하고, 별도의 AI 서버를 두어 연산 집약적인 작업을 분리한 것이 특징입니다.

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

주요 구성 요소

- **frontend (Client)** : 웹/앱 인터페이스를 통해 사용자 요청을 수신하며 S3 직접 업로드 및 분석 결과 조회를 담당합니다.
- **Nginx (API Gateway)** : 모든 클라이언트 요청의 단일 진입점 역할을 수행하며, 부하 분산 및 백엔드 서비스로의 라우팅을 담당합니다.
- **Backend Services** :
 - **Auth-Service** : 사용자 인증 및 JWT 발급을 관리합니다.
 - **User-Service** : 사용자 프로필 및 계정 정보를 관리합니다.
 - **Feature-Service** : 핵심 비즈니스 로직(AI 분석 요청 등) 을 처리합니다.
- **Data Persistence & Caching** :
 - **MySQL** : 사용자 정보 및 AI 분석 결과 등 정형 데이터를 저장합니다.
- **Redis** : 세션 관리 및 Refresh Token 저장을 통해 인증 성능을 최적화합니다.
- **External & Academic Server** :
 - **Amazon S3** : 대용량 영상 파일을 저장하는 객체 스토리지 입니다.
 - **AI Server (학과서버)** : S3로부터 영상을 가져와 딥러닝 분석을 수행하는 특화 서버입니다.


6.2. 사용자 기능설계 (Sequence Diagram)

시나리오 1: 사용자 인증 및 로그인 (Login Flow)

[설계 의도: 보안성 및 무상태성(Stateless) 유지]본 시스템은 마이크로서비스 아키텍처(MSA)의 특성을 살려 JWT 기반 인증 방식을 채택했습니다.

- 인증 분리: 모든 인증 로직을 Auth-Service로 집중시켜 각 기능 서비스(User, Feature)가 비즈니스 로직에만 집중할 수 있게 설계했습니다.
- 토큰 이중 관리: Access Token은 클라이언트가 보유하여 무상태 통신을 구현하고, Refresh Token은 서버 측 저장소인 Redis에 저장하여 보안 사고 발생 시 즉각적인 토큰 무효화(Revoke)가 가능하도록 했습니다.


성능 최적화: 세션 정보를 DB가 아닌 메모리 기반 저장소인 Redis에서 관리함으로써 인증 확인 속도를 극대화했습니다.



시나리오 2: 영상 업로드 (Video Upload Flow)

[설계 의도: 서버 자원 효율화 및 대용량 데이터 처리] 대용량 영상 파일 처리에 있어 백엔드 서버가 병목 지점이 되지 않도록 S3 Direct Upload 전략을 사용했습니다.


- **서버 부하 방지 (S3 Direct):** 클라이언트가 영상을 백엔드 서버로 먼저 보낸 뒤 서버가 다시 S3로 올리는 방식은 서버의 CPU, 메모리, 네트워크 대역폭을 이중으로 낭비합니다. 이를 방지하기 위해 클라이언트가 S3에 직접 업로드하도록 설계했습니다.
- **데이터 정합성:** 업로드가 완료된 후 S3로부터 받은 고유 URL만 백엔드로 전달함으로써, DB에는 실제 파일 대신 참조 경로만 저장하여 저장 공간을 효율적으로 관리합니다.
- **확장성:** 전 세계 어디서든 빠른 업로드를 위해 S3의 가용성을 활용하며, 향후 트래픽 증가에도 백엔드 서버 증설 없이 안정적인 업로드가 가능합니다.



시나리오 3: AI 분석 프로세스 (AI Analysis Flow)

[설계 의도: 비동기 처리 및 연산 자원 격리]시간이 오래 걸리는 AI 모델 추론 작업을 별도의 전용 서버에서 처리하고 결과를 연동하는 흐름입니다.

- **자원 격리:** 높은 GPU/CPU 연산이 필요한 AI 분석을 백엔드 서비스와 분리된 AI Server (학과 서버)에서 수행하여, 분석 작업 중에도 일반 API 요청(로그인, 조회 등)이 끊김 없이 처리되도록 보장합니다.
- **효율적 데이터 전달:** AI 서버가 전체 영상 파일을 백엔드로부터 직접 전송받는 대신, S3 URL을 통해 필요한 시점에 파일을 직접 다운로드하게 함으로써 내부 네트워크 트래픽을 최소화했습니다.
- **상태 추적:** 분석 시작 시 DB 상태를 PENDING으로, 완료 시 COMPLETED로 업데이트하여 사용자가 분석 진행 상황을 실시간으로 확인할 수 있는 기반을 마련했습니다.



6.3. AI학습서버 기능설계

6.3.1 ai 생성 영상 탐지

본 프로젝트에서 AI학습서버는 AI 생성 영상 탐지 모델의 학습, 검증, 추론 실험을 수행하기 위한 GPU 기반 실행 환경으로 사용된다. 본 서버의 주요 목적은 GenVideo-100K 기반 학습 데이터를 처리하고, VideoMAE-compatible encoder 기반 탐지 모델을 학습한 뒤, 학습된 모델을 이용하여 입력 영상의 AI 생성 여부를 판별하는 것이다.

AI학습서버는 일반 웹 서비스 기능을 직접 담당하는 서버가 아니라, 연산량이 큰 AI 모델 학습 및 추론을 담당하는 특화 서버이다. 웹 서비스 서버는 사용자 요청, 영상 업로드, 분석 상태 관리, 결과 조회 등을 담당하고, AI학습서버는 영상 분석에 필요한 전처리, 모델 학습, 성능 평가, 추론, 설명 가능 결과 생성을 담당한다. 이를 통해 사용자 서비스 로직과 GPU 기반 AI 연산을 분리하여 시스템의 안정성과 확장성을 확보한다.

본 프로젝트의 AI 생성 영상 탐지 학습서버는 다음 기능을 중심으로 구성된다.

6.3.1.1 데이터 관리 및 검증 기능

AI학습서버의 첫 번째 기능은 학습과 평가에 사용할 영상 데이터를 관리하는 것이다. 본 프로젝트에서는 원본 영상 파일을 단순히 폴더 단위로 순회하여 사용하는 것이 아니라, manifest 파일을 기준으로 학습 샘플을 정의한다. Manifest에는 각 영상의 상대 경로, 라벨, 데이터 분할 정보, 파일 상태 정보가 포함된다.

학습서버는 manifest를 읽은 뒤, train, validation, test split에 따라 데이터를 구분한다. 또한 파일 상태 정보를 확인하여 학습에 사용할 수 없는 샘플을 제외한다. 대용량 영상 데이터셋은 다운로드나 압축 해제 과정에서 일부 파일이 손상될 수 있으므로, 학습 전에 사용 가능한 샘플만 선별하는 과정이 필요하다.

이 기능을 통해 일부 파일 오류가 전체 학습을 중단시키는 문제를 줄이고, 재현 가능한 학습 데이터 구성을 유지할 수 있다.

6.3.1.2 영상 전처리 기능

AI학습서버의 두 번째 기능은 원본 영상을 모델 입력 형식으로 변환하는 것이다. 원본 영상은 길이, FPS, 해상도, 파일 형식이 서로 다르므로, 이를 그대로 모델에 입력할 수 없다. 따라서 모든 영상은 일정한 프레임 수와 해상도를 가지는 텐서로 변환된다.

또한 반복 학습 시 원본 MP4 또는 GIF 파일을 매번 디코딩하면 학습 속도가 저하될 수 있으므로, 필요에 따라 전처리된 프레임 텐서를 .pt 형태로 캐시하여 사용할 수 있다. 캐시를 사용할 경우 학습서버는 원본 영상 대신 캐시된 텐서를 불러와 학습 속도를 개선한다.

6.3.1.3 모델 학습 기능

AI학습서버의 핵심 기능은 AI 생성 영상 탐지 모델을 학습하는 것이다. 본 프로젝트에서는 VideoMAE-compatible encoder를 기반으로 영상의 시공간 특징을 추출하고, classifier head를 통해 실제 영상과 AI 생성 영상을 이진 분류한다.

VideoMAE-compatible encoder는 프레임 내부의 공간적 특징과 프레임 간 시간적 특징을 함께 추출한다. 분류 헤드는 실험 조건에 따라 MLP head 또는 Transformer head를 사용할 수 있다. MLP head는 구조가 단순하고 baseline 실험에 적합하며, Transformer head는 sequence feature를 유지한 상태에서 token 간 관계를 추가로 학습할 수 있다.

학습 손실 함수는 이진 분류 문제에 적합한 BCEWithLogitsLoss를 사용한다. Optimizer는 Transformer 계열 모델 학습에 적합한 AdamW를 사용한다. 학습 중에는 epoch 단위로 validation 성능을 확인하여 모델이 정상적으로 수렴하는지 평가한다.

6.3.1.4 모델 평가 기능

학습된 모델은 validation 또는 test manifest를 기준으로 성능을 평가한다. AI 생성 영상 탐지는 단순히 정확도만으로 평가하기 어렵기 때문에, 본 프로젝트에서는 Accuracy, F1-score, ROC-AUC를 주요 성능 지표로 사용한다.

평가 결과에는 전체 샘플 수, 정상적으로 예측된 샘플 수, 실패 샘플 수, 주요 성능 지표가 포함된다. 이 구조는 모델 성능뿐 아니라 데이터 로딩 실패나 손상 파일 문제도 함께 확인할 수 있게 한다.

6.3.1.5 추론 기능

AI학습서버는 학습된 checkpoint를 이용하여 새로운 영상에 대한 추론을 수행한다. 추론 기능은 크게 단일 영상 추론과 manifest 기반 대량 추론으로 구분된다.

단일 영상 추론은 서비스 요청 또는 개별 실험에서 하나의 영상을 분석할 때 사용된다.

다. 입력 영상은 학습 시와 동일한 전처리 과정을 거쳐 모델에 입력되며, 모델은 해당 영상이 AI 생성 영상일 확률을 출력한다.

긴 영상의 경우 하나의 구간만 분석하면 AI 생성 흔적이 포함된 구간을 놓칠 수 있다. 따라서 학습서버는 필요 시 여러 clip을 생성하여 각 clip별 예측을 수행한다. 최종 판정은 가장 높은 AI 생성 확률을 보인 대표 clip을 기준으로 수행한다.

Manifest 기반 대량 추론은 test split 전체에 대해 모델 성능을 평가하거나, 다수의 영상에 대한 예측 결과를 한 번에 생성할 때 사용된다. 이 과정에서 각 영상의 예측 결과와 실패 항목을 분리하여 저장한다.

6.3.1.6 XAI 결과 생성 기능

AI학습서버는 단순히 최종 판정 결과만 생성하는 것이 아니라, 모델이 어떤 프레임과 구간을 중요하게 보았는지 확인할 수 있는 설명 가능 결과를 생성한다. 본 프로젝트의 AI 생성 영상 탐지에서는 attention 기반 XAI를 사용하여 frame importance, 의심 구간, heatmap/overlay를 생성한다.

Frame importance는 모델이 입력 clip 내에서 상대적으로 중요하게 본 프레임의 점수이다. 이 점수를 기준으로 의심 프레임과 의심 구간을 추출할 수 있다. 또한 attention map을 이용하여 모델이 주목한 영역을 heatmap 형태로 시각화할 수 있다.

다만 XAI 결과는 모델 판단의 보조 근거로 사용해야 한다. Attention map이나 heatmap은 모델 내부의 주의 흐름을 시각화한 결과이며, 최종 판단의 완전한 원인으로 단정할 수 없다. 따라서 본 프로젝트에서는 XAI 결과를 판단 근거를 이해하기 위한 보조 정보로 제공한다.

6.3.1.7 AI 학습서버 시퀀스 다이어그램

그림 6.3는 본 프로젝트의 AI학습서버 기능 구성을 나타낸다. 입력된 영상 데이터는 전처리 과정을 거쳐 프레임 시퀀스로 변환되며, 이후 GPU 자원을 활용하여 VideoMAE 기반 탐지 모델의 학습이 수행된다. 학습 완료 후 생성된 모델은 추론 단계에서 새로운 영상의 진위 여부를 판별하는 데 사용되며, 결과는 성능 지표 및 시각화 결과와 함께 저장된다.




그림 6.3 AI 학습서버 시퀀스 다이어그램

6.3.2 AI 학습서버 기능설계 (딥페이크 탐지)

본 프로젝트에서 AI 학습서버는 딥페이크 탐지 모델의 학습과 추론 실험을 수행하기 위한 실행 환경으로 사용된다. 본 서버의 주요 목적은 영상 데이터로부터 얼굴 프레임을 추출하고, GPU 자원을 활용하여 Xception 기반 탐지 모델을 학습하며, 학습이 완료된 모델에 대해 추론 및 성능 검증을 수행하는 것이다. 즉, 본 프로젝트에서 학습서버는 서비스 운영을 위한 상용 서버라기보다, 모델 개발과 성능 검증을 지원하는 GPU 기반 실험 서버의 성격을 가진다.

학습서버의 첫 번째 기능은 입력 데이터 전처리이다. 원본 영상 데이터는 학습서버로 전달된 후 일정 간격으로 프레임 샘플링이 이루어지며, 이후 MTCNN을 이용한 얼굴 검출 과정을 수행한다. 검출된 얼굴 영역은 Bounding Box 확장 크롭, 인접 프레임 간 IOU 기반 추적, 블러 필터링, 256×256 해상도 정규화 과정을 거쳐 모델 입력 형식에 맞는 얼굴 이미지 데이터로 변환된다. 이러한 전처리 과정은 모델이 배경보다 얼굴 중심의 위조 흔적에 집중하도록 돕는 역할을 한다.


두 번째 기능은 딥페이크 탐지 모델 학습 수행이다. 본 프로젝트에서는 사전학습된 Xception 백본에 이진 분류 헤드를 결합한 뒤, 실제 영상과 조작 영상을 구분하는 이진 분류 학습을 수행한다. 이 과정에서 학습서버는 GPU 연산 자원을 활용하여 파라미터 갱신을 수행하며, 에폭(Epoch) 단위로 손실값과 검증 성능을 확인한다. 또한 필요에 따라 학습률, 배치 크기 등의 하이퍼파라미터를 조정하면서 반복 실험을 수행하여 적절한 모델 설정을 탐색한다.

세 번째 기능은 학습된 모델을 이용한 추론 수행이다. 학습이 완료된 모델은 새로운 입력 영상에 대해 프레임 단위의 Real/Fake 확률값을 산출하며, 이를 평균 집계하여 영상 단위의 최종 진위 여부를 판별한다. 이 과정에서도 학습서버는 GPU를 활용하여 추론 속도와 실험 효율을 높이며, 출력 결과로 예측 클래스와 확률값을 제공한다. 이러한 구조는 특정 프레임에서 발생할 수 있는 일시적 오판 가능성을 줄이고, 영상 전체에 대한 보다 안정적인 판단 결과를 얻는 데 도움을 준다.

네 번째 기능은 설명 가능성(XAI) 분석 수행이다. 최종 판별 결과와 함께 Grad-CAM 기반 시각화를 적용하여, 모델이 얼굴의 어느 부위를 근거로 조작 여부를 판단했는지 확인하고자 한다. 학습서버는 이러한 시각화 결과를 생성함으로써 단순한 분류 결과뿐 아니라 판단 근거를 함께 제시할 수 있도록 지원한다. 이는 탐지 결과의 신뢰성을 보완하고, 모델이 실제 위조 흔적에 적절히 반응하고 있는지를 분석하는 데에도 활용될 수 있다.

마지막으로 학습서버는 실험 결과 저장 및 관리 기능을 가진다. 학습 과정에서 생성된 모델 가중치, 성능 지표, 추론 결과, Grad-CAM 시각화 결과 등은 후속 비교 실험과 최종 모델 선정에 활용된다. 이를 통해 동일한 데이터에 대해 여러 실험 결과를 비교하고, 안정적인 성능을 보이는 탐지 모델을 선택할 수 있다.

정리하면, 본 프로젝트의 AI 학습서버는 얼굴 프레임 기반 전처리, GPU 기반 모델 학습, 영상 단위 추론, Grad-CAM 분석, 결과 저장 및 관리 기능을 수행하는 실험용 연산 서버로 설계된다. 이는 딥페이크 탐지 모델을 효율적으로 개발하고 검증하기 위한 핵심 실행 환경이라고 할 수 있다.




AI 학습서버 시퀀스 다이어그램

해당 시퀀스 다이어그램은 본 프로젝트의 AI 학습서버 기능 구성을 시계열적으로 나타낸다. 사용자의 영상 탐지 요청부터 MTCNN 기반의 전처리, Xception 모델을 통한 특징 추출 및 분류, 그리고 Grad-CAM 시각화 결과 생성에 이르기까지의 전체적인 데이터 흐름을 명시한다. 특히 프레임 단위의 판별 확률을 평균 집계(Mean Pooling)하여 영상 단위의 최종 결과를 도출하고 이를 데이터베이스에 기록하는 일련의 과정을 상세히 기술하였다.

7. API 설계

7.1. 서버/클라이언트 구조



본 설계는 그림 4.1에서처럼 MSA 아키텍처 내에서 요청이 어떻게 라우팅되고 처리되는지를 인터페이스 관점에서 명확히 보여줍니다.

7.2. 서비스 REST API 정의

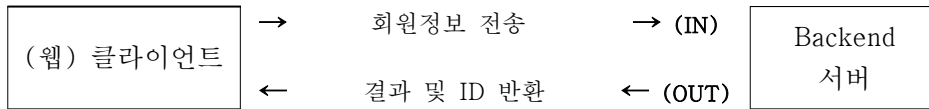
Method	URI	Description
GET	/api/videos/{id}/status	분석 진행 상태
	/api/videos/url	분석 결과 조회
	/api/quiz/next	다음 퀴즈 영상
	/api/quiz/status	내 정답률
	 (계속 정의 ... 함)	

Method	URI	Description
POST	/api/auth/register	사용자 회원가입
	/api/auth/login	사용자 로그인
	/api/auth/logout	사용자 로그아웃
	/api/auth/refresh	사용자 토큰 갱신
	/api/videos/upload	영상 파일 업로드
	/api/videos/url	URL 기반 분석 요청
	/api/quiz/answer	정답 제출
	 (계속 정의 ... 함)	

Method	URI	Description
DELETE	/api/history/{id}	기록삭제
E	... (계속 정의 ... 함)	...

7.3. 서비스 REST API 설계

POST /api/auth/register



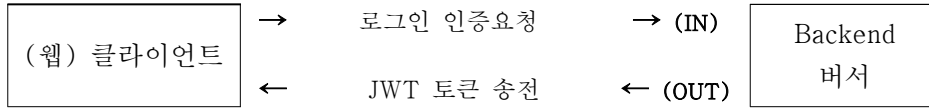
Parameter

속성	전송방향		Type	Description
	IN	OUT		
email	O		String	사용자 이메일(아이디)
password	O		String	비밀번호
nickname	O		String	사용자닉네임
result_code		O	int	200: 성공, 400 중복등
user_id		O	Long	생성된 사용자 고유 식별자

실제 전송내용 (JSON 의 경우라면)

```
// IN
{ "email": "user@example.com", "password": "password123", "nickname": "지혁" }
// OUT
{ "result_code": 200, "user_id": 1024 }
```

POST /api/auth/login



Parameter

속성	전송방향		Type	Description
	IN	OUT		
email	O		String	사용자 이메일
password	O		String	비밀번호
access_token		O	String	API 접근용 JWT 토큰
refresh_token		O	String	토큰 갱신용 리프레시 토큰

실제 전송내용 (JSON 의 경우라면)

GET /api/videos/{id}/result

(웹) 클라이언트

→ 분석 결과 요청(ID) → (IN)

← 상세 분석 데이터 전송 ← (OUT)

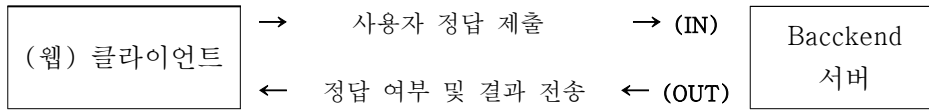
Backend
서버

Parameter

속성	전송방향		Type	Description
	IN	OUT		
video_id	O		Long	분석된 영상 고유번호
verdict		O	String	최종 판정(진본/위조)
score		O	float	딥페이크 확률 수치
xai_image		O	String	설명 가능한 AI 분석 이미지 IURL

실제 전송내용 (JSON 의 경우라면)

POST /api/quiz/answer



Parameter

속성	전송방향		Type	Description
	IN	OUT		
video_id	O		Long	퀴즈 영상 번호
answer	O		String	사용자가 선택한 정답
is_correct		O	boolean	정답 여부 (true/false)
correct_answer		O	String	실제 정답 정보

실제 전송내용 (JSON 의 경우라면)

POST /api/auth/password-change

(웹) 클라이언트

→ 기존/신규 비번 전송 → (IN)

← 처리 결과 전송 ← (OUT)

Backend
서버

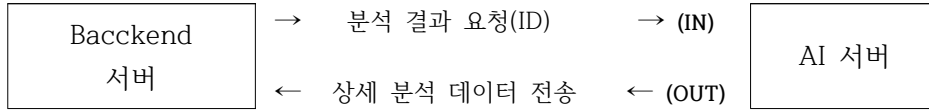
Parameter

속성	전송방향		Type	Description
	IN	OUT		
old_password	O		String	현재 비밀번호
new_password	O		String	변경할 새 비밀번호
result_code		O	int	처리 결과 코드

실제 전송내용 (JSON 의 경우라면)

7.4. AI학습서버 REST API 설계

POST /t2v/analyze



Parameter

속성	전송방향		Type	Description
	IN	OUT		
s3_url	O		String	분석 대상 영상의 S3 또는 presigned URL
return_xai	O		Boolean	
decision		O	String	최종 판정. REAL 또는 FAKE
t2v_prob		O	Float	AI 생성 영상일 확률
model_used		O	String	사용한 모델명
evidence		O	Object	모델 판단 근거 정보


실제 전송내용 (JSON 의 경우라면)

```
Request
{
  "s3_url":
  "https://example-bucket.s3.ap-northeast-2.amazonaws.com/videos/sample.mp4",
  "return_xai": true,
}

// 내용이 매우 긴 관계로 일부 생략
Response
{
  "decision": "FAKE",
  "t2v_prob": 0.9821,
  "model_used": "VideoMAE",
  "evidence": {
    "frame_importance": [
      0.12,
      0.25,
      0.78
    ],
    "sampled_frames": [
      {
        "sampled_frame_index": 0,
        "original_frame_index": 0,
        "timestamp_sec": 0.0,
        "importance": 0.12
      },
      {
        "sampled_frame_index": 1,
        "original_frame_index": 37,
        "timestamp_sec": 1.23,
        "importance": 0.25
      }
    ],
    "segments": [
      {
        "start_frame": 2,
        "end_frame": 4,
        "type": "motion anomaly",
        "confidence": 0.85,
        "start_sampled_frame_index": 2,
        "end_sampled_frame_index": 4,
        "start_original_frame_index": 74,
        "end_original_frame_index": 148,
        "start_timestamp_sec": 2.46,
        "end_timestamp_sec": 4.93
      }
    ]
  }, ...
}
```


8. 데이터 설계

8.1. ERD



데이터베이스

본 서비스의 데이터베이스는 회원 정보(users), 영상 업로드 정보(videos), AI 분석 결과(results), 퀴즈 참여 기록(quiz_records) 총 4개의 테이블로 구성되며, 비로그인 사용자도 영상 분석이 가능하도록 videos 테이블의 user_id는 null을 허용한다.

8.2. 논리적 DB설계 (테이블명세서)

테이블명(회원정보) :			USERS			
NO	Attribute	Data Type	NN	PK	FK	Description
1	ID	BIGINT	O	O		회원 고유 식별자
2	EMAIL	VARCHAR(255)	O			사용자 이메일(로그인 ID)
3	PASSWORD	VARHCHAR(255)				암호화된 비밀번호
4	NICKNAME	VARCHAR(100)				사용자 닉네임
5	CREATED_AT	TIMESPATMP				계정 생성 일시

테이블명(영상정보) :			VIDEOS			
NO	Attribute	Data Type	NN	PK	FK	Description
1	ID	BIGINT	O	O		영상 고유 식별자
2	USER_ID	BIGINT			O	업로드한 회원 식별자
3	FILE_PATH	VARHCHAR(500)				서버 내 영상 파일 저장 경로
4	URL	VARCHAR(100)				외부 링크 기반 분석 URL
5	STATUS	VARCHAR(50)				분석 상태 (대기/분석중/완료/실패)
6	CREATED_AT	TIMESTAMP				영상 업로드 시간

테이블명(AI 분석 결과) :			RESULTS			
NO	Attribute	Data Type	NN	PK	FK	Description
1	ID	BIGINT	O	O		결과 고유 식별자
2	VIDEO_ID	BIGINT	O		O	대상 영상 식별자
3	FINAL_VERDICT	VARHCHAR(20)				최종 판정 결과
4	DEEPFAKE_SCORE	FLOAT				딥페이크 확률 값
5	T2V_SCORE	FLOAT				T2V 확률 값
6	SUSPICIOUS_FRAMES	JSON				의심되는 프레임 번호 목록
7	XAI_EXPLANATION	JSON				XAI 근거 설명 데이터
8	CREATED_AT	TIMESTAMP				분석 완료 시간

테이블명(퀴즈 참여 기록) :			QUIZ_RECORDS			
NO	Attribute	Data Type	NN	PK	FK	Description
1	ID	BIGINT	O	O		퀴즈 고유 식별자
2	USER_ID	BIGINT	O		O	참여한 회원 식별자
3	VIDEO_ID	BIGINT	O		O	퀴즈 대상 영상 식별자
4	USER_ANSWE R	VARCHAR(20)				사용자가 제출한 정답
5	IS_CIORRECT	BOOLEAN				정답 여부
6	CREATED_AT	TIMESTAMP				퀴즈 참여 시간

8.3. 로그파일 설계

파일명 : oooooooooo.log

레벨	형식	설명	비고
0	error	디바이스에서 발생하는 치명적인 오류를 포함	즉시 확인 필요
1	warn	디바이스에서 발생하는 일반적인 오류를 포함	잠재적 문제 발생
2	info	디바이스에서 상태변경과 같은 정보성 메시지	정상 운영 기록
3	DEBUG	개발 단계에서 상세 로직 확인용 (API 요청 파라미터 등)	운영시 비활성화 가능

Log 예시)

2026.03.26.14:10:05.12 [INFO] 200 : 정상 처리, 사용자(ID: gachon-18) 로그인에 성공하였습니다.
2026.03.26.14:12:30.45 [INFO] 200 : 정상 처리, 비디오 파일(video_001.mp4) 업로드가 완료되었습니다.
2026.03.26.14:12:32.10 [INFO] 202 : 분석 시작, Celery 태스크 큐에 비디오 분석 작업이 할당되었습니다.
2026.03.26.14:15:20.88 [INFO] 200 : 정상 처리, AI 분석 완료 (결과: FAKE, Score: 98.5).
2026.03.26.14:20:00.00 [WARN] 403 : 권한 없음, 유효하지 않은 토큰으로 결과 조회 시도가 발생했습니다.
2026.03.26.15:00:10.55 [ERROR] 500 : 시스템 오류, RDS 데이터베이스 연결 세션이 만료되었습니다.
2026.03.26.15:05:30.11 [ERROR] 404 : 해당 파일을 찾을 수 없습니다. './storage/uploads/temp_video.mp4'

<표 8.3> Log 파일 설계

8.4. 오류코드 및 오류파일 설계

코드 번호	설명	비고
200	정상 처리(성공)	
000	정의되지 않은 에러코드	
400	잘못된 파일형식 오류	지원하지않는 확장자(mp4등)
401	사용자 인증 및 권한 오류	비로그인 또는 토큰만료
413	파일크기 초과 오류	설정한 최대 용량 초과
501	비디오 프레임 추출 오류	영상 데이터 손상으로 인한 파싱 실패
502	Celery 작업 할당 오류	비동기 작업 큐 연결 실패
503	AI 모델 추론 엔진 오류	Deepfake/T2V 모델 실행 중 런타임 에러
504	XAI 근거 생성 오류	설명 가능한 AI 데이터 생성 실패
505	결과 데이터베이스 저장 오류	분석 결과의 RDS 매핑 실패
506	비디오 저장소 접근 오류	S3 또는 local storage 읽기/쓰기 권한 문제

<표 8.4> 오류코드

400 에러 코드는 사용자가 업로드한 파일이 시스템에서 지원하는 영상 포맷(MP4, AVI 등)이 아닐 때 발생하는 오류이다.

502 에러 코드는 백엔드 서버에서 AI 분석을 위해 비동기 작업 서버(Celery)로 요청을 보낼 때, 메시지 브로커와의 통신이 원활하지 않아 발생하는 오류이다.

503 에러 코드는 AI 모델이 로드되지 않거나, 영상 분석 과정에서 메모리 부족(OOM) 등으로 인해 비정상 종료되었을 때 발생한다.

[오류 파일 설계]

오류 발생 시 원인을 즉각 파악하기 위해 시스템 로그와 별개로 '에러 전용 로그 파일'을 운영한다.

파일명: error_detect_%d{yyyy-MM-dd}.err

파일 형식: JSON 포맷 (자동화된 에러 모니터링 및 분석을 용이하게 하기 위함)

[오류 파일 포맷 상세 설명]

- Timestamp: 오류가 발생한 정확한 일시
- ErrorCode: 위 <표 8.4>에서 정의한 고유 코드
- ErrorLevel: 오류의 심각도 (Critical, Major, Minor)
- RequestID: 오류를 추적하기 위한 고유 요청 ID (Trace ID)
- StackTrace: 프로그래밍 언어상에서 발생한 상세 오류 추적 경로
- Description: 오류 상황에 대한 요약 설명

9. 성능평가지표

9.1. AI서비스 성능평가지표

평가항목	단위	개발목표치	평가방법
AI 영상 탐지 정확도	%	≥ 85	Cross-dataset 검증 및 성능지표 기반 평가

평가항목	AI 영상 탐지 정확도 (Detection Accuracy)
시험내용	본 시험은 AI 생성 영상과 실제 영상 간의 이진 분류 성능을 평가하기 위해 수행한다. 특히 모델이 특정 데이터셋에 과적합되지 않았음을 검증하기 위해 cross-dataset evaluation을 적용한다. 학습 데이터셋과 서로 다른 출처의 테스트 데이터셋을 사용하여 일반화 성능을 측정하며, Confusion Matrix를 기반으로 Accuracy, Precision, Recall, F1-score, AUC-ROC를 산출한다.
시험환경	1. AI 영상 데이터셋 (GenVideo, diffusion 기반 영상 등) 2. 실제 영상 데이터셋 (WebVid-10M, MSR-VTT 등) 3. 학습된 VideoMAE 기반 탐지 모델 4. 성능 평가를 위한 Python 환경 (PyTorch, sklearn)
시험절차	1. AI 영상과 실제 영상 데이터를 각각 수집 및 구성한다. 2. 특정 데이터셋을 이용하여 모델을 학습한다. 3. 학습에 사용되지 않은 다른 데이터셋을 이용하여 테스트를 수행한다. 4. 테스트 결과를 기반으로 Confusion Matrix를 구성한다. 5. 아래 지표를 계산한다: • $\text{Accuracy} = (\text{TP} + \text{TN}) / \text{전체}$ • $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$ • $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$ • $\text{F1-score} = \text{Precision과 Recall의 조화 평균}$ • $\text{AUC-ROC} = \text{threshold 변화에 따른 전체 분류 성능 목표 성능 기준 이상일 경우 성공으로 판단한다.}$

평가항목	단위	개발목표치	평가방법
Localization 및 Explanation 성능평가	%	≥ 75	IoU 기반 구간 평가 및 설명 정확도 검증

평가항목	이상 구간 및 원인 설명 정확도 (Localization & Explanation Accuracy)
시험내용	본 시험은 Localization에 대해 영상 내에서 이상이 발생한 시간 구간을 정확히 탐지하는 성능을 평가한다. 모델이 attention 기반으로 산출한 frame-level 중요도를 이용하여 이상 구간을 생성하고, 이를 사전에 정의된 Ground Truth 구간과 비교하여 정확도를 측정한다 또한 Explanation에 대해 모델이 생성한 설명이 실제 영상의 이상 현상을 올바르게 반영하는지 평가한다. 모델은 이상 구간에 대해 다음과 같은 유형을 분류한다: • Texture jitter (텍스처 깜빡임) • Object inconsistency (형태 이상) • Movement anomaly (움직임 이상) • Lighting anomaly (조명 이상) • Space anomaly (공간 구조 이상) 설명은 시간 + 위치 + 이상 유형을 기반으로 생성된다.
시험환경	1. 이상 구간이 정의된 영상 데이터 (수동 라벨링) 2. VideoMAE 기반 모델 및 attention 추출 모듈 3. 이상 유형 분류 및 설명 생성 모듈 4. 평가를 위한 Python 환경
시험절차	1. 평가용 영상에 대해 이상 발생 구간(Ground Truth)을 정의한다. 2. 모델을 이용하여 frame별 anomaly score를 산출하고, threshold를 적용하여 이상 구간(segment)을 생성한다. 3. 예측된 이상 구간과 Ground Truth 구간을 비교하여 IoU 및 frame-level Accuracy를 계산한다. 4. 모델이 생성한 이상 유형 및 설명 결과를 수집한다. 5. Rule-based 검증을 통해 설명이 영상 특성과 일치하는지 확인한다. 6. 일부 샘플에 대해 human evaluation을 수행하여 설명의 타당성을 평가하고, 최종 성능을 종합적으로 판단한다.

평가항목	단위	개발목표치	평가방법
딥페이크 탐지 정확도	%	≥ 85	테스트 데이터셋 기반 Confusion Matrix 및 성능 지표 평가

평가항목	딥페이크 탐지 정확도
시험내용	본 시험은 모델이 실제 사람의 얼굴 영상(Real)과 AI로 생성된 조작 영상(Fake)을 얼마나 정확하게 분류하는지 평가한다. 학습에 사용되지 않은 FaceForensics++ 테스트 데이터셋을 활용하여 일반화 성능을 측정하며, Accuracy, Precision, Recall, F1-score, AUC-ROC 지표를 종합적으로 산출한다.
시험환경	1. 평가용 데이터셋: FaceForensics++ (Real 및 Fake 프레임 이미지) 2. 평가 모델: 학습이 완료된 Xception 기반 딥페이크 탐지 모델 3. 성능 평가 환경: Python, PyTorch, scikit-learn 라이브러리
시험절차	1. 테스트용 안면 프레임 데이터를 모델에 입력하여 Real/Fake 확률을 산출한다. 2. 프레임 단위 확률값을 영상 단위로 평균 집계하여 최종 예측값을 도출한다. 3. 예측값과 실제 라벨(Ground Truth)을 비교하여 Confusion Matrix를 구성한다. 4. 정해진 수식에 따라 Accuracy, F1-score 등을 계산한다. 5. 산출된 정확도가 목표 기준(85%) 이상인지 확인하고, Precision, Recall, F1-score 등 보조 지표를 함께 검토하여 성능을 종합적으로 판단한다.

평가항목	단위	개발목표치	평가방법
시각적 판단 근거 정확도	%	≥ 75	샘플링 데이터 기반 Grad-CAM 시각화 타당성 평가 (Human Evaluation)

평가항목	시각적 판단 근거 정확도
시험내용	본 시험은 모델이 영상 프레임을 Fake로 판별했을 때, Grad-CAM 히트맵이 실제 위조가 발생한 안면 영역을 합리적으로 지시하고 있는지 그 타당성(Validity)을 평가한다. 픽셀 단위의 정답 마스크 확보가 까다로운 환경을 고려하여, 모델이 생성한 히트맵을 다수의 평가자가 직접 시각적으로 확인하는 정성적 평가 방식을 채택한다.
시험환경	1. 검증용 데이터: 테스트셋에서 실제 Fake인 샘플 중 모델이 Fake로 올바르게 판정(True Positive)한 사례 100개 프레임 2. 평가 모델: 학습 완료된 Xception 모델 및 Grad-CAM 시각화 추출 모듈 3. 평가자: 딥페이크 위조 특징 및 안면 구조에 대한 사전 가이드를 숙지한 프로젝트 팀원 (최소 2인 이상)
시험절차	1. 테스트셋의 정답 판정(TP) 사례 중 무작위로 100개의 샘플을 추출하여 Grad-CAM 히트맵을 생성한다. 2. 최소 2명 이상의 평가자가 독립적으로 히트맵을 확인하여 다음 기준에 따라 'Pass/Fail'을 판정한다. - Pass: 안면 윤곽, 눈가, 입가, 피부 경계 등 얼굴 내 조작 의심 부위에 주된 활성화가 형성된 경우 - Fail: 배경, 의복, 화면 외곽 등 비관련 영역에 주된 활성화가 집중된 경우 3. 평가자 간 의견이 불일치할 경우, 교차 검토 및 협의를 통해 최종 판정을 확정한다. 4. 다음 수식을 통해 타당성 지표를 계산한다: - 시각적 타당성 비율(%) = (Pass 판정을 받은 샘플 수 / 100) × 100 5. 산출된 타당성 비율이 목표 기준(75%) 이상일 경우 성공으로 판단한다.

9.2. AI학습 성능(ROC)

본 프로젝트는 5가지 항목에 대해 평가 및 그래프를 작성할 예정이며, 평가 항목은 Accuracy, Precision, Recall, F1-score, AUC-ROC이다.

Accuracy는 전체 테스트 데이터 중 모델이 올바르게 분류한 비율을 의미한다. 실제 AI 영상을 AI로, 실제 영상을 REAL로 정확히 판별한 결과를 모두 포함하여 산출한다. 또한 학습 데이터셋과 다른 출처의 테스트 데이터셋에 대해서도 동일하게 Accuracy를 측정하여 모델의 일반화 성능을 함께 확인할 계획이다.

Precision@0.5는 모델이 AI라고 예측한 영상들 중 실제로 AI 영상인 비율을 의미한다. 즉, AI라고 판단한 결과가 얼마나 신뢰할 수 있는지를 나타내는 지표이다. 테스트 시 모델이 출력한 확률값을 기준으로 threshold를 적용하여 AI 여부를 판정하고, 해당 결과를 바탕으로 Precision 값을 계산할 예정이다. 필요 시 threshold를 조정해가며 Precision 변화를 함께 분석할 계획이다.

Recall@0.5는 실제 AI 영상 중에서 모델이 AI로 올바르게 탐지한 비율을 의미한다. 이는 AI 생성 영상을 얼마나 놓치지 않고 검출할 수 있는지를 보여주는 지표이다. 본 프로젝트에서는 단순히 오탐을 줄이는 것뿐 아니라, 실제 AI 영상을 충분히 검출하는 능력도 중요하므로 Recall을 함께 평가한다. 테스트 데이터셋 내 실제 AI 영상에 대한 예측 결과를 기준으로 Recall 값을 산출하고, 이를 통해 모델의 탐지 민감도를 분석할 예정이다.

F1-score는 Precision과 Recall의 균형을 종합적으로 평가하는 지표이다. Accuracy는 데이터 분포에 따라 높게 나타날 수 있으나, 실제로는 AI 탐지 성능이 충분하지 않을 수 있다. 따라서 본 프로젝트에서는 Precision과 Recall을 동시에 고려할 수 있는 F1-score를 핵심 평가 지표 중 하나로 사용한다.

AUC-ROC는 threshold를 변화시키면서 모델의 전체적인 분류 성능을 평가하는 지표이다. ROC Curve는 False Positive Rate와 True Positive Rate의 관계를 나타내며, AUC 값은 해당 곡선 아래 면적을 의미한다. 본 프로젝트에서는 특정 threshold 하나에만 의존하지 않고, 모델이 전반적으로 AI 영상과 실제 영상을 얼마나 잘 구분하는지를 확인하기 위해 AUC-ROC를 사용한다. 테스트 데이터셋에 대해 모델이 출력한 확률값을 수집한 뒤 ROC Curve를 작성하고, 이를 바탕으로 AUC 값을 계산할 예정이다.

9.3. AI 학습 성능(ROC) 및 평가지표 분석 (딥페이크 탐지)

본 프로젝트에서는 딥페이크 탐지 모델의 성능을 다각적으로 평가하기 위해 Accuracy, Precision, Recall, F1-score, AUC-ROC의 5가지 항목을 기준으로 성능을 측정하고 관련 그래프를 작성할 예정이다. 단일 지표만으로는 모델의 실제 탐지 성능을 충분히 설명하기 어렵기 때문에, 본 연구에서는 실제 영상과 조작 영상을 얼마나 정확하고 균형 있게 구분하는지를 종합적으로 확인할 수 있는 지표들을 함께 활용한다.

- **Accuracy (정확도):** 전체 테스트 데이터 중 모델이 올바르게 분류한 비율을 의미한다. 즉, 실제 영상(Real)을 Real로, 조작 영상(Fake)을 Fake로 정확하게 판별한 결과를 모두 포함하여 산출한다. 본 프로젝트에서는 테스트 데이터셋에 대해 Accuracy를 계산함으로써 모델의 전반적인 분류 성능을 확인하고, 필요에 따라 학습 데이터와 구성이 다른 테스트 샘플에 대해서도 평가를 수행하여 일반화 가능성을 검토할 예정이다.
- **Precision (정밀도):** 모델이 조작 영상(Fake)이라고 예측한 결과 중 실제로 조작 영상인 비율을 의미한다. 이는 모델이 Fake라고 판단한 결과가 얼마나 신뢰할 수 있는지를 보여준다. 딥페이크 탐지에서는 실제 영상을 조작 영상으로 잘못 분류(False Positive, 오탐)하는 경우도 치명적이므로, Precision을 통해 오탐의 수준을 함께 확인한다. 모델이 출력한 확률값에 임계값(Threshold)을 적용하여 산출할 예정이다.
- **Recall (재현율):** 실제 조작 영상(Fake) 중에서 모델이 조작 영상으로 올바르게 탐지한 비율을 의미한다. 딥페이크 탐지 과제에서는 오탐을 줄이는 것뿐만 아니라, 교묘하게 위조된 영상을 놓치지 않고 검출(False Negative 방지)하는 능력 역시 매우 중요하므로 Recall을 필수적으로 평가하여 모델의 탐지 민감도를 분석할 계획이다.
- **F1-score:** Precision과 Recall의 조화평균으로, 두 지표 간의 균형을 종합적으로 평가하기 위한 기준이다. 데이터 분포에 따라 Accuracy가 상대적으로 높게 나타나는 착시를 방지하고, 실제 영상과 조작 영상에 대한 탐지 성능이 어느 한쪽으로 치우치지 않고 균형 있게 확보되었는지를 확인하고자 한다.
- **AUC-ROC:** 임계값(Threshold)을 변화시키면서 모델의 전체적인 분류 성능을 평가하는 지표이다. ROC Curve는 False Positive Rate와 True Positive Rate의 관계를 나타내며, AUC 값은 해당 곡선 아래의 면적을 의미한다. 단일 임계값에만 의존하지 않고, 모델이 전체적으로 실제와 조작을 얼마나 잘 구분하는지를 확인하기 위해 ROC Curve를 작성하고 AUC 값을 계산할 예정이다.

[영상 단위 집계 평가 전략]

본 프로젝트의 딥페이크 탐지 모델은 프레임 단위 안면 이미지를 입력으로 사용하고, 각 프레임에 대한 예측 확률값을 평균 집계(Mean Pooling)하여 영상 단위의 최종 판별 결과를 생성한다. 따라서 위의 성능지표들은 **최종적으로 '영상 단위의 예측 결과'를 기준으로 산출하는 것을 원칙으로** 하며, 필요할 경우 프레임 단위 결과와 비교하여 분석할 수도 있다. 이러한 평가 방식은 특정 프레임의 일시적인 오판에 영향을 덜 받으면서, 영상 전체에 대한 보다 안정적인 탐지 성능을 확인하는 데 도움이 된다.

결과적으로 본 프로젝트에서는 Accuracy, Precision, Recall, F1-score, AUC-ROC를 종합적으로 활용하여 Xception 기반 딥페이크 탐지 모델의 성능을 평가하고자 한다. 이를 통해 단순한 분류 정확도뿐 아니라 오탐과 미탐의 균형, Threshold 변화에 따른 성능 추이, 영상 단위 탐지 안정성 등을 함께 분석함으로써 모델의 실제 서비스 적용 가능성을 종합적으로 검토할 계획이다.

10. 개발환경구성

10.1. 개발환경

■ 서버

구분	개발환경	규격	비고
개발툴	편집툴	VS Code / IntelliJ IDEA	
	개발IDE	VS Code / IntelliJ IDEA	
	프레임워크	Spring Boot 3.x / Java 17	
	사용할 미들웨어(모듈)	ai : python 3.10, PyTorch... front : Express, Router back : docker, docker compose messeging que : redis, Celery	
서버	TCP Port주소	8080(API), 3306(DB), 22(SSH)	
	IP주소	AWS EC2 퍼블릭 IP	
	OS	Ubuntu 22.04 LTS	
	DB	AWS RDS (MySQL)	
서버 하드웨어	CPU	vCPU 2 Core (t3.small)	
	RAM	2G RAM	
	DISK	20GB SSD (gp3)	
	Network	최대 5Gbps(aws 내부 네트워크)	

팀명 : 달팽이 질주	딥러닝을 활용한 AI 생성 스포츠 영상 탐지 서비스	version v1.0	컴퓨터공학과 (졸업작품 프로젝트)
-------------	---------------------------------	-----------------	-----------------------

10.2. 소스디렉터리 구조

1. Backend (Spring Boot - API Server)

디렉터리 / 파일명	역할 및 기능	주요 메소드(예시)
controller / VideoController.java	클라이언트의 요청을 받고 응답을 반환하는 메인 컨트롤러	uploadVideo(), getAnalysisResult()
service AnalysisService.java	비즈니스 로직 처리 및 Celery 작업 큐에 분석 요청 전달	requestDeepfakeAnalysis(), saveQuizRecord()
repository / VideoRepository.java	Spring Data JPA를 이용한 RDS(DB) 인터페이스 정의	findById(), findById()
dto / VideoResponseDTO.java	데이터 전송을 위한 객체 (Data Transfer Object)	-

2. AI Worker (Python - Celery)

디렉터리 / 파일명	역할 및 기능	주요 메소드(예시)
tasks/ worker.py	Celery로부터 할당받은 분석 작업을 실행하는 메인 태스크	detect_fake_task(), extract_frames()
models/ inference.py	실제 AI 모델(Deepfake/T2V) 로드 및 추론 실행	predict_score(), get_xai_reason()
utils/ video_processor.py	비디오 파일 전처리 및 프레임 추출 유틸리티	resize_video(), save_frames()

3. Infrastructure (Docker)

파일명	역할 및 기능	비고
Dockerfile	각 서비스(Backend, Worker) 를 컨테이너화하기 위한 빌드 파일	이미지 최적화
docker-compose.yml	API, Worker, Redis 컨테이너 를 통합 실행 및 네트워크 관 리	개발/운영 환경 구성

4. AI Server

디렉터리 / 파일명	역할 및 기능	비고
README.md	프로젝트 개요 및 실행 방법	설치, 학습, 추론 명령 안내
OUTPUT_SPEC_CODE.md	출력 JSON 명세	학습 결과, 추론 결과, XAI, API 응답 형식 정의
docs/	설계 및 정리 문서	프로젝트 개요, 작업 현황, 설 계서 준비 문서
manifests/	데이터셋 manifest	학습/검증/테스트 샘플 목록
outputs/	추론 및 XAI 결과	single prediction, manifest prediction, heatmap, overlay
runs/	학습 결과	checkpoint, train metrics
tools/	보조 스크립트	데이터 정리, 캐시 생성, 실험 보조 도구
tests/	테스트 코드	pipeline test, API test
src/ai_video_detector/	AI 생성 영상 탐지 Python package	핵심 학습 및 추론 코드

10.3. 명칭표준안(변수,함수,파일명)

본 프로젝트의 소스 코드 및 데이터베이스 관리의 가독성과 통일성을 위해 다음과 같은 명칭 표준안을 준수한다.

[표 9.1] 기본 명명 규칙

구분	표기법 (Case)	예시	비고
Project Name	Kebab Case	deepfake-detection-service	전체 소문자 및 하이픈(-) 사용
Package / Directory	Lower Case	com.gachon.video.controller	단어 간 구분 없이 소문자 권장
Class / Interface	Pascal Case	VideoService, UserMapper	첫 글자 대문자, 명사형 사용
Method / Variable	Camel Case	uploadVideo(), isCorrect	첫 글자 소문자, 동사/형용사형
Constant (상수)	Snake Case (Upper)	MAX_FILE_SIZE, DEFAULT_SCORE	전체 대문자 및 언더바(_) 사용
DB Table	Snake Case (Lower)	users, video_results	복수형 명사 사용 권장
DB Column	Snake Case (Lower)	user_id, created_at	소문자 및 언더바(_) 사용

[표 9.2] 주요 구성 요소별 접미사(Suffix) 정의

프로젝트의 계층(Layer)을 명확히 구분하기 위해 클래스명 뒤에 다음과 같은 접미사를 붙인다.

구분	접미사	설명	예시
Controller	Controller	클라이언트 요청을 처리하는 진입점 클래스	VideoController
Service	Service	비즈니스 로직 및 외부 연동을 담당하는 클래스	AnalysisService
Repository	Repository	DB 접근 및 데이터 영속성을 담당하는 클래스	VideoRepository
Data Object	DTO	계층 간 데이터 전송을 위한 객체	VideoRequestDTO
Entity	(없음 / Entity)	DB 테이블과 1:1 매핑되는 도메인 모델	User, Video
AI Task	Task	Celery 등 워커에서 실행되는 비동기 작업	AnalyzeTask

[표 9.3] 가용 용어 및 약어 제한

의미가 불분명한 약어 사용을 지양하고, 프로젝트 내에서 통용되는 용어를 사전에 정의한다.

1. 동사 사용 표준:

- get...: 단순히 데이터를 조회할 때 (예: getUser)
- find...: 조건에 맞는 데이터를 검색할 때 (예: findByEmail)
- save... / create...: 데이터를 새로 생성하거나 저장할 때
- modify... / update...: 데이터를 수정할 때
- remove... / delete...: 데이터를 삭제할 때