

Explainable SNS Deepfake Detection

개요 및 문제 배경

문제 배경

- **SNS 딥페이크 확산** – 인스타·틱톡에 실제로 퍼져 사람들이 속음
- **벤치마크 ≠ 현실** – 학회 데이터는 풀렸지만 실제 SNS 영상은 도메인이 다름
- **점수만으론 신뢰 불가** – "92% 가짜" 숫자만으론 왜 가짜인지 알 수 없음
- **진화하는 생성기** – 최신 생성기는 기존 탐지기를 우회

해결방안 — Explainable SNS Detection

- SNS 도메인 특화 탐지 모델 구현 (F3NetLiteV2o)
- 실제 SNS 환경 데이터로 학습 (DF4o + SNS real)
- 실제 SNS 화면녹화로 **OOD 일반화 성능 검증**
- **XAI 설명 병행 제공** – 왜 가짜인지 근거까지




벤치마크는 풀렸는데, 현실은?

- 학회 벤치마크에서는 거의 완벽한 성능
- FF++ AUC **0.97** / DFDC AUC **0.99**
- 그러나 우리가 풀고 싶은 건 학회 데이터가 아니라, 실제 인스타·틱톡에 올라오는 딥페이크

❏ **핵심 질문:** 학회 데이터는 잘 잡는데, 실제 SNS 영상도 잡을까?

접근: 모델 아키텍처

F3NetLiteV20 (dual-branch, ~44M)



- RGB Branch (Xception) → 공간 텍스처
- FAD 3-band 주파수 Branch (Xception) → 주파수 아티팩트
- SEBlockFusion (채널 어텐션)으로 두 갈래 융합 → 판정

추론 흐름 (AI 파트)

- 영상 → 얼굴 검출·크롭 → 프레임별 추론
→ 앙상블 판정 → XAI 근거 생성

데이터 & 학습 전략

DF40

최신 생성기 40종, 약 24만 장 (sd2.1/DiT/SiT 등 최신 딥페이크)

FF++ / DFDC real

고전 진짜 얼굴

SNS real

실제 SNS 화면녹화, 자체 수집

SNS 도메인 증강

화면녹화 아티팩트 모사 (Double JPEG, bilateral/median 스무딩, resize-rescale, 노이즈)

① **핵심:** 최신 가짜 + 실제 SNS 화면 환경을 학습에 직접 주입
학습 데이터와 평가셋(140개)은 **출처가 분리됨**

잘 잡는 줄 알았는데, SNS는 동전 던지기였다

- in-distribution: FF++ **0.97** / DFDC **0.99**
- SNS 화면녹화 OOD: **0.41**
- 0.5(랜덤)보다도 낮음 - 도메인이 바뀌면 성능 붕괴

⚠ 벤치마크 잘 잡는 모델 ≠ 실제 **SNS** 잡는 모델
이 0.41을 끌어올리는 것이 프로젝트의 진짜 시작



0.41을 풀려고: 37번의 실험

01

v1~v5

아키텍처 탐색 (Xception → F3NetLite → Freq-only)

02

v6~v7

FF++/DFDC 통합 → cross-domain gap 해소

03

v8~v10

주파수 dual-branch(F3NetLite) 도입

04

v11~v13

DF40 단독 학습 → in-dist 과적합 실패

05

v15~v17

SNS 증강 투입 → 그래도 OOD 0.41 (Phase1 실패 선언)

06

v20

DF40+SNS 첫 학습 → 0.67 (base 모델)

07

v24

SNS real 5x 파인튜닝 → **0.87 (단일 최고)**

08

v28/v32/v34

DINOv2 계열 시도 → 0.81 (못 넘음)


09

sweep

v24+v25+v29 앙상블 → 0.89

총 37개 버전 – 변수를 하나씩만 바꾸며 통제 실험

무엇이 OOD를 풀었나 (Ablation)



- **Phase1** (주파수 모델 + SNS 증강, DF40 없음): **0.41**
- **+DF40** 데이터 (fake를 DF40 24만/40종으로 교체): **0.67** (+0.26)
- **+SNS real** 파인튜닝 (실제 SNS real 5x 오버샘플): **0.87** (+0.20)

❏ **결론:** OOD를 끌어올린 주역은 화려한 구조가 아니라 **데이터 전략** (주파수 구조 기여는 +0.066, 보조)

v16→v20은 구조 사실상 동일 → 바뀐 변수는 학습 데이터뿐. 주파수는 개별 판정 근거론 강함 (슬8) - 다른 층위

왜 최신 모델이 아니라 이걸 썼나 + 정직한 한계

왜 F3NetLiteV20?

- DINOv2-large (최신 SSL) OOD = 0.81
- F3NetLiteV20 (우리) OOD = 0.87 → 우리 OOD에선 최신 backbone을 이김 + 추론 가벼움

최종 성능 (정직하게)

- 단일 모델 v24 = **0.87** ← 대표 수치
- 앙상블 = 0.89 (단일 대비 +0.018 보조, 동일 셋 sweep이라 낙관적)


한계 (먼저 인정)

- 평가셋 n=140 – 라벨 신뢰성 위해 양보다 검증된 데이터 택함, 신뢰구간 넓음 인정
- 강한 후보정 오탐 – 보정·필터가 극단적으로 강한 진짜 영상은 딥페이크로 오탐 가능

개선사항

- 검증된 OOD 데이터 확장 → 신뢰구간 좁히고 현재 0.87을 더 위로
- 보정 강도 분리 학습 → "심한 보정 ≠ 딥페이크" 오탐 감소
- 최신 생성기 지속 편입 → 진화하는 딥페이크 대응

XAI: 점수가 아니라 '왜 FAKE인지'를 보여준다



- **판정:** CRITICAL / FAKE, Deepfake 확률 92.5%, 분석 프레임 30
- **어디:** Grad-CAM 히트맵 - 코·얼굴 중앙에 집중
- **언제:** Frame-by-Frame Anomaly 그래프 + threshold 라인
- **무엇으로:** 영상마다 RGB(공간) vs 주파수 중 결정 근거가 다름 → 매 판정마다 비율 분해 (예시 이 영상: Freq 63% / Spatial 37%)

① 공간·시간·주파수 **3중 근거 = 설명 가능한 포렌식 증거**, 고정 비율 아닌 영상별 적응형 설명
포지셔닝: 과학적 주장이 아니라 **제품 UX** - 기자·일반인이 눈으로 납득

정리

문제 인식

학회에선 풀린 듯 보이던 문제가 실제 SNS에선 **0.41**

해결

데이터 전략(DF4o + SNS real 파인튜닝)으로 **0.87**까지

설명

그 판정에 '왜'라는 **설명(XAI)**을 붙였다

현실적 출발점

한계는 분명히 인정하되, 실제로 쓸 수 있는 현실적 baseline을 만들었다

